TECHNISCHE HOCHSCHULE MITTELHESSEN

Campus Friedberg

Studienprojekt 2 · Masterstudiengang Mechatronik

Sturzerkennung mit TinyML in einer sensorischen Einlegesohle

Vom Rumpf zum Fuß: Datensätze, Modelltransfer, Sensororientierung und Prototyp auf dem ESP32-C6

Verfasser: Aly Elbermawy (Matr.-Nr. 5335848)
Betreuer: Prof. Dr. Sergej Kovalev
Industriepartner: TrackTech GmbH / Clever-Sole, Friedberg

Abgabe: Oktober 2026

Kurzfassung

Ziel des Projekts ist eine Sturzerkennung, die vollständig in einer Einlegesohle auf einem ESP32-C6 mit sechsachsiger *Inertial Measurement Unit* (IMU) läuft. Öffentliche Sturzdatensätze messen fast ausschließlich am Rumpf; einen Datensatz mit Stürzen an der Sohle gibt es nicht. Ein 1D-CNN (61 601 Parameter, int8 rund 77 KB) erreicht auf SisFall 99,0 % Sensitivität bei 99,3 % Spezifität, verliert aber an Bein und Fuß den Großteil seiner Leistung. Schrittweise wird gezeigt, woran das liegt und was hilft: Sturzdaten vom Schienbein heben die Sensitivität am Bein von 21 auf 83 %, treiben aber die Fehlalarme an der Sohle auf mehrere hundert je Stunde; Sohlendaten ohne Stürze senken sie um 91–96 %, ohne Sensitivität zu kosten. Als bislang unbeachtete Fehlerquelle erweist sich die **Achsenlage des Sensors**: Spiegelbildlich getragene Sensoren unterscheiden sich bei identischen Stürzen um bis zu Faktor neun, und allein die Ausrichtung der eigenen Hüftaufnahmen an den Achsen von SisFall hebt die Erkennung von 2 auf 15 von 22 Stürzen. Eine Rotationsaugmentierung macht das Modell signifikant robuster. Auf dem eigenen Prototyp erkennt das Modell nach Ausrichtung über die Schwerkraft – wie in der Firmware – alle 67 Stürze einer Person an Hüfte und Knöcheln; in der Sohle läuft es mit eigenen int8-Kernen in Echtzeit. Alle Aussagen sind subjektunabhängig kreuzvalidiert und, wo möglich, gepaart statistisch abgesichert.

Inhaltsverzeichnis

1 Theoretischer Hintergrund **1**
- 1.1 Motivation und Aufgabenstellung . . . 1
- 1.2 Sensorik: Achsen und Sensoreigenschaften . . . 1
- 1.3 Verfahren der Sturzerkennung . . . 1
- 1.4 Datensätze . . . 2

2 Durchführung **3**
- 2.1 Prototyp und Datenaufnahme . . . 3
- 2.2 Datenaufbereitung . . . 3
- 2.3 Modelle und Trainingskette . . . 4
- 2.4 Bewertungsmethodik . . . 4
- 2.5 Firmware . . . 4
- 2.6 Kommerzielles Modell . . . 5

3 Ergebnisse und Diskussion **6**
- 3.1 Basismodell am Rumpf . . . 6
- 3.2 Übertragbarkeit auf andere Datensätze . . . 6
- 3.3 Fehlalarme und zeitliche Plausibilisierung . . . 6
- 3.4 Progressives Training und Hard Negatives . . . 7
- 3.5 Zielgruppe: ältere Menschen . . . 7
- 3.6 Vom Rumpf zum Fuß . . . 7
- 3.7 Einfluss der Sensororientierung . . . 9
- 3.8 Pilotversuch auf der Zielhardware . . . 10
- 3.9 Eigene Sohlenaufnahmen . . . 11
- 3.10 Funktionstest in der Sohle . . . 11
- 3.11 Übersicht der geprüften Behauptungen . . . 12
- 3.12 Einschränkungen . . . 12

4 Zusammenfassung und Ausblick **13**

Literaturverzeichnis **14**

1 Theoretischer Hintergrund

1.1 Motivation und Aufgabenstellung

Stürze sind bei älteren und pflegebedürftigen Menschen eine der häufigsten Ursachen schwerer Verletzungen; entscheidend ist oft nicht der Sturz selbst, sondern wie lange die Person unbemerkt liegen bleibt. Der Projektpartner Clever-Sole entwickelt eine sensorische Einlegesohle. Das Studienprojekt untersucht, ob sich darin eine Sturzerkennung *auf dem Gerät* (TinyML) realisieren lässt. Die Aufgaben umfassen (1) die Wahl der Sensorkonfiguration, (2) die relevanten Sensoreigenschaften, (3) die Bewertung öffentlicher Datensätze und (4) Entwicklung, Training und prototypische Integration des Modells. Der Schwerpunkt liegt auf Aufgabe 4.

1.2 Sensorik: Achsen und Sensoreigenschaften

Ein **3-Achsen**-Beschleunigungssensor erfasst Aufprall und Freifall über den Betrag $|a|$, kann aber sturzähnliche Alltagsaktivitäten (*Activities of Daily Living*, ADL) wie kräftiges Hinsetzen schlecht abgrenzen [1, 2]. Ein **Gyroskop** (6 Achsen) ergänzt die Drehrate, also die für einen Sturz typische schnelle Rotation in die Horizontale; in der Literatur steigt dadurch vor allem die Spezifität, z. B. von 82,7 auf 96,2 % [2]. Ein **Magnetometer** (9 Achsen) liefert eine absolute Richtung und korrigiert die Gyroskopdrift [3]. Diese Drift ist über die ein bis zwei Sekunden eines Sturzes vernachlässigbar, während Magnetfelder in Innenräumen durch Stahl und Geräte gestört werden [4]. Empfohlen wird daher eine **6-Achsen-IMU**; Tabelle 1.1 fasst den Arbeitspunkt zusammen.

Tabelle 1.1: Sensoreigenschaften und empfohlener Arbeitspunkt.

Eigenschaft	Wirkung auf die Sturzerkennung	Empfehlung
Messbereich	Zu klein: Aufprallspitze wird abgeschnitten (Clipping) [5]	$\pm 16\,\mathrm{g}$
Abtastrate	15–20 Hz genügen dem CNN [6, 7]; Erfassung höher, dann filtern	$\geq 100\,\mathrm{Hz} \rightarrow 50\,\mathrm{Hz}$
Auflösung	Effektiv durch Rauschen begrenzt [8]	$\geq 12\,\mathrm{Bit}$
Rauschdichte	Relevant für feine Merkmale, nicht für den Aufprall [9]	$\lesssim 100\,\mu\mathrm{g}/\sqrt{\mathrm{Hz}}$
Gyroskopdrift	Über die Sturzdauer vernachlässigbar [3]	unkritisch

1.3 Verfahren der Sturzerkennung

Schwellwertverfahren lösen aus, wenn $|a|$ einen Freifall- und einen Aufprallschwellwert über- bzw. unterschreitet [10]. **Klassische ML-Verfahren** wie der Random Forest arbeiten auf Merkmalen je Zeitfenster; beruhen diese auf Vektorbeträgen, sind sie unabhängig von der Einbaulage. Ein **1D-CNN** lernt die Merkmale direkt aus dem Rohsignal (Fenster $T \times 6$). Es ist dadurch leistungsfähiger, verarbeitet die sechs Kanäle aber einzeln und ist *nicht* drehinvariant: Dieselbe Bewegung erscheint bei gedrehtem Sensor in anderen Kanälen.

Domänenlücke und Transfer Learning. Ein Modell, das an einer Position und mit einer Sensorhardware trainiert wurde, überträgt sich nicht zwangsläufig auf eine andere (*Domänenlücke*). Beim Fine-Tuning werden die Gewichte eines vortrainierten Modells mit kleiner Lernrate auf Daten der Zieldomäne nachtrainiert, bei progressivem Fine-Tuning über eine Zwischendomäne.

Orientierung. Wird der Sensor um eine Rotationsmatrix R gedreht, gilt für Beschleunigung und Drehrate $a' = R\,a$, $\omega' = R\,\omega$. Bei einer Spiegelung (linke statt rechte Körperseite) verhält sich ω als Pseudovektor: Die gespiegelte Achse der Beschleunigung wechselt das Vorzeichen, beim Gyroskop die beiden anderen. Eine **Rotationsaugmentierung** ergänzt das Training um zufällig gedrehte und gespiegelte Kopien jedes Fensters, damit das CNN die Orientierung nicht als Merkmal lernt.

Bewertungsgrößen. Sensitivität $Se = TP/(TP + FN)$ (erkannte Stürze), Spezifität $Sp = TN/(TN + FP)$, Genauigkeit Acc und – für den Einsatz entscheidend – **Fehlalarme je Stunde** Alltag (FP/h). Bei seltenen Stürzen ist die Genauigkeit wenig aussagekräftig: Ein Modell, das nie alarmiert, erreicht bereits über 97 %.

1.4 Datensätze

Tabelle 1.2 und Abbildung 1.1 zeigen die verwendeten Datensätze und ihre Messorte. Kein Datensatz enthält Stürze an der Sohle; die beiden Sohlendatensätze enthalten nur Alltag. MobiAct wurde wegen Smartphone-Sensorik (±2 g) und nicht-kommerzieller Lizenz nicht verwendet, UniMiB-SHAR (nur Beschleunigung) nur für den Achsenvergleich.

Tabelle 1.2: Verwendete Datensätze (P: Probanden, S: Stürze vorhanden).

Datensatz	Position	Hz	P	S	Rolle im Projekt
SisFall [11]	Hüfte	200	38	ja	Basismodell
KFall [12]	unterer Rücken	100	32	ja	Transfer, Zwischenstufe
UMAFall [13]	5 Positionen	20	19	ja	Transfer, Knöchel
FallAllD [14]	Nacken, Hand, Taille	238	15	ja	Transfer
WEDA-FALL [15]	Handgelenk	50	25	ja	Ältere (77–95 J.)
CAPPIMU [16]	9 Positionen	50	30	ja	Positionskurve, Beinmodell
ImbalanSense [17]	Sohle	100	40	nein	Alltag am Fuß (Training)
Smart-Insole [18]	Sohle	100	29	nein	externer Test, Vorher/Nachher
Eigene Pilotdaten	Hüfte, Knöchel	100	1	ja	Test auf Zielhardware

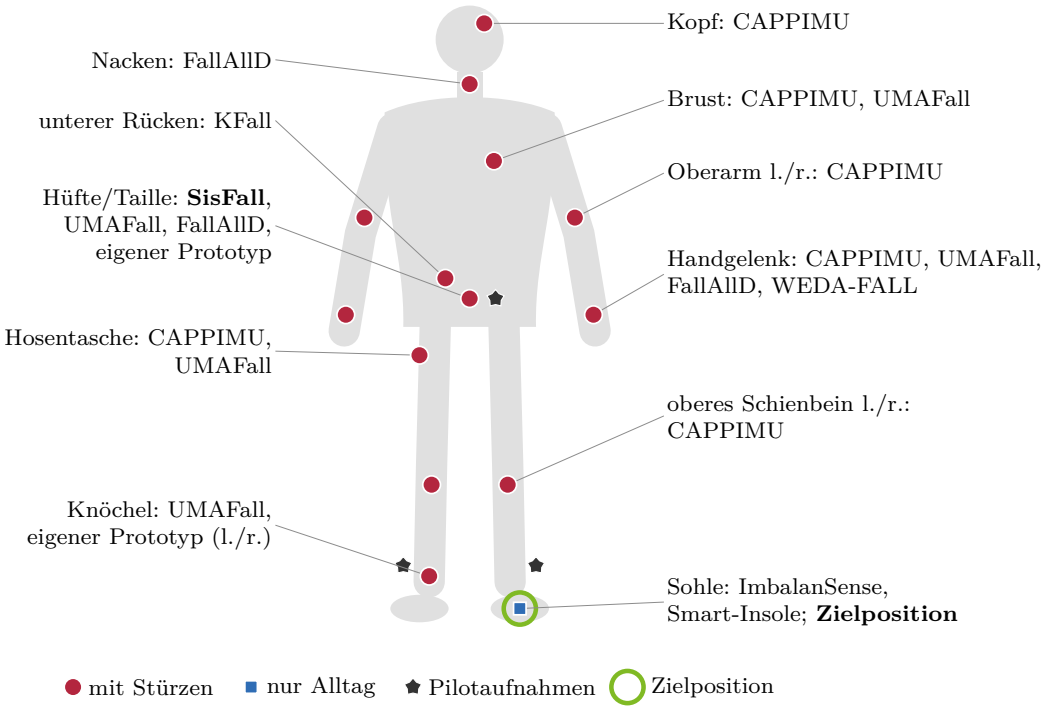


Abbildung 1.1: Messorte der Datensätze am Körper. Stürze liegen nur an Rumpf, Armen, Schienbein und Knöchel vor; an der Sohle nur Alltagsdaten.

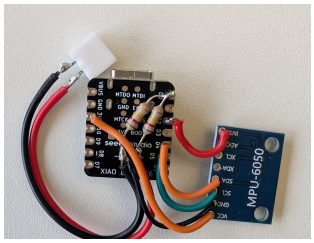
2 Durchführung

2.1 Prototyp und Datenaufnahme

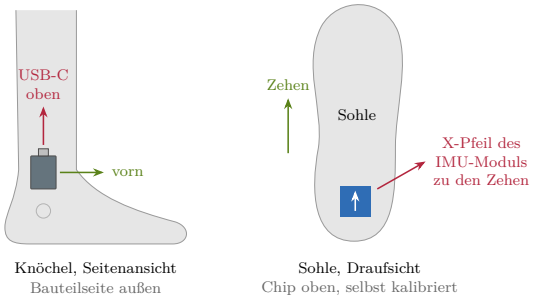
Der Prototyp besteht aus einem Seeed Studio XIAO ESP32-C6 (RISC-V, 160 MHz, BLE, USB-C) und einem IMU-Modul (HW-123, Aufdruck MPU-6050; die Firmware erkennt den Chip über das Register `WHO_AM_I`), verbunden über I^2C und versorgt über einen Akkuanschluss (Abbildung 2.1). Die IMU läuft mit ±16 g, ±2000 °/s und 100 Hz bei aktivem digitalem Tiefpassfilter. Für die Pilotdaten wurde eine eigene Firmware (*DatenLogger*) geschrieben: Aufnahme mit 100 Hz in den internen Flash, Bedienung per Smartphone über Bluetooth (Aktivität wählen, Start/Stopp), automatischer Stopp nach 120 s und Auslesen per Python-Skript. Da Flash-Schreibzugriffe einzelne Abtastwerte verzögern, werden die Daten anhand der Zeitstempel auf ein exaktes 100-Hz-Raster interpoliert.



(a) Oberseite



(b) Unterseite



(c) Einbaulage: Pilotaufnahmen (Knöchel), Zielposition (Sohle)

Abbildung 2.1: Prototyp: XIAO ESP32-C6 mit IMU-Modul und Akkuanschluss (a, b) sowie Einbaulage des Sensors (c).

Aufnahmeprotokoll. Eine Person (der Verfasser) trug den Sensor an der Hüfte sowie am rechten und linken Knöchel (USB-Buchse jeweils oben). Je Position wurden vier Sturzarten auf eine Matte aufgezeichnet (auf die Knie, vorwärts, seitlich, rückwärts; je vier bis acht Wiederholungen mit anschließender Liegephase von 5 s) sowie Gehen, Joggen, Treppen, Hinsetzen, kräftiges Hinsetzen, Springen, Aufheben und Hinlegen. Insgesamt liegen 22/23/22 Stürze und 9,7/6,6/7,2 min Alltag (Hüfte/Knöchel rechts/links) vor. Aufnahmen in beiden Sohlen (vier Sturzarten, Alltag) entstanden erst zum Projektende; sie werden in Abschnitt 3.9 beschrieben, aber noch nicht mit dem Modell ausgewertet.

2.2 Datenaufbereitung

Alle Datensätze werden in eine gemeinsame Form gebracht: sechs Kanäle in g und °/s, gefiltertes Heruntertasten auf 50 Hz, Fenster von 2 s (100×6) und Z-Normalisierung je Fenster und Kanal. Ein Sturzfenster wird auf den Aufprall (Maximum von $|a|$) zentriert; innerhalb einer Sturzaufnahme gilt *nur* dieses Fenster als Sturz. Zwei Sonderfälle erforderten eigene Lösungen:

- **CAPPIMU** beschriftet eine ganze Sturzsitzung (≈ 160 s) als *fall*. Einzelne Aufpralle werden an der Brust detektiert (> 2,5 g, Abstand ≥ 4 s) und über die gemeinsamen Zeitstempel auf alle Positionen übertragen.
- **Pilotdaten:** Am Knöchel ist der Sturz (2,6–2,9 g im Median) oft schwächer als Klopfmarken oder Springen (bis 12 g). Der Aufprall wird daher über die folgende Liegephase bestimmt: Ruhe ≥ 2 s, deren Schwerkraftrichtung um mehr als 40° von der Stehhaltung abweicht; Aufprall ist das Maximum von $|a|$ in den 2 s davor.

2.3 Modelle und Trainingskette

Das CNN besteht aus drei Faltungsblöcken (32/64/128 Filter, Kernel 5, Batch-Normalisierung, Max-Pooling), Global-Average-Pooling, einer Dense-Schicht (64) mit Dropout 0,3 und Sigmoid-Ausgang (61 601 Parameter, Adam, binäre Kreuzentropie, Klassengewichte). Als Vergleich dienen ein Schwellwertverfahren und ein Random Forest mit 18 Betragsmerkmalen. Abbildung 2.2 zeigt die Trainingskette für das Fußmodell.

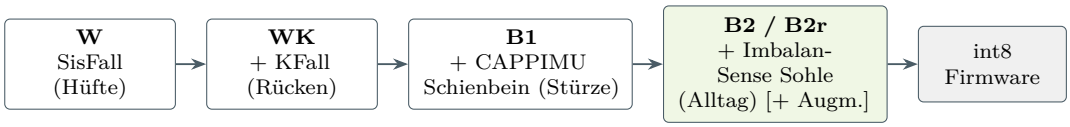


Abbildung 2.2: Trainingskette vom Rumpf- zum Fußmodell. B2r: B2 mit Rotations-/Spiegelaugmentierung (eine zufällig gedrehte, mit 50 % gespiegelte Kopie je Fenster).

2.4 Bewertungsmethodik

- **Subjektunabhängig:** Kein Proband erscheint zugleich in Training und Test.
- **Fünffache Kreuzvalidierung, gepaart:** Verfahren werden auf denselben Falten verglichen; berichtet wird die mittlere Differenz mit 95 %-Konfidenzintervall. Ein Unterschied gilt als gesichert, wenn das Intervall die Null nicht enthält. Konfidenzintervalle einzelner Anteile nach Wilson.
- **Fehlalarme** auf reinen Alltagsdaten, umgerechnet je Stunde (Fenster mit 1 s Versatz, ohne Abstimmungsregel).
- **Betriebsbewertung** wie in der Firmware: Inferenz alle 0,2 s, Alarm bei 3 von 5 Fenstern über 0,5. Ein Sturz gilt als erkannt, wenn spätestens 1 s nach dem Aufprall ein Alarm fällt; jeder Alarm im Alltag ist ein Fehlalarm-Ereignis.

Der Code liegt in einer gemeinsamen Bibliothek (`fall_lib.py`) und fünf Colab-Notebooks: (01) Basismodell, (02) Transfer, Fehlalarme, Zielgruppe, (03) progressives Training, (04) Fuß und Orientierung, (05) Pilotdaten (Teil E: kommerzielles Modell, vorbereitet).

2.5 Firmware

Die Firmware ist für die Einlegesohle ausgelegt. Sie liest die IMU mit 100 Hz, tastet auf 50 Hz herunter, hält einen Ringpuffer von 2 s und wertet alle 200 ms das int8-Modell aus (77 KB, gemessen ≈ 117 ms je Fenster). Eine 3-von-5-Regel entscheidet über den Alarm, der per BLE gemeldet wird; je Sturz wird genau ein Alarm ausgelöst. Eingesetzt wird B2r, da es gegenüber Drehungen am robustesten ist (Abschnitt 3.7); int8 und Gleitkommamodell treffen auf den Pilotfenstern in 99,5 % der Fälle dieselbe Entscheidung.

Eigene int8-Kerne statt TensorFlow Lite Micro. Mit TensorFlow Lite Micro lieferte das Modell auf dem ESP32-C6 unabhängig vom Eingang konstant $p \approx 0{,}47$, während dieselbe Datei am PC korrekt rechnete. Auch nach dem Einrechnen der Batch-Normalisierung in die folgende Schicht (maximale Abweichung $< 10^{-5}$) blieb der Fehler. Die Firmware rechnet das Netz deshalb mit eigenen, rund 130 Zeilen langen int8-Kernen (Faltung, Max-Pooling, Mittelwert, Dense), die die Festkomma-Arithmetik der TensorFlow-Lite-Referenz nachbilden. Das Exportskript erzeugt daraus die Gewichtsdatei, kompiliert die Kerne am PC und vergleicht sie mit dem TensorFlow-Lite-Interpreter: Faltungen und Dense-Schichten sind bitgleich, der Mittelwert weicht höchstens um eine int8-Stufe ab, die Entscheidungen stimmen in allen Fenstern überein. Beim Start rechnet die Firmware fünf Selbsttest-Muster nach.

Selbstkalibrierung der Einbaulage. Vorgabe ist: IMU-Modul flach unter der Ferse, Chip oben, aufgedruckter X-Pfeil zu den Zehen. Da die Lage in einer Sohle nie exakt ist, bestimmt die Firmware sie nach jedem Aufwachen selbst: Die Schwerkraft im Stillstand liefert die Hochachse, die Hauptdrehachse der Winkelgeschwindigkeit beim Gehen die Querachse, und der aufgedruckte X-Pfeil legt fest, wo vorn ist (die Richtung aus den Gangdaten allein erwies sich an der Sohle als unzuverlässig). Weicht die so bestimmte Lage um mehr als 45° von der Vorgabe ab, wird nur die Neigung korrigiert. Daraus folgt die Drehung in den Trainingsrahmen (x' vorwärts, y' abwärts, z' links). Auf den Knöchelaufnahmen, rechnerisch in beliebige Lagen gedreht, stellte das Verfahren die Achsen in allen Fällen richtig wieder her (Vorwärtsstürze danach $x' = -0{,}89$ bis $-1{,}0$); an der Sohle ist es im Betrieb bestätigt (Abschnitt 3.10).

Sturzrichtung und Testmodus. Nach einem Alarm wertet die Firmware die erste Ruhephase aus und meldet die Lage als Schätzung (Bauchlage ≈ vorwärts, Rückenlage ≈ rückwärts, seitlich). Das Modell selbst unterscheidet nur Sturz und Nicht-Sturz; seine Ausgabe p ist kein kalibrierter Wahrscheinlichkeitswert. Eine Live-Anzeige gibt alle 0,2 s Sturz-Wert, Stimmen und Urteil aus, seriell und über den Nordic UART Service (z. B. App *Serial Bluetooth Terminal*). Wahlweise hält die Auswertung nach einem Alarm an, bis `R` gesendet wird.

2.6 Kommerzielles Modell

Für den Projektpartner ist ein zweites Modell vorbereitet, das nur Daten verwendet, deren Lizenz eine kommerzielle Nutzung nicht ausschließt (**alle Datensätze außer Smart-Insole und MobiAct**): Vortraining auf einem gemischten, orientierungsaugmentierten Pool aller Positionen, danach wie B2r auf Schienbein und ImbalanSense, zuletzt um die eigenen Pilotaufnahmen ergänzt (Notebook 05, Teil E). Dieser Lauf wurde im Projektzeitraum nicht mehr ausgeführt; die Ergebnisse dieses Berichts beziehen sich alle auf B2r. Die Lizenzen sind vor einer Übergabe im Einzelnen zu prüfen.

3 Ergebnisse und Diskussion

Die Ergebnisse sind entlang der Behauptungen geordnet, die im Projekt geprüft wurden. Tabelle 3.8 am Ende des Kapitels fasst zusammen, welche sich bestätigt haben und welche nicht.

3.1 Basismodell am Rumpf

Tabelle 3.1: Basismodelle auf SisFall, subjektunabhängiger Testsatz (10 Probanden, 12 431 Fenster). Quelle: Notebook 01.

Modell	Se	Sp	Acc	FP	FN
Schwellwert ($\lvert a\rvert > 2{,}8$ g)	96,7 %	82,9 %	83,2 %	2 074	10
Random Forest (18 Betragsmerkmale)	92,7 %	99,6 %	99,4 %	48	22
1D-CNN	**99,0** %	**99,3** %	**99,3** %	82	**3**

Jede Stufe behebt die Schwäche der vorigen: Der Random Forest senkt die Fehlalarm-Fenster des Schwellwerts um den Faktor 43, das CNN die übersehenen Stürze von 22 auf 3. Ein Schwellwert kann nur Sensitivität gegen Fehlalarme tauschen: Bei 1,5 g erkennt er alle Stürze bei 57,5 % Spezifität, bei 4,0 g noch 74,7 % der Stürze bei 95,9 % Spezifität. Im Random Forest entfallen 62,3 % der Merkmalswichtigkeit auf das Gyroskop. Der direkte Achsenvergleich mit identischem CNN relativiert den Nutzen jedoch: mit 6 Achsen 99,3 %, nur mit Beschleunigung 98,0 %, nur mit Gyroskop 94,7 % Sensitivität. An der Hüfte liegt die Leistung nahe der Obergrenze; der Vorteil des Gyroskops (+1,3 pp) ist dort klein. Ein mit 3 Achsen trainiertes Modell erreicht auf UniMiB-SHAR (± 2 g, Hosentasche) nach Fine-Tuning 95,5 % (Zero-Shot 23,5 %).

3.2 Übertragbarkeit auf andere Datensätze

Tabelle 3.2: Transfer des SisFall-Modells. Zero-Shot (ZS) und nach Fine-Tuning (FT), je eine subjektunabhängige Aufteilung. Quelle: Notebook 02.

Datensatz	Position, Hz	Se ZS	Se FT	Anmerkung
KFall	Rücken, 100	99,5 %	100,0 %	Sp 99,5 % ohne Anpassung
UMAFall	Taille, 20	45,8 %	93,8 %	
UMAFall	Knöchel, 20	25,0 %	25,0 %	36 Sturzfenster im Test; CV in Tab. 3.3
FallAllD	Taille, 238	11,3 %	75,8 %	Messbereich ± 8 g

KFall überträgt ohne Anpassung, FallAllD trotz der höchsten Abtastrate kaum. Ein Kontrollversuch schließt den Messbereich als Ursache aus: Auf ± 8 g und ± 4 g begrenzte SisFall-Testdaten erreichen unverändert 99,0 %, selbst ± 2 g noch 98,0 %. Ursprünglich wurde die Lücke den Signaleigenschaften der Hardware zugeschrieben. Die Ergebnisse zur Orientierung (Abschnitt 3.7) legen eine einfachere Erklärung nahe: An der eigenen Hüfte bricht das Basismodell ebenso ein und erholt sich allein durch Ausrichtung der Achsen. Für FallAllD wurde dies nicht geprüft, ist aber naheliegend.

3.3 Fehlalarme und zeitliche Plausibilisierung

Auf den Alltagsdaten am Knöchel (UMAFall, 1,76 h) löst das Basismodell 3,8 % der Fenster aus, rund 137 Fehlalarme je Stunde, vor allem beim Joggen (20,1 %), Türöffnen (5,7 %) und Gehen (4,9 %) – also bei jedem Fersenaufsatz. Die Wahrscheinlichkeit liegt dabei bis $p = 1{,}000$; eine höhere Schwelle allein hilft nicht.

Eine N-von-M-Regel verlangt N positive unter den letzten M Entscheidungen. Sie wirkt erst bei kleiner Schrittweite (0,2 s): Bei 1 s liegt der Aufprall in nur einem Fenster, sodass jede Regel mit $N \geq 2$ scheitert. Auf UMAFall (47 Stürze, 0,57 h Alltag) senkt *3-von-5* die Fehlalarme des angepassten Modells um 70 % (246 → 74/h), kostet aber 40 % der erkannten Stürze (25 → 15). Strengere Regeln lassen kaum Stürze übrig (*5-von-7*: 3 von 47 bei 40/h). Das nicht angepasste Modell erkennt mit 3-von-5 ebenso 15 Stürze, bei 98/h. **Voting allein löst das Fehlalarmproblem am Knöchel nicht**; es glättet nur, was das Modell liefert.

3.4 Progressives Training und Hard Negatives

Tabelle 3.3: UMAFall-Knöchel, fünffach kreuzvalidiert (157 Stürze). Quelle: Notebook 03.

	Strategie	**Se [95 %-KI]**	**Sp**
A	Zero-Shot (SisFall)	28,7 % [22,2; 36,2]	96,2 %
B	direkt: SisFall → UMAFall	35,7 % [28,6; 43,4]	96,8 %
C1	nur Zwischenstufe KFall	12,7 % [8,4; 18,9]	98,6 %
C2	progressiv: SisFall → KFall → UMAFall	**56,7** % [48,9; 64,2]	96,8 %

Progressiv übertrifft direkt um +23,8 pp (KI [+3,9; +43,8], 3 von 5 Falten besser, 2 gleich; Spezifität unverändert), obwohl die Zwischenstufe allein die Leistung zunächst senkt (C1): Sie verallgemeinert die Repräsentation, statt sie zu verbessern. Eine Höhergewichtung impactstarker Alltagsfenster (*Hard Negatives*, Faktor 3) hebt zwar die Spezifität um +1,8 pp, kostet aber −6,3 pp Sensitivität (KI [−9,9; −2,6], beides gesichert, 5 von 5 Falten). Für ein Notrufsystem ist das der falsche Tausch, denn Fehlalarme lassen sich nachgelagert filtern, übersehene Stürze nicht.

Eine Einschränkung zeigt Abschnitt 3.7: Mit vielen Sturzdaten am Bein (CAPPIMU, 1462 Sturzfenster) ist ein Modell *ohne* Rumpf-Vortraining (L0) ebenso gut wie die progressive Kette (B2; +0,5 pp, nicht gesichert). Das Vortraining hilft also, wenn Zieldaten knapp sind.

3.5 Zielgruppe: ältere Menschen

Auf WEDA-FALL (Handgelenk) erzeugen Ältere bei gleichen Aktivitäten 4,0-mal mehr Fehlalarme (172 gegenüber 43/h, Schwelle 0,9). Die Aufschlüsselung zeigt, dass dies vor allem auf Klatschen (21,0 gegenüber 2,0 % der Fenster) und Türöffnen (6,8 gegenüber 0,8 %) zurückgeht; beim Gehen (0,2 gegenüber 0,4 %) und Treppensteigen schneiden Ältere sogar besser ab. An der Sohle (Smart-Insole) liegen Ältere (127/h) und Parkinson-Patienten (120/h) dagegen bei denselben Geh- und Aufstehtests deutlich über jüngeren Erwachsenen (69/h). Für die Sohle ist die Zielgruppe also ein realer Faktor.

3.6 Vom Rumpf zum Fuß

Die Sohle ist die schwierigste Position. Die Partnerdaten des bestehenden Sohlenprototyps sind mit 10 Hz, ±2 g je Achse (6,4 % aller Achswerte am Anschlag, schon beim Gehen) und ohne Gyroskop nicht verwendbar. Unverfälschte Sohlendaten zeigen, warum: Schon beim Gehen erreicht $|a|$ im 99. Perzentil 4,4–5,1 g, Einzelachsen bis ±16 g – mehr als viele Stürze am Rumpf. Tabelle 3.4 zeigt das unveränderte Basismodell an allen Positionen.

Tabelle 3.4: Basismodell (Zero-Shot) je Position. CAPPIMU: dieselben Stürze gleichzeitig an neun Positionen (je 731 Sturzfenster, ≈ 31 h Alltag). Quelle: Notebook 04, Teil A.

Position	Se	FP/h	Position	Se	FP/h
Kopf	28,5 %	66	Handgelenk rechts	50,9 %	133
Brust	51,4 %	81	Hosentasche	21,2 %	63
Oberarm links	5,1 %	45	Schienbein links	12,2 %	152
Oberarm rechts	47,3 %	72	Schienbein rechts	48,3 %	43
Handgelenk links	13,5 %	83	**Sohle** (ImbalanSense / Smart-Insole)	–	**65 / 101**

Statt einer mit dem Abstand vom Rumpf fallenden Kurve unterscheiden sich **linke und rechte Seite** bei identischen Stürzen um bis zu Faktor neun – ein Befund, dem Abschnitt 3.7 nachgeht. Zugleich zeigt sich, warum ein Spitzenwert am Bein nicht trennen kann: Am Schienbein liegt die Aufprallspitze eines Sturzes im Median bei 2,9–3,0 g, das 99. Perzentil des Alltags bei 9,9–10,2 g; an der Brust (5,0 gegenüber 6,0 g) und am Kopf (2,9 gegenüber 2,2 g) liegen beide noch nah beieinander.

Vorher/Nachher: Daten vom Bein und vom Fuß. Tabelle 3.5 zeigt, wie sich die Leistung mit jeder Datenquelle ändert. Bewertet wird auf Testprobanden, die nicht im Training waren; Smart-Insole ist außer in der letzten Zeile ein vollständig externer Test. Die oberen vier Zeilen (ohne Augmentierung) und die unteren drei (augmentiert) stammen aus zwei Läufen; verglichen wird jeweils nur innerhalb eines Blocks.

Tabelle 3.5: Wirkung von Bein- und Fußdaten, fünffach kreuzvalidiert (1462 Sturzfenster am Schienbein). Quelle: Notebook 04, Teil B (oben) und Teil E (unten).

		Schienbein		FP/h Sohle	
	Training	**Se [95 %-KI]**	**Sp**	**ImbalanSense**	**Smart-Insole**
A	SisFall (Basis)	30,2 % [27,9; 32,6]	97,3 %	65	101
K	+ KFall	21,5 % [19,5; 23,7]	98,5 %	105	115
B1	+ Schienbein-Stürze (*ohne* Fußdaten)	83,2 % [81,2; 85,0]	98,8 %	268	400
B2	+ ImbalanSense (Sohle, ohne Stürze)	77,6 % [75,4; 79,6]	90,3 %	36	81
B1r	B1, augmentiert	84,3 % [82,4; 86,1]	98,5 %	350	310
B2r	B1r + ImbalanSense, augmentiert	**84,0** % [82,0; 85,8]	96,0 %	**13,2**	**28,0**
	B2r + Smart-Insole im Training	82,1 % [80,0; 84,0]	98,1 %	1,6	11,1

Drei Befunde. (1) **Sturzdaten vom Bein sind entscheidend**: +61,5 pp Sensitivität (B1 gegenüber K, KI [+59,3; +63,8], 5 von 5 Falten). (2) **Ohne Fußdaten explodieren die Fehlalarme an der Sohle** (268 bis 400/h): Das Modell lernt „kräftiger Beinimpuls = Sturz“, und jeder Fersenaufsatz ist einer. (3) **Fußdaten ohne Stürze beheben das – ohne Sensitivitätsverlust aber nur mit Augmentierung.** Augmentiert (B2r gegenüber B1r) sinken die Fehlalarme um 96 bzw. 91 % (Spezifität +9,4 bzw. +8,1 pp, gesichert), die Sensitivität bleibt gleich (−0,2 pp, nicht verschieden). Ohne Augmentierung (B2 gegenüber B1) sinken die Fehlalarme ebenfalls (−87 bzw. −80 %), dafür fällt die Spezifität am Schienbein gesichert um 8,6 pp und die Sensitivität um 5,8 pp (nicht gesichert). Im Gegensatz zu den Hard Negatives werden hier keine vorhandenen Fenster umgewichtet, sondern Daten der Zielposition ergänzt. Smart-Insole als zweite Sohlenquelle senkt die Fehlalarme zwar weiter (13,2 → 1,6 bzw. 28,0 → 11,1/h), kostet aber gesichert Sensitivität (−2,0 pp, KI [−3,7; −0,2], nur 1 von 5 Falten). Da die Lizenz zudem nicht-kommerziell ist, bleibt B2r das eingesetzte Modell; die Zeile dient nur dem Bericht. Die Genauigkeit wird nicht berichtet:

Sie liegt bei seltenen Stürzen in allen Zeilen über 90 %, obwohl die Sensitivität zwischen 21 und 84 % schwankt.

3.7 Einfluss der Sensororientierung

Spiegeltest. Werden die Sensoren der linken Körperseite rechnerisch an der xz-Ebene gespiegelt (Gyroskop als Pseudovektor), erreicht das Basismodell dort die Werte der rechten Seite: Oberarm 5,1 → 53,8 %, Handgelenk 13,5 → 57,5 %, Schienbein 12,2 → 48,3 %. Umgekehrt fällt die gespiegelte rechte Seite auf 4,4, 7,7 und 14,9 %. **Der Seitenunterschied ist damit vollständig durch die Achsenlage erklärt.** Bei 20 zufälligen Drehungen schwankt die Sensitivität am Schienbein zwischen 6 und 58 %.

Gegenmaßnahme: Augmentierung. Tabelle 3.6 vergleicht fünf Trainingsketten auf denselben Falten.

Tabelle 3.6: Trainingsketten, fünffach kreuzvalidiert. Gedreht: Mittel über fünf zufällige Drehungen der Testdaten. Quelle: Notebook 04, Teil D; alle fünf Zeilen stammen aus demselben Lauf und denselben Falten, nur so ist der Vergleich zwischen den Ketten zulässig.

		Se Schienbein		**FP/h Sohle**	
	Kette	**original**	**gedreht**	**IMB**	**SI**
W	SisFall	30,2 %	27,1 %	65	101
WK	SisFall → KFall	21,1 %	16,8 %	80	88
L0	Bein + Fuß *ohne* Vortraining	83,6 %	51,6 %	4	18
B2	WK → Bein + Fuß	84,1 %	57,9 %	17	50
B2r	wie B2, augmentiert	**84,7** %	**75,8** %	**5**	**16**

Die Augmentierung kostet nichts: gedreht +17,9 pp (KI [+11,9; +23,9], 5 von 5 Falten), original +0,8 pp (nicht verschieden), Spezifität an Smart-Insole gesichert höher (+1,0 pp), an ImbalanSense nicht verschieden.

Die Fehlalarmraten dieser Tabelle sind nicht mit denen aus Tabelle 3.5 vergleichbar: beide Läufe verwenden unterschiedliche Obergrenzen für die Alltagsstichprobe und unterschiedliche Zufallsstartwerte, und die Fehlalarme an der Sohle streuen zwischen den Falten erheblich (B1r: 65 bis 755/h). Für B2r stehen deshalb hier 5 bzw. 16/h, in Tabelle 3.5 dagegen 13,2 bzw. 28,0/h. Belastbar ist jeweils nur der Vergleich *innerhalb* einer Tabelle.

Eigene Hüfte in den SisFall-Rahmen. SisFall definiert die Achsen des Gürtelsensors als $+z$ vorwärts, $+y$ nach unten, $+x$ nach rechts [11]. Am Prototyp zeigte die Schwerkraft im Stand auf $-x$, und die Liegelage nach Vorwärts- und Rückwärtsstürzen weist $+z$ als Vorwärtsrichtung aus. Daraus folgt die feste Drehung $x_S = -y$, $y_S = x$, $z_S = z$ samt Ausgleich der Platinenneigung ($\approx 25°$) – bestimmt aus der Einbaulage, nicht aus den Ergebnissen. Das *unveränderte* Basismodell erkennt danach **15 statt 2 von 22 Stürzen** bei etwa gleicher Zahl an Fehlalarmen (13 statt 12; Tabelle 3.7). Nur die Achsenvertauschung ohne Ausgleich der Neigung bringt 8 von 22. Ebenso zeigte die Liegelage, dass der linke Knöchelsensor gegenüber dem rechten um 180° um die Hochachse gedreht war.

3.8 Pilotversuch auf der Zielhardware

Tabelle 3.7: Betriebsbewertung auf den eigenen Aufnahmen (3 von 5, Schwelle 0,5): erkannte Stürze / Fehlalarm-Ereignisse. „Lage über Schwerkraft“: Drehung der mittleren Schwerkraft im Stand auf die des Trainings, wie in der Firmware. Quelle: Notebook 05. Alltag: Hüfte 9,3, rechts 6,2, links 6,8 min mit gezielt schwierigen Bewegungen (Springen, kräftiges Hinsetzen, Aufheben).

Modell	Hüfte	Knöchel rechts	Knöchel links
Basis (SisFall), Rohdaten	2/22 / 12	16/23 / 16	8/22 / 39
Basis, Achsen wie SisFall	15/22 / 13	–	–
Basis, Lage über Schwerkraft	13/22 / 6	14/23 / 9	15/22 / 7
B2 (Bein + Fuß)	11/22 / 93	17/23 / 28	10/22 / 35
B2r (augmentiert)	18/22 / 83	21/23 / 21	17/22 / 29
B2r, Lage über Schwerkraft	**22/22 / 65**	**23/23 / 12**	**22/22 / 17**

Ohne Lageausgleich erkennt B2r am Knöchel 17 bis 21 der Stürze und liegt damit deutlich über B2. Richtet man die Aufnahmen wie die Firmware über die Schwerkraft aus (Neigung 35–47° am Knöchel), erkennt B2r **alle 67 Stürze**, obwohl es weder diese Hardware noch diese Person gesehen hat; am Knöchel bei 12 bzw. 17 Fehlalarm-Ereignissen. Die Fehlalarme stammen aus Bewegungen, bei denen das Bein selbst in die Horizontale kommt (Hinsetzen, Aufheben); an der Hüfte sind es mit 65 in 9,3 min deutlich mehr – sie ist aber nicht die Zielposition. Eine Rate je Stunde ist aus wenigen Minuten solcher Aufnahmen nicht ableitbar.

Kennwerte je Aktivität. Abbildung 3.1 zeigt zwei orientierungsunabhängige Kennwerte je Ereignis. Die Spitze von $|a|$ trennt am Knöchel nicht: Gehen, Joggen und Springen erreichen 1,6–10,7 g, Stürze 1,8–9,6 g. Trennend sind die Lageänderung und die Ruhe danach. Die Regel $|a|_{\max} > 1{,}5$ g, Lage $> 40°$, Ruhe $< 0{,}2$ g erkennt am Knöchel 34 von 45 Stürzen ohne Fehlalarm, an der Hüfte ($> 50°$, $< 0{,}05$ g) 16 von 22. Übersehen werden v. a. Vorwärts- und Rückwärtsstürze, nach denen der Unterschenkel seine Lage kaum ändert. Die Schwellen sind an denselben Daten bestimmt und damit optimistisch; sie eignen sich als zweite Stufe, die einen CNN-Alarm bestätigt.

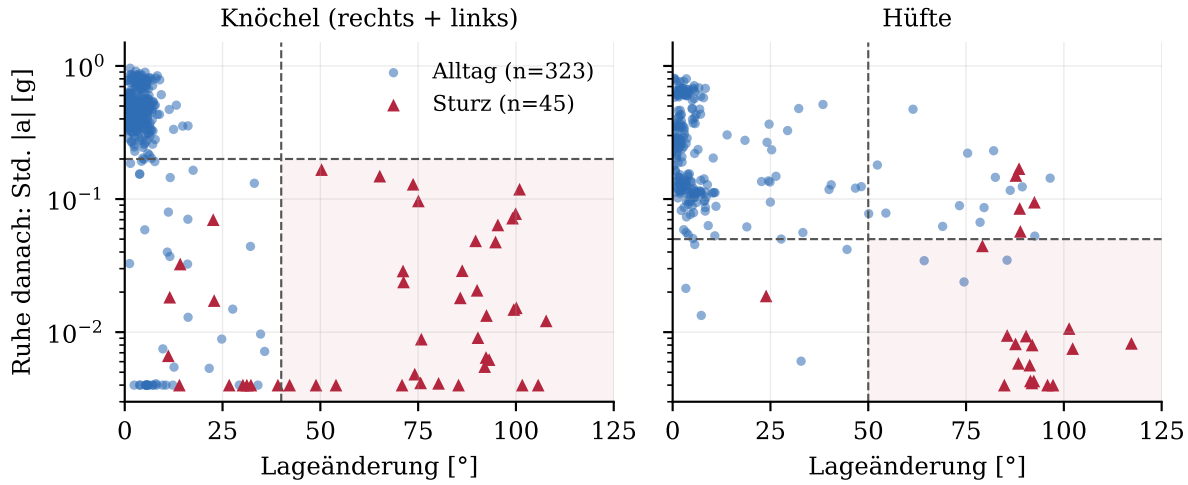


Abbildung 3.1: Lageänderung und Ruhe nach jedem Ereignis (Alltag: jede Spitze $|a| > 1{,}3$ g). Rot hinterlegt: Bereich der Regel (zusätzlich $|a|_{\max} > 1{,}5$ g). Werte unter 0,004 g auf 0,004 g gesetzt.

3.9 Eigene Sohlenaufnahmen

Zum Projektende wurden mit dem Prototyp Aufnahmen in beiden Sohlen erstellt (eine Person, 26 Dateien, 19,9 min, 100 Hz, ±16 g, ohne Sättigung): vier Sturzarten sowie Gehen, Joggen, Treppen, Springen und kräftiges Hinsetzen. Stürze auf die Knie fanden auf hartem Boden statt, die übrigen auf einer weichen Unterlage. Bereits ohne Modell zeigt sich: **Kein Sturz übertrifft die stärkste Alltagsbewegung.** Rechts erreicht Joggen 6,5 g, die Stürze 2,3–5,4 g; links Springen 7,7 g, die Stürze 3,5–5,7 g. Normales Gehen erreicht an der Sohle über 4 g und damit mehr, als die bisherige Partner-Sohle (±2 g je Achse, höchstens 3,5 g als Betrag) messen kann. Die Aufnahmen bestätigen damit an der Zielposition, dass nur die zeitliche Form trennt. Einen ersten Funktionstest des Modells darauf beschreibt Abschnitt 3.10.

3.10 Funktionstest in der Sohle

Zum Abschluss lief die Firmware mit B2r im Prototyp in der Sohle (eine Person, qualitativer Test). Die Selbsttests stimmen, jedes Fenster benötigt rund 115–117 ms und damit gut die Hälfte des 200-ms-Takts. Beim Gehen erreichen einzelne Fenster $p = 0{,}85$ bis 0,94, lösen aber wegen der 3-von-5-Regel keinen Alarm aus. Simulierte Stürze lösten einen Alarm aus; die anschließende Lageprüfung meldete z. B. „vorwärts 95 %“. Ohne Sperre löste ein Sturz mehrere Alarme nacheinander aus, weil die Abstimmung nach jedem Alarm neu beginnt; seitdem ist der Alarm während der Lageprüfung gesperrt. Die zweite Stufe (Lage und Ruhe) bestätigte nicht jeden Sturz, da nach den Versuchen nicht immer lange genug still gelegen wurde. Eine Auswertung mit Raten je Stunde steht aus.

3.11 Übersicht der geprüften Behauptungen

Tabelle 3.8: Geprüfte Behauptungen und Ergebnis.

Behauptung	Ergebnis	Beleg
Fine-Tuning schließt die Domänenlücke	**bestätigt**	UMAFall Taille 46 → 94 %, FallAllD 11 → 76 %; Spezifität bleibt
Sturzdaten vom Bein sind für das Fußmodell nötig	**bestätigt**	Schienbein +61,5 pp (B1 vs. K, 5/5 Falten)
Die Achsenlage erklärt den Links-rechts-Unterschied	**bestätigt**	Spiegelung links: 5 → 54 %, rechts: 47 → 4 %
Ein Gyroskop verbessert die Erkennung deutlich	**teilweise**	RF: 62 % Gyro-Wichtigkeit; CNN an der Hüfte nur +1,3 pp (Deckeneffekt)
Höhere Abtastrate sichert den Transfer	**widerlegt**	FallAllD (238 Hz) 11,3 %, KFall (100 Hz) 99,5 %
Der Messbereich ±8 g erklärt den FallAllD-Einbruch	**widerlegt**	Clipping auf ±8 g: unverändert 99,0 %
Die Position bestimmt die Leistung	**widerlegt**	Seite (Achsenlage) wiegt schwerer: Spiegeltest 5 → 54 %
Progressives Fine-Tuning hilft	**teilweise**	+23,8 pp bei wenig Zieldaten; bei vielen kein Unterschied (L0 vs. B2)
Hard Negatives senken Fehlalarme sinnvoll	**widerlegt**	+1,8 pp Sp gegen −6,3 pp Se
Voting senkt Fehlalarme	**teilweise**	3 von 5: −70 % FP, aber −40 % erkannte Stürze (UMAFall-Knöchel)
Ältere erzeugen mehr Fehlalarme	**teilweise**	Handgelenk: v. a. Klatschen, Türöffnen; Sohle: ja (127 vs. 69/h)
Fußdaten ohne Stürze kosten Sensitivität	**widerlegt**	augmentiert: Se −0,2 pp (n. s.), FP −91 bis −96 %; ohne Augm. Sp −8,6 pp
Augmentierung kostet Sensitivität	**widerlegt**	Se +0,8 pp (n. s.), gedreht +17,9 pp, FP an Smart-Insole geringer
Das Basismodell scheitert an der eigenen Hüfte wegen der Hardware	**widerlegt**	Achsen wie SisFall: 2 → 15 von 22
Spitzenwerte trennen Stürze am Fuß	**widerlegt**	Knöchel: Alltag bis 10,7 g; Sohle: Stürze $\leq$ 5,7 g, Joggen/Springen bis 7,7 g
Smart-Insole im Training senkt Fehlalarme weiter	**teilweise**	28 → 11/h, aber Se −2,0 pp (gesichert)
TFLite Micro rechnet das Modell auf dem ESP32-C6 korrekt	**widerlegt**	konstant $p \approx 0{,}47$; eigene int8-Kerne entscheiden wie TFLite
Breiteres Vortraining verbessert das Fußmodell	–	nicht geprüft (Notebook 05, Teil E vorbereitet)

3.12 Einschränkungen

Eigene Sohlenaufnahmen mit Stürzen liegen erst seit Projektende vor und sind mit dem Modell nur im qualitativen Funktionstest erprobt (Abschnitt 3.10); Erkennungs- und Fehlalarmraten an der Sohle sind daher nicht belegt, das Modell ist vom Knöchel übertragen. Das kommerzielle Modell wurde nicht trainiert. Die Pilotdaten stammen von einer Person und enthalten nur Minuten Alltag. Alle Stürze sind simuliert, von überwiegend jungen Personen. Die Aufprallbeschriftung von CAPPIMU ist eine Näherung.

4 Zusammenfassung und Ausblick

Eine Sturzerkennung in der Einlegesohle ist mit einer 6-Achsen-IMU und einem kleinen 1D-CNN auf dem ESP32-C6 umsetzbar; das Modell benötigt rund 77 KB und rechnet alle 200 ms in rund 117 ms mit eigenen int8-Kernen, da TensorFlow Lite Micro auf dem ESP32-C6 keine korrekten Ausgaben lieferte. Die wesentlichen Erkenntnisse:

1. **Am Fuß sind Fehlalarme das Kernproblem**, nicht die Sensitivität. Ein auf Beinstürze trainiertes Modell ohne Sohlendaten erzeugt an der Sohle 268–400 Fehlalarme je Stunde, das Rumpfmodell 65–101, bei Älteren 127.
2. **Die richtigen Daten wirken stärker als jede andere Maßnahme.** Sturzdaten vom Bein heben die Sensitivität um 61 pp, Sohlendaten ohne Stürze senken die Fehlalarme um 91–96 %, ohne Sensitivität zu kosten (augmentiert). Umgewichtung (Hard Negatives) und Voting allein reichen nicht. Ein Grenzwert auf die Spitze kann an der Sohle grundsätzlich nicht trennen.
3. **Die Achsenlage des Sensors ist eine eigene, bislang übersehene Fehlerquelle.** Sie erklärt den Seitenunterschied vollständig und den Einbruch an der eigenen Hüfte weitgehend. Die Einbaulage gehört zur Modellspezifikation und wird in der Firmware ausgeglichen; eine Rotationsaugmentierung macht das Modell zusätzlich robust.
4. **Auf der eigenen Hardware** erkennt B2r nach Ausrichtung über die Schwerkraft alle 67 Stürze einer Person an Hüfte und Knöcheln.

Ausblick. (1) Die vorhandenen Aufnahmen in beiden Sohlen mit dem Modell auswerten und um mehrere Personen und Stürze auf hartem Boden ergänzen, um das Modell an der Zielposition zu validieren. (2) Zweite Stufe mit Lageänderung und Liegephase zur Bestätigung eines Alarms und Langliegeerkennung. (3) Parameter der Alarmlogik (N, M, Schwelle) auf Sohlendaten festlegen. (4) Energiebedarf im Dauerbetrieb messen. (5) Für NEARBY (vormals Clever-Sole) das vorbereitete kommerzielle Modell trainieren, gegen B2r prüfen und nach Prüfung der Lizenzen übergeben.

Literaturverzeichnis

[1] A. Dinh, Y. Shi, D. Teng, A. Ralhan, L. Chen, V. D. Bui, H. Nguyen, D.-H. Le, W.-Y. Ko, K.-H. Ihn, and H. H. Nguyen, "A fall and near-fall assessment and evaluation system," *Open Biomedical Engineering Journal*, vol. 3, pp. 1–7, 2009.

[2] Q. T. Huynh, U. D. Nguyen, L. B. Irazabal, N. Ghassemian, and B. Q. Tran, "Optimization of an accelerometer and gyroscope-based fall detection algorithm," *Journal of Sensors*, vol. 2015, p. Article ID 452078, 2015.

[3] D. Roetenberg, H. J. Luinge, C. T. M. Baten, and P. H. Veltink, "Compensation of magnetic disturbances improves inertial and magnetic sensing of human body segment orientation," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 13, no. 3, pp. 395–405, 2005.

[4] I. Weygers, M. Kok, M. Konings, H. Hallez, H. De Vroey, and K. Claeys, "Inertial sensor-based lower limb joint kinematics: A methodological systematic review," *Sensors*, vol. 20, no. 3, p. 673, 2020.

[5] F. M. G. Cornelissen, R. Peeters, R. van der Straaten, C. E. E. M. van der Zee, A. De Brabandere, and B. Vanwanseele, "Evaluation of a restoration algorithm applied to clipped tibial acceleration signals," *Sensors*, vol. 23, no. 10, p. 4747, 2023.

[6] J. R. Villar, E. de la Cal, M. Fañez, V. M. González, and J. Sedano, "A study of the influence of the sensor sampling frequency on the performance of wearable fall detectors," *Measurement*, vol. 193, p. 110945, 2022.

[7] A. Díaz-Ramirez *et al.*, "The impact of the accelerometer sampling rate on the performance of machine and deep learning models in wearable fall-detection systems," *Sensors*, vol. 26, no. 1, p. 162, 2026.

[8] NXP Semiconductors, "AN4075 – The Trade-Off Between High Resolution and Low Power Consumption in MEMS Accelerometers," tech. rep., NXP Semiconductors (formerly Freescale), 2013.

[9] S. Arar, "Accelerometer specifications: Measurement range, sensitivity, and noise performance." All About Circuits, technischer Artikel, 2022.

[10] F. Bagalà, C. Becker, A. Cappello, L. Chiari, K. Aminian, J. M. Hausdorff, W. Zijlstra, and J. Klenk, "Evaluation of accelerometer-based fall detection algorithms on real-world falls," *PLOS ONE*, vol. 7, no. 5, p. e37062, 2012.

[11] A. Sucerquia, J. D. López, and J. F. Vargas-Bonilla, "SisFall: A fall and movement dataset," *Sensors*, vol. 17, no. 1, p. 198, 2017.

[12] X. Yu, J. Jang, and S. Xiong, "A large-scale open motion dataset (KFall) and benchmark algorithms for detecting pre-impact fall of the elderly using wearable inertial sensors," *Frontiers in Aging Neuroscience*, vol. 13, p. 692865, 2021.

[13] E. Casilari, J. A. Santoyo-Ramón, and J. M. Cano-García, "UMAFall: A multisensor dataset for the research on automatic fall detection," *Procedia Computer Science*, vol. 110, pp. 32–39, 2017.

[14] M. Saleh, M. Abbas, and R. Le Bouquin Jeannès, "FallAllD: An open dataset of human falls and activities of daily living for classical and deep learning applications," *IEEE Sensors Journal*, vol. 21, no. 2, pp. 1849–1858, 2021.

[15] J. Marques, N. Bento, M. Barandas, and H. Gamboa, "Online fall detection using wrist devices," *Sensors*, vol. 23, no. 3, p. 1146, 2023.

[16] "CAPPIMU: A composite activities dataset for human activity recognition utilizing plantar pressure and IMU sensors." `https://github.com/quiqi/CAPPIMU`, 2024.

[17] "ImbalanSense: Smart insole data for gait imbalance detection." Zenodo, Aalto University, 2026. Lizenz CC BY 4.0.

[18] C. Chatzaki, V. Skaramagkas, N. Tachos, G. Christodoulakis, E. Maniadi, Z. Kefalopoulou, D. I. Fotiadis, and M. Tsiknakis, "The smart-insole dataset: Gait analysis using wearable sensors with a focus on elderly and Parkinson's patients," *Sensors*, vol. 21, no. 8, p. 2821, 2021.