TECHNISCHE HOCHSCHULE MITTELHESSEN

Campus Friedberg

Studienprojekt 2 · Masterstudiengang Mechatronik

Sturzerkennung mit TinyML in einer sensorischen Einlegesohle

Vom Rumpf zum Fuß: Datensätze, Modelltransfer, Sensororientierung und Prototyp auf dem ESP32-C6

Verfasser:	Aly Elbermawy (Matr.-Nr. 5335848)
Betreuer:	Prof. Dr. Sergej Kovalev
Industriepartner:	TrackTech GmbH / Clever-Sole, Friedberg
Abgabe:	Oktober 2026

Kurzfassung

Ziel des Projekts ist eine Sturzerkennung, die vollständig in einer Einlegesohle auf einem ESP32-C6 mit sechsachsiger *Inertial Measurement Unit* (IMU) läuft. Öffentliche Sturzdatensätze messen fast ausschließlich am Rumpf; einen Datensatz mit Stürzen an der Sohle gibt es nicht. Ein 1D-CNN (61 601 Parameter, int8 rund 80 KB) erreicht auf SisFall 98,0 % Sensitivität bei 99,7 % Spezifität, verliert aber an Bein und Fuß den Großteil seiner Leistung und erzeugt an der Sohle bis zu 290 Fehlalarme je Stunde. Schrittweise wird gezeigt, woran das liegt und was hilft: Sturzdaten vom Schienbein heben die Sensitivität am Bein von 23 auf 84 %, Sohlendaten ohne Stürze senken die Fehlalarme an der Sohle um mehr als 95 %, ohne Sensitivität zu kosten. Als bislang unbeachtete Fehlerquelle erweist sich die **Achsenlage des Sensors**: Spiegelbildlich getragene Sensoren unterscheiden sich bei identischen Stürzen um bis zu Faktor neun, und allein die Ausrichtung der eigenen Hüftaufnahmen an den Achsen von SisFall hebt die Erkennung von 3 auf 15 von 22 Stürzen. Eine Rotationsaugmentierung macht das Modell signifikant robuster. Auf dem eigenen Prototyp erkennt das Modell am Knöchel 20–22 von 22 bzw. 23 Stürzen einer Person. Alle Aussagen sind subjektunabhängig kreuzvalidiert und, wo möglich, gepaart statistisch abgesichert.

Inhaltsverzeichnis

1 Theoretischer Hintergrund **1**
- 1.1 Motivation und Aufgabenstellung . . . 1
- 1.2 Sensorik: Achsen und Sensoreigenschaften . . . 1
- 1.3 Verfahren der Sturzerkennung . . . 1
- 1.4 Datensätze . . . 2

2 Durchführung **3**
- 2.1 Prototyp und Datenaufnahme . . . 3
- 2.2 Datenaufbereitung . . . 3
- 2.3 Modelle und Trainingskette . . . 4
- 2.4 Bewertungsmethodik . . . 4
- 2.5 Firmware . . . 4
- 2.6 Kommerzielles Modell . . . 4

3 Ergebnisse und Diskussion **5**
- 3.1 Basismodell am Rumpf . . . 5
- 3.2 Übertragbarkeit auf andere Datensätze . . . 5
- 3.3 Fehlalarme und zeitliche Plausibilisierung . . . 5
- 3.4 Progressives Training und Hard Negatives . . . 6
- 3.5 Zielgruppe: ältere Menschen . . . 6
- 3.6 Vom Rumpf zum Fuß . . . 6
- 3.7 Einfluss der Sensororientierung . . . 7
- 3.8 Pilotversuch auf der Zielhardware . . . 8
- 3.9 Kommerzielles Modell . . . 9
- 3.10 Übersicht der geprüften Behauptungen . . . 10
- 3.11 Einschränkungen . . . 10

4 Zusammenfassung und Ausblick **11**

Literaturverzeichnis **12**

1 Theoretischer Hintergrund

1.1 Motivation und Aufgabenstellung

Stürze sind bei älteren und pflegebedürftigen Menschen eine der häufigsten Ursachen schwerer Verletzungen; entscheidend ist oft nicht der Sturz selbst, sondern wie lange die Person unbemerkt liegen bleibt. Der Projektpartner Clever-Sole entwickelt eine sensorische Einlegesohle. Das Studienprojekt untersucht, ob sich darin eine Sturzerkennung *auf dem Gerät* (TinyML) realisieren lässt. Die Aufgaben umfassen (1) die Wahl der Sensorkonfiguration, (2) die relevanten Sensoreigenschaften, (3) die Bewertung öffentlicher Datensätze und (4) Entwicklung, Training und prototypische Integration des Modells. Der Schwerpunkt liegt auf Aufgabe 4.

1.2 Sensorik: Achsen und Sensoreigenschaften

Ein **3-Achsen**-Beschleunigungssensor erfasst Aufprall und Freifall über den Betrag $|a|$, kann aber sturzähnliche Alltagsaktivitäten (*Activities of Daily Living*, ADL) wie kräftiges Hinsetzen schlecht abgrenzen [1, 2]. Ein **Gyroskop** (6 Achsen) ergänzt die Drehrate, also die für einen Sturz typische schnelle Rotation in die Horizontale; in der Literatur steigt dadurch vor allem die Spezifität, z. B. von 82,7 auf 96,2 % [2]. Ein **Magnetometer** (9 Achsen) liefert eine absolute Richtung und korrigiert die Gyroskopdrift [3]. Diese Drift ist über die ein bis zwei Sekunden eines Sturzes vernachlässigbar, während Magnetfelder in Innenräumen durch Stahl und Geräte gestört werden [4]. Empfohlen wird daher eine **6-Achsen-IMU**; Tabelle 1.1 fasst den Arbeitspunkt zusammen.

Tabelle 1.1: Sensoreigenschaften und empfohlener Arbeitspunkt.

Eigenschaft	Wirkung auf die Sturzerkennung	Empfehlung
Messbereich	Zu klein: Aufprallspitze wird abgeschnitten (Clipping) [5]	$\pm 16\,\mathrm{g}$
Abtastrate	15–20 Hz genügen dem CNN [6, 7]; Erfassung höher, dann filtern	$\geq 100\,\mathrm{Hz} \rightarrow 50\,\mathrm{Hz}$
Auflösung	Effektiv durch Rauschen begrenzt [8]	$\geq 12\,\mathrm{Bit}$
Rauschdichte	Relevant für feine Merkmale, nicht für den Aufprall [9]	$\lesssim 100\,\mu\mathrm{g}/\sqrt{\mathrm{Hz}}$
Gyroskopdrift	Über die Sturzdauer vernachlässigbar [3]	unkritisch

1.3 Verfahren der Sturzerkennung

Schwellwertverfahren lösen aus, wenn $|a|$ einen Freifall- und einen Aufprallschwellwert über- bzw. unterschreitet [10]. **Klassische ML-Verfahren** wie der Random Forest arbeiten auf Merkmalen je Zeitfenster; beruhen diese auf Vektorbeträgen, sind sie unabhängig von der Einbaulage. Ein **1D-CNN** lernt die Merkmale direkt aus dem Rohsignal (Fenster $T \times 6$). Es ist dadurch leistungsfähiger, verarbeitet die sechs Kanäle aber einzeln und ist *nicht* drehinvariant: Dieselbe Bewegung erscheint bei gedrehtem Sensor in anderen Kanälen.

Domänenlücke und Transfer Learning. Ein Modell, das an einer Position und mit einer Sensorhardware trainiert wurde, überträgt sich nicht zwangsläufig auf eine andere (*Domänenlücke*). Beim Fine-Tuning werden die Gewichte eines vortrainierten Modells mit kleiner Lernrate auf Daten der Zieldomäne nachtrainiert, bei progressivem Fine-Tuning über eine Zwischendomäne.

Orientierung. Wird der Sensor um eine Rotationsmatrix R gedreht, gilt für Beschleunigung und Drehrate $a' = R\,a$, $\omega' = R\,\omega$. Bei einer Spiegelung (linke statt rechte Körperseite) verhält sich ω als Pseudovektor: Die gespiegelte Achse der Beschleunigung wechselt das Vorzeichen, beim Gyroskop die beiden anderen. Eine **Rotationsaugmentierung** ergänzt das Training um zufällig gedrehte und gespiegelte Kopien jedes Fensters, damit das CNN die Orientierung nicht als Merkmal lernt.

Bewertungsgrößen. Sensitivität $Se = TP/(TP + FN)$ (erkannte Stürze), Spezifität $Sp = TN/(TN + FP)$, Genauigkeit Acc und – für den Einsatz entscheidend – **Fehlalarme je Stunde** Alltag (FP/h). Bei seltenen Stürzen ist die Genauigkeit wenig aussagekräftig: Ein Modell, das nie alarmiert, erreicht bereits über 97 %.

1.4 Datensätze

Tabelle 1.2 und Abbildung 1.1 zeigen die verwendeten Datensätze und ihre Messorte. Kein Datensatz enthält Stürze an der Sohle; die beiden Sohlendatensätze enthalten nur Alltag. MobiAct wurde wegen Smartphone-Sensorik (±2 g) und nicht-kommerzieller Lizenz nicht verwendet, UniMiB-SHAR (nur Beschleunigung) nur für den Achsenvergleich.

Tabelle 1.2: Verwendete Datensätze (P: Probanden, S: Stürze vorhanden).

Datensatz	Position	Hz	P	S	Rolle im Projekt
SisFall [11]	Hüfte	200	38	ja	Basismodell
KFall [12]	unterer Rücken	100	32	ja	Transfer, Zwischenstufe
UMAFall [13]	5 Positionen	20	19	ja	Transfer, Knöchel
FallAllD [14]	Nacken, Hand, Taille	238	15	ja	Transfer
WEDA-FALL [15]	Handgelenk	50	25	ja	Ältere (77–95 J.)
CAPPIMU [16]	9 Positionen	50	30	ja	Positionskurve, Beinmodell
ImbalanSense [17]	Sohle	100	40	nein	Alltag am Fuß (Training)
Smart-Insole [18]	Sohle	100	29	nein	externer Test, Vorher/Nachher
Eigene Pilotdaten	Hüfte, Knöchel	100	1	ja	Test auf Zielhardware

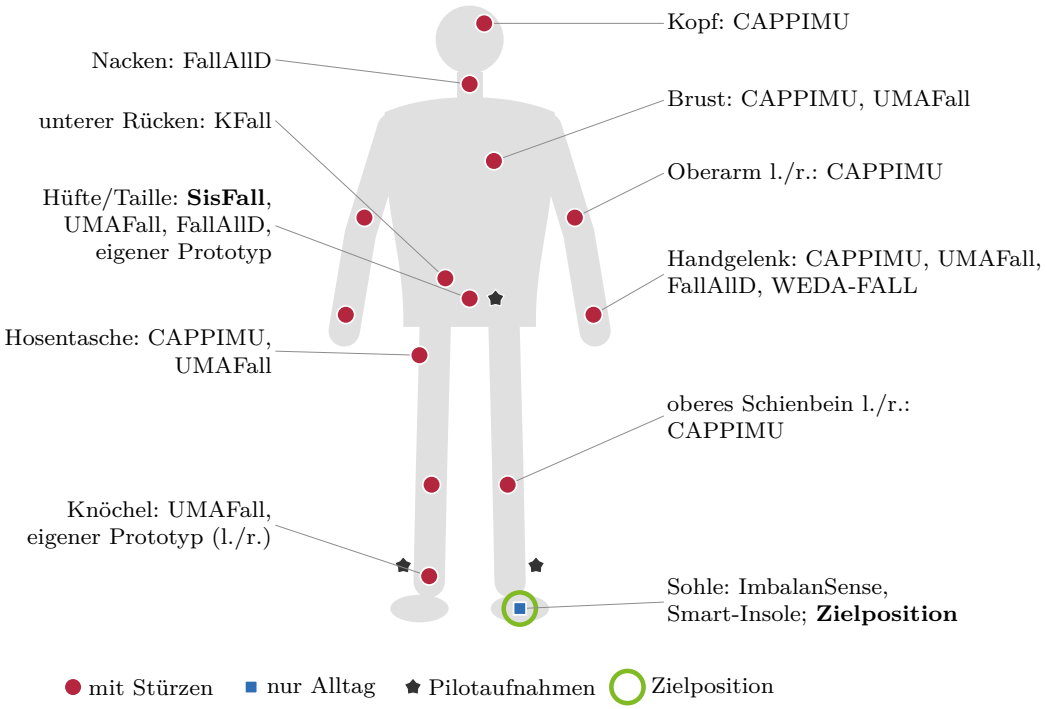
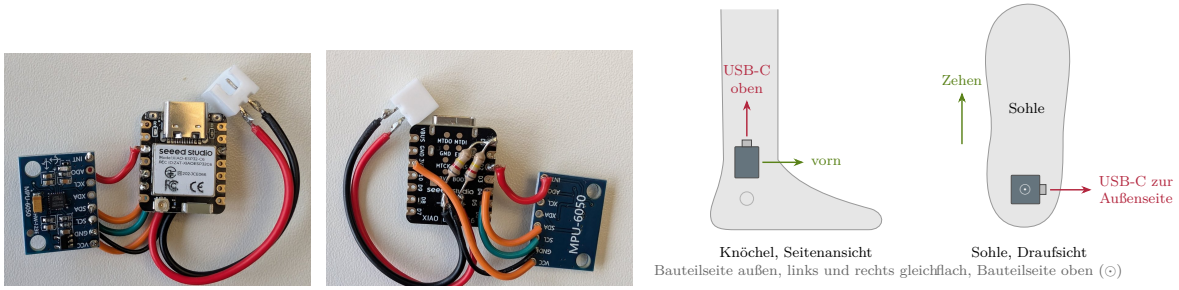


Abbildung 1.1: Messorte der Datensätze am Körper. Stürze liegen nur an Rumpf, Armen, Schienbein und Knöchel vor; an der Sohle nur Alltagsdaten.

2 Durchführung

2.1 Prototyp und Datenaufnahme

Der Prototyp besteht aus einem Seeed Studio XIAO ESP32-C6 (RISC-V, 160 MHz, BLE, USB-C) und einem IMU-Modul (HW-123, Aufdruck MPU-6050; die Firmware erkennt den Chip über das Register `WHO_AM_I`), verbunden über I^2C und versorgt über einen Akkuanschluss (Abbildung 2.1). Die IMU läuft mit ±16 g, ±2000 °/s und 100 Hz bei aktivem digitalem Tiefpassfilter. Für die Pilotdaten wurde eine eigene Firmware (*DatenLogger*) geschrieben: Aufnahme mit 100 Hz in den internen Flash, Bedienung per Smartphone über Bluetooth (Aktivität wählen, Start/Stopp), automatischer Stopp nach 120 s und Auslesen per Python-Skript. Da Flash-Schreibzugriffe einzelne Abtastwerte verzögern, werden die Daten anhand der Zeitstempel auf ein exaktes 100-Hz-Raster interpoliert.



(a) Oberseite (b) Unterseite (c) Einbaulage am Knöchel und in der Sohle

Abbildung 2.1: Prototyp: XIAO ESP32-C6 mit IMU-Modul und Akkuanschluss (a, b) sowie Einbaulage des Sensors (c).

Aufnahmeprotokoll. Eine Person (der Verfasser) trug den Sensor an der Hüfte sowie am rechten und linken Knöchel (USB-Buchse jeweils oben). Je Position wurden vier Sturzarten auf eine Matte aufgezeichnet (auf die Knie, vorwärts, seitlich, rückwärts; je vier bis acht Wiederholungen mit anschließender Liegephase von 5 s) sowie Gehen, Joggen, Treppen, Hinsetzen, kräftiges Hinsetzen, Springen, Aufheben und Hinlegen. Insgesamt liegen 22/23/22 Stürze und 9,7/6,6/7,2 min Alltag (Hüfte/Knöchel rechts/links) vor. Aufnahmen in der Sohle wurden nur unvollständig und einseitig erstellt und werden nicht ausgewertet.

2.2 Datenaufbereitung

Alle Datensätze werden in eine gemeinsame Form gebracht: sechs Kanäle in g und °/s, gefiltertes Heruntertasten auf 50 Hz, Fenster von 2 s (100×6) und Z-Normalisierung je Fenster und Kanal. Ein Sturzfenster wird auf den Aufprall (Maximum von $|a|$) zentriert; innerhalb einer Sturzaufnahme gilt *nur* dieses Fenster als Sturz. Zwei Sonderfälle erforderten eigene Lösungen:

- **CAPPIMU** beschriftet eine ganze Sturzsitzung (≈ 160 s) als *fall*. Einzelne Aufpralle werden an der Brust detektiert (> 2,5 g, Abstand ≥ 4 s) und über die gemeinsamen Zeitstempel auf alle Positionen übertragen.
- **Pilotdaten:** Am Knöchel ist der Sturz (2,6–2,9 g im Median) oft schwächer als Klopfmarken oder Springen (bis 12 g). Der Aufprall wird daher über die folgende Liegephase bestimmt: Ruhe ≥ 2 s, deren Schwerkraftrichtung um mehr als 40° von der Stehhaltung abweicht; Aufprall ist das Maximum von $|a|$ in den 2 s davor.

2.3 Modelle und Trainingskette

Das CNN besteht aus drei Faltungsblöcken (32/64/128 Filter, Kernel 5, Batch-Normalisierung, Max-Pooling), Global-Average-Pooling, einer Dense-Schicht (64) mit Dropout 0,3 und Sigmoid-Ausgang (61 601 Parameter, Adam, binäre Kreuzentropie, Klassengewichte). Als Vergleich dienen ein Schwellwertverfahren und ein Random Forest mit 18 Betragsmerkmalen. Abbildung 2.2 zeigt die Trainingskette für das Fußmodell.

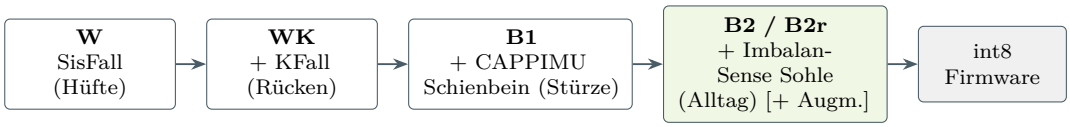


Abbildung 2.2: Trainingskette vom Rumpf- zum Fußmodell. B2r: B2 mit Rotations-/Spiegelaugmentierung (eine zufällig gedrehte, mit 50 % gespiegelte Kopie je Fenster).

2.4 Bewertungsmethodik

- **Subjektunabhängig:** Kein Proband erscheint zugleich in Training und Test.
- **Fünffache Kreuzvalidierung, gepaart:** Verfahren werden auf denselben Falten verglichen; berichtet wird die mittlere Differenz mit 95 %-Konfidenzintervall. Ein Unterschied gilt als gesichert, wenn das Intervall die Null nicht enthält. Konfidenzintervalle einzelner Anteile nach Wilson.
- **Fehlalarme** auf reinen Alltagsdaten, umgerechnet je Stunde.
- **Betriebsbewertung** wie in der Firmware: Inferenz alle 0,2 s, Alarm bei 3 von 5 Fenstern über 0,5. Ein Sturz gilt als erkannt, wenn spätestens 1 s nach dem Aufprall ein Alarm fällt; jeder Alarm im Alltag ist ein Fehlalarm-Ereignis.

Der Code liegt in einer gemeinsamen Bibliothek (`fall_lib.py`) und fünf Colab-Notebooks: (01) Basismodell, (02) Transfer, Fehlalarme, Zielgruppe, (03) progressives Training, (04) Fuß und Orientierung, (05) Pilotdaten und kommerzielles Modell.

2.5 Firmware

Die Firmware liest die IMU mit 100 Hz, tastet auf 50 Hz herunter, hält einen Ringpuffer von 2 s und führt alle 200 ms eine Inferenz mit TensorFlow Lite Micro aus (int8, 9 Operatoren). Eine 3-von-5-Regel entscheidet über den Alarm, der per BLE gemeldet wird. Vor der Inferenz wird die feste Einbaulage über eine Drehmatrix in den Achsrahmen des Trainings überführt. Für die Sohle (Platine flach, Bauteilseite oben, USB-C zur Außenseite der Ferse) lautet sie $x' = x$, $y' = -z$, $z' = y$. Eingesetzt wird B2r, da es gegenüber Drehungen am robustesten ist (Abschnitt 3.7); int8 und Gleitkommamodell treffen auf den Pilotfenstern in 96 % der Fälle dieselbe Entscheidung.

2.6 Kommerzielles Modell

Für den Projektpartner wird ein zweites Modell nur aus Daten trainiert, deren Lizenz eine kommerzielle Nutzung nicht ausschließt: **alle Datensätze außer Smart-Insole und MobiAct**. Es wird von Grund auf auf einem gemischten Pool aller Positionen vortrainiert (SisFall, KFall, UMAFall, FallAllD, WEDA-FALL, CAPPIMU ohne Schienbein; orientierungsaugmentiert), dann wie B2r auf Schienbein und ImbalanSense nachtrainiert und abschließend um die eigenen Pilotaufnahmen ergänzt. Der Unterschied zum Berichtsmodell B2r prüft die Behauptung, dass breiteres Vortraining dem Fußmodell nützt (Abschnitt 3.9). Die Lizenzen sind vor der Übergabe im Einzelnen zu prüfen.

3 Ergebnisse und Diskussion

Die Ergebnisse sind entlang der Behauptungen geordnet, die im Projekt geprüft wurden. Tabelle 3.9 am Ende des Kapitels fasst zusammen, welche sich bestätigt haben und welche nicht.

3.1 Basismodell am Rumpf

Tabelle 3.1: Basismodelle auf SisFall, subjektunabhängiger Testsatz (10 Probanden, 13 031 Fenster).

Modell	Se	Sp	Acc	FP	FN
Schwellwert (Bourke)	96,7 %	76,8 %	77,5 %	11 503	59
Random Forest (18 Betragsmerkmale)	94,2 %	99,6 %	99,4 %	215	105
1D-CNN	**98,0 %**	**99,7 %**	**99,6 %**	**39**	**18**

Jede Stufe behebt die Schwäche der vorigen: Der Random Forest senkt die Fehlalarme des Schwellwerts um den Faktor 50, das CNN zusätzlich die übersehenen Stürze von 105 auf 18. Im Random Forest entfallen 62,3 % der Merkmalswichtigkeit auf das Gyroskop. Der direkte Achsenvergleich mit identischem CNN relativiert den Nutzen jedoch: mit 6 Achsen 98,7 %, nur mit Beschleunigung 98,0 %, nur mit Gyroskop 93,0 % Sensitivität. An der Hüfte liegt die Leistung nahe der Obergrenze; der Vorteil des Gyroskops (+0,7 pp) ist dort klein. Ein mit 3 Achsen trainiertes Modell erreicht auf UniMiB-SHAR (±2 g, Hosentasche) nach Fine-Tuning 95,9 % (Zero-Shot 20,4 %).

3.2 Übertragbarkeit auf andere Datensätze

Tabelle 3.2: Transfer des SisFall-Modells. Zero-Shot (ZS) und nach Fine-Tuning (FT), je eine subjektunabhängige Aufteilung.

Datensatz	Position, Hz	Se ZS	Se FT	Anmerkung
KFall	Rücken, 100	100,0 %	100,0 %	Sp 99,5 % ohne Anpassung
UMAFall	Taille, 20	43,8 %	91,7 %	
UMAFall	Knöchel, 20	19,4 %	27,8 %	36 Sturzfenster im Test; CV in Tab. 3.3
FallAllD	Taille, 238	12,7 %	69,8 %	Messbereich ±8 g

KFall überträgt ohne Anpassung, FallAllD trotz der höchsten Abtastrate kaum. Ein Kontrollversuch schließt den Messbereich als Ursache aus: Auf ±8 g und ±4 g begrenzte SisFall-Testdaten erreichen unverändert 98,7 %, selbst ±2 g noch 96,3 %. Ursprünglich wurde die Lücke den Signaleigenschaften der Hardware zugeschrieben. Die Ergebnisse zur Orientierung (Abschnitt 3.7) legen eine einfachere Erklärung nahe: An der eigenen Hüfte bricht das Basismodell ebenso ein und erholt sich allein durch Ausrichtung der Achsen. Für FallAllD wurde dies nicht geprüft, ist aber naheliegend.

3.3 Fehlalarme und zeitliche Plausibilisierung

Auf den Alltagsdaten am Knöchel (UMAFall, 1,76 h) löst das Basismodell 2,6 % der Fenster aus, rund 94 Fehlalarme je Stunde, vor allem beim Joggen (15,4 %) und Gehen (3,7 %) – also bei jedem Fersenaufsatz. Die Wahrscheinlichkeit liegt dabei bis $p = 1{,}000$; eine höhere Schwelle allein hilft nicht.

Eine N-von-M-Regel verlangt N positive unter den letzten M Entscheidungen. Sie wirkt erst bei kleiner Schrittweite (0,2 s): Bei 1 s liegt der Aufprall in nur einem Fenster, sodass jede Regel mit $N \geq 2$ scheitert. Auf UMAFall senkt *5-von-7* die Fehlalarme des angepassten Modells um 84 % (265 → 42/h), kostet aber die Hälfte der Sensitivität (61,7 → 27,7 %). Beim nicht angepassten Modell bleiben von 47 Stürzen nur drei erkannt, beim angepassten dreizehn: Nur ein angepasstes Modell erzeugt um den Aufprall einen zusammenhängenden Block positiver Fenster. **Voting ersetzt die Domänenanpassung nicht, es setzt sie voraus.**

3.4 Progressives Training und Hard Negatives

Tabelle 3.3: UMAFall-Knöchel, fünffach kreuzvalidiert (157 Stürze).

	Strategie	**Se [95 %-KI]**	**Sp**
A	Zero-Shot (SisFall)	25,5 % [19,3; 32,8]	97,4 %
B	direkt: SisFall → UMAFall	42,7 % [35,2; 50,5]	96,7 %
C1	nur Zwischenstufe KFall	17,2 % [12,1; 23,9]	98,7 %
C2	progressiv: SisFall → KFall → UMAFall	**52,2** % [44,5; 59,9]	96,5 %

Progressiv übertrifft direkt um +9,9 pp (KI [+5,1; +14,7], 5 von 5 Falten), obwohl die Zwischenstufe allein die Leistung zunächst senkt (C1): Sie verallgemeinert die Repräsentation, statt sie zu verbessern. Eine Höhergewichtung impactstarker Alltagsfenster (*Hard Negatives*, Faktor 3) hebt zwar die Spezifität um +2,1 pp, kostet aber −7,4 pp Sensitivität (KI [−10,4; −4,4], beides gesichert). Für ein Notrufsystem ist das der falsche Tausch, denn Fehlalarme lassen sich nachgelagert filtern, übersehene Stürze nicht.

Eine Einschränkung zeigt Abschnitt 3.7: Mit vielen Sturzdaten am Bein (CAPPIMU, 1462 Sturzfenster) ist ein Modell *ohne* Rumpf-Vortraining (L0) ebenso gut wie die progressive Kette (B2; −4,2 pp, nicht gesichert). Das Vortraining hilft also, wenn Zieldaten knapp sind.

3.5 Zielgruppe: ältere Menschen

Auf WEDA-FALL (Handgelenk) erzeugen Ältere bei gleichen Aktivitäten 3,8-mal mehr Fehlalarme (201 gegenüber 53/h, Schwelle 0,9). Die Aufschlüsselung zeigt, dass dies fast nur auf das Klatschen zurückgeht (25,5 gegenüber 2,5 % der Fenster); beim Gehen (0,7 gegenüber 0,4 %) und Treppensteigen unterscheiden sich die Gruppen kaum. An der Sohle (Smart-Insole) liegen Ältere (373/h) und Parkinson-Patienten (302/h) dagegen bei denselben Geh- und Aufstehtests deutlich über jüngeren Erwachsenen (215/h). Für die Sohle ist die Zielgruppe also ein realer Faktor.

3.6 Vom Rumpf zum Fuß

Die Sohle ist die schwierigste Position. Die Partnerdaten des bestehenden Sohlenprototyps sind mit 10 Hz, ±2 g (16,7 % der Werte abgeschnitten) und ohne Gyroskop nicht verwendbar. Unverfälschte Sohlendaten zeigen, warum: Schon beim Gehen erreicht $|a|$ im 99. Perzentil 4,4–5,1 g, Einzelachsen bis ±16 g – mehr als viele Stürze am Rumpf. Tabelle 3.4 zeigt das unveränderte Basismodell an allen Positionen.

Tabelle 3.4: Basismodell (Zero-Shot) je Position. CAPPIMU: dieselben Stürze gleichzeitig an neun Positionen (je 731 Sturzfenster, ≈ 31 h Alltag).

Position	Se	FP/h	Position	Se	FP/h
Kopf	28,4 %	59	Handgelenk rechts	51,8 %	118
Brust	48,4 %	92	Hosentasche	23,0 %	63
Oberarm links	6,2 %	46	Schienbein links	16,6 %	168
Oberarm rechts	54,6 %	116	Schienbein rechts	39,5 %	36
Handgelenk links	9,9 %	84	**Sohle** (ImbalanSense / Smart-Insole)	–	**161 / 290**

Statt einer mit dem Abstand vom Rumpf fallenden Kurve unterscheiden sich **linke und rechte Seite** bei identischen Stürzen um bis zu Faktor neun – ein Befund, dem Abschnitt 3.7 nachgeht.

Vorher/Nachher: Daten vom Bein und vom Fuß. Tabelle 3.5 zeigt, wie sich die Leistung mit jeder Datenquelle ändert. Bewertet wird auf Testprobanden, die nicht im Training waren; Smart-Insole ist in den oberen vier Zeilen ein vollständig externer Test.

Tabelle 3.5: Wirkung von Bein- und Fußdaten, fünffach kreuzvalidiert (1462 Sturzfenster am Schienbein).

		Schienbein		FP/h Sohle	
	Training	**Se [95 %-KI]**	**Sp**	**ImbalanSense**	**Smart-Insole**
A	SisFall (Basis)	28,0 % [25,8; 30,4]	97,2 %	161	290
K	+ KFall	22,6 % [20,5; 24,8]	98,7 %	51	65
B1	+ Schienbein-Stürze (*ohne* Fußdaten)	83,9 % [81,9; 85,7]	98,8 %	412	508
B2	+ ImbalanSense (Sohle, ohne Stürze)	**84,5** % [82,5; 86,2]	96,4 %	**18**	**53**
B2r	B2 mit Augmentierung (vollst. nachtrainiert)	85,0 %	[offen:]	3,9	17,7
	B2r + Smart-Insole im Training	[offen:]	[offen:]	[offen:]	[offen:]

Drei Befunde. (1) **Sturzdaten vom Bein sind entscheidend**: +61,2 pp Sensitivität (B1 gegenüber K, 5 von 5 Falten). (2) **Ohne Fußdaten explodieren die Fehlalarme an der Sohle** (412 bzw. 508/h): Das Modell lernt „kräftiger Beinimpuls = Sturz“, und jeder Fersenaufsatz ist einer. (3) **Fußdaten ohne Stürze beheben das ohne Sensitivitätsverlust**: −95 % Fehlalarme (Spezifität +10,9 bzw. +12,6 pp, gesichert), Sensitivität +0,6 pp (nicht verschieden). Im Gegensatz zu den Hard Negatives werden hier keine vorhandenen Fenster umgewichtet, sondern Daten der Zielposition ergänzt. Ob Smart-Insole als zweite Sohlenquelle die Fehlalarme weiter senkt, prüft Notebook 04, Teil E [offen: Ergebnis]. Die Spezifität am Schienbein liegt in allen Zeilen über 96 %, obwohl die Sensitivität zwischen 23 und 85 % schwankt; dasselbe gilt für die Genauigkeit, die bei seltenen Stürzen von den Alltagsfenstern dominiert wird.

3.7 Einfluss der Sensororientierung

Spiegeltest. Werden die Sensoren der linken Körperseite rechnerisch an der xz-Ebene gespiegelt (Gyroskop als Pseudovektor), erreicht das Basismodell dort die Werte der rechten Seite: Oberarm 6,2 → 60,2 %, Handgelenk 9,9 → 60,3 %, Schienbein 16,6 → 41,9 %. Umgekehrt fällt die gespiegelte rechte Seite auf 4,5, 7,5 und 17,0 %. **Der Seitenunterschied ist damit vollständig durch die Achsenlage erklärt.** Bei 20 zufälligen Drehungen schwankt die Sensitivität am Schienbein zwischen 9 und 58 %.

Gegenmaßnahme: Augmentierung. Tabelle 3.6 vergleicht fünf Trainingsketten auf denselben Falten.

Tabelle 3.6: Trainingsketten, fünffach kreuzvalidiert. Gedreht: Mittel über fünf zufällige Drehungen der Testdaten.

		Se Schienbein		FP/h Sohle	
	Kette	**original**	**gedreht**	**IMB**	**SI**
W	SisFall	28,0 %	27,6 %	161	290
WK	SisFall → KFall	22,0 %	18,8 %	112	148
L0	Bein + Fuß *ohne* Vortraining	84,5 %	58,0 %	6	26
B2	WK → Bein + Fuß	80,6 %	60,6 %	23	59
B2r	wie B2, augmentiert	**85,0** %	**78,0** %	**4**	**18**

Die Augmentierung kostet nichts und gewinnt in allen Größen: gedreht +17,3 pp (KI [+8,9; +25,8], 5 von 5 Falten), original +4,6 pp, Spezifität an beiden Sohlendatensätzen gesichert höher.

Eigene Hüfte in den SisFall-Rahmen. SisFall definiert die Achsen des Gürtelsensors als $+z$ vorwärts, $+y$ nach unten, $+x$ nach rechts [11]. Am Prototyp zeigte die Schwerkraft im Stand auf $-x$, und die Liegelage nach Vorwärts- und Rückwärtsstürzen weist $+z$ als Vorwärtsrichtung aus. Daraus folgt die feste Drehung $x_S = -y$, $y_S = x$, $z_S = z$ samt Ausgleich der Platinenneigung ($\approx 25°$) – bestimmt aus der Einbaulage, nicht aus den Ergebnissen. Das *unveränderte* Basismodell erkennt danach **15 statt 3 von 22 Stürzen** bei gleicher Zahl an Fehlalarmen (Tabelle 3.7). Ebenso zeigte die Liegelage, dass der linke Knöchelsensor gegenüber dem rechten um 180° um die Hochachse gedreht war.

3.8 Pilotversuch auf der Zielhardware

Tabelle 3.7: Betriebsbewertung auf den eigenen Aufnahmen (3 von 5, Schwelle 0,5): erkannte Stürze / Fehlalarm-Ereignisse. Alltag: Hüfte 9,3, rechts 6,2, links 6,8 min mit gezielt schwierigen Bewegungen (Springen, kräftiges Hinsetzen, Aufheben).

Modell	**Hüfte**	**Knöchel rechts**	**Knöchel links**
Basis (SisFall), Rohdaten	3/22 / 14	17/23 / 51	13/22 / 42
Basis, Achsen wie SisFall	**15/22 / 14**	–	–
B2 (Bein + Fuß)	15/22 / 82	22/23 / 27	20/22 / 39
B2r (augmentiert)	16/22 / 63	20/23 / 17	11/22 / 18
B2r, links 180° gedreht	–	–	**20/22 / 7**

Am Knöchel erkennen die Beinmodelle nahezu alle Stürze, obwohl sie weder diese Hardware noch diese Person gesehen haben; B2r senkt die Fehlalarme gegenüber B2. Mit korrekt ausgerichteter Einbaulage erreicht B2r links 20 von 22 Stürzen bei 7 Fehlalarm-Ereignissen. Die verbleibenden Fehlalarme stammen aus Bewegungen, bei denen das Bein selbst in die Horizontale kommt (Hinsetzen, Aufheben); eine Rate je Stunde ist aus wenigen Minuten solcher Aufnahmen nicht ableitbar.

Kennwerte je Aktivität. Abbildung 3.1 zeigt zwei orientierungsunabhängige Kennwerte je Ereignis. Die Spitze von $|a|$ trennt am Knöchel nicht: Gehen, Joggen und Springen erreichen 1,6–10,7 g, Stürze 1,8–9,6 g. Trennend sind die Lageänderung und die Ruhe danach. Die Regel $|a|_{\max} > 1{,}5$ g, Lage $> 40°$, Ruhe $< 0{,}2$ g erkennt am Knöchel 34 von 45 Stürzen ohne Fehlalarm, an der Hüfte ($> 50°$, $< 0{,}05$ g) 16 von 22. Übersehen werden v. a. Vorwärts- und Rückwärtsstürze, nach denen der Unterschenkel seine Lage kaum ändert. Die Schwellen sind an denselben Daten bestimmt und damit optimistisch; sie eignen sich als zweite Stufe, die einen CNN-Alarm bestätigt.

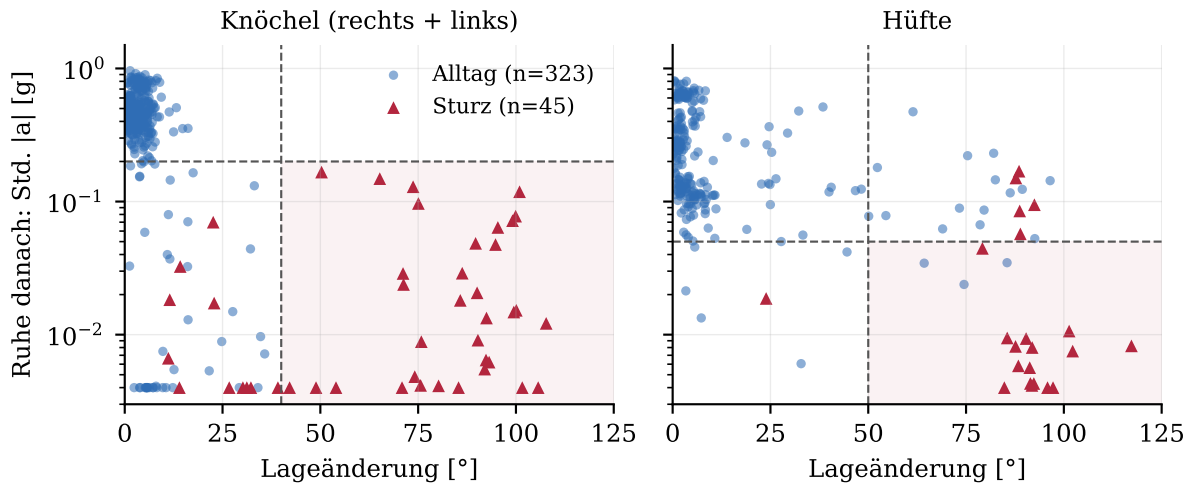


Abbildung 3.1: Lageänderung und Ruhe nach jedem Ereignis (Alltag: jede Spitze $|a| > 1{,}3\,\mathrm{g}$). Rot hinterlegt: Bereich der Regel (zusätzlich $|a|_{\max} > 1{,}5\,\mathrm{g}$). Werte unter $0{,}004\,\mathrm{g}$ auf $0{,}004\,\mathrm{g}$ gesetzt.

3.9 Kommerzielles Modell

Tabelle 3.8: Kommerzielles Modell (ohne Smart-Insole und MobiAct) gegenüber B2r auf identischen Falten. Smart-Insole und Pilotdaten sind für beide extern.

Modell	Se	Se gedreht	FP/h IMB	FP/h SI	Pilot Knöchel Se
B2r (Bericht)	[offen:]	[offen:]	[offen:]	[offen:]	[offen:]
Kommerziell	[offen:]	[offen:]	[offen:]	[offen:]	[offen:]

[offen: Einordnung nach dem Lauf von Notebook 05, Teil E: gesicherter Unterschied ja/nein, in welche Richtung.]

3.10 Übersicht der geprüften Behauptungen

Tabelle 3.9: Geprüfte Behauptungen und Ergebnis.

Behauptung	Ergebnis	Beleg
Fine-Tuning schließt die Domänenlücke	**bestätigt**	UMAFall Taille 44 → 92 %, FallAllD 13 → 70 %; Spezifität bleibt
Sturzdaten vom Bein sind für das Fußmodell nötig	**bestätigt**	Schienbein +61,2 pp (B1 vs. K, 5/5 Falten)
Die Achsenlage erklärt den Links-rechts-Unterschied	**bestätigt**	Spiegelung links: 6 → 60 %, rechts: 55 → 5 %
Ein Gyroskop verbessert die Erkennung deutlich	**teilweise**	RF: 62 % Gyro-Wichtigkeit; CNN an der Hüfte nur +0,7 pp (Deckeneffekt)
Höhere Abtastrate sichert den Transfer	**widerlegt**	FallAllD (238 Hz) 12,7 %, KFall (100 Hz) 100 %
Der Messbereich ±8 g erklärt den FallAllD-Einbruch	**widerlegt**	Clipping auf ±8 g: unverändert 98,7 %
Die Position bestimmt die Leistung	**widerlegt**	Seite (Achsenlage) wiegt schwerer: Spiegeltest 6 → 60 %
Progressives Fine-Tuning hilft	**teilweise**	+9,9 pp bei wenig Zieldaten; bei vielen kein Unterschied (L0 vs. B2)
Hard Negatives senken Fehlalarme sinnvoll	**widerlegt**	+2,1 pp Sp gegen −7,4 pp Se
Voting senkt Fehlalarme	**teilweise**	−84 % FP, aber nur mit angepasstem Modell tragfähig
Ältere erzeugen mehr Fehlalarme	**teilweise**	Handgelenk: nur Klatschen; Sohle: ja (373 vs. 215/h)
Fußdaten ohne Stürze kosten Sensitivität	**widerlegt**	B2 vs. B1: Se +0,6 pp, FP −95 %
Augmentierung kostet Sensitivität	**widerlegt**	Se +4,6 pp, gedreht +17,3 pp, FP geringer
Das Basismodell scheitert an der eigenen Hüfte wegen der Hardware	**widerlegt**	Achsen wie SisFall: 3 → 15 von 22
Spitzenwerte trennen Stürze am Fuß	**widerlegt**	Alltag bis 10,7 g; Lage + Ruhe trennen
Smart-Insole im Training senkt Fehlalarme weiter	**[offen:]**	Notebook 04, Teil E
Breiteres Vortraining verbessert das Fußmodell	**[offen:]**	Notebook 05, Teil E

3.11 Einschränkungen

Stürze an der Sohle wurden nicht gemessen; das Firmwaremodell ist an der Sohle daher nicht validiert, sondern vom Knöchel übertragen. Die Pilotdaten stammen von einer Person und enthalten nur Minuten Alltag. Alle Stürze sind simuliert, von überwiegend jungen Personen. Die Aufprallbeschriftung von CAPPIMU ist eine Näherung.

4 Zusammenfassung und Ausblick

Eine Sturzerkennung in der Einlegesohle ist mit einer 6-Achsen-IMU und einem kleinen 1D-CNN auf dem ESP32-C6 umsetzbar; das Modell benötigt rund 80 KB und rechnet alle 200 ms. Die wesentlichen Erkenntnisse:

1. **Am Fuß sind Fehlalarme das Kernproblem**, nicht die Sensitivität. Ein Rumpfmodell erzeugt an der Sohle 161–290 Fehlalarme je Stunde, bei Älteren bis 373.
2. **Die richtigen Daten wirken stärker als jede andere Maßnahme.** Sturzdaten vom Bein heben die Sensitivität um 61 pp, Sohlendaten ohne Stürze senken die Fehlalarme um 95 %, ohne Sensitivität zu kosten. Umgewichtung (Hard Negatives) und Voting allein reichen nicht.
3. **Die Achsenlage des Sensors ist eine eigene, bislang übersehene Fehlerquelle.** Sie erklärt den Seitenunterschied vollständig und den Einbruch an der eigenen Hüfte weitgehend. Die Einbaulage gehört zur Modellspezifikation und wird in der Firmware ausgeglichen; eine Rotationsaugmentierung macht das Modell zusätzlich robust.
4. **Auf der eigenen Hardware** erkennt das Beinmodell am Knöchel nahezu alle Stürze einer Person.

Ausblick. (1) Aufnahmen mit dem Prototyp in *beiden* Sohlen und mehreren Personen, einschließlich Stürzen auf Matte, um das Modell an der Zielposition zu validieren. (2) Zweite Stufe mit Lageänderung und Liegephase zur Bestätigung eines Alarms und Langliegeerkennung. (3) Parameter der Alarmlogik (N, M, Schwelle) auf Sohlendaten festlegen. (4) Energiebedarf im Dauerbetrieb messen. (5) Für Clever-Sole das kommerzielle Modell nach Prüfung der Lizenzen übergeben.

Literaturverzeichnis

[1] A. Dinh, Y. Shi, D. Teng, A. Ralhan, L. Chen, V. D. Bui, H. Nguyen, D.-H. Le, W.-Y. Ko, K.-H. Ihn, and H. H. Nguyen, "A fall and near-fall assessment and evaluation system," *Open Biomedical Engineering Journal*, vol. 3, pp. 1–7, 2009.

[2] Q. T. Huynh, U. D. Nguyen, L. B. Irazabal, N. Ghassemian, and B. Q. Tran, "Optimization of an accelerometer and gyroscope-based fall detection algorithm," *Journal of Sensors*, vol. 2015, p. Article ID 452078, 2015.

[3] D. Roetenberg, H. J. Luinge, C. T. M. Baten, and P. H. Veltink, "Compensation of magnetic disturbances improves inertial and magnetic sensing of human body segment orientation," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 13, no. 3, pp. 395–405, 2005.

[4] I. Weygers, M. Kok, M. Konings, H. Hallez, H. De Vroey, and K. Claeys, "Inertial sensor-based lower limb joint kinematics: A methodological systematic review," *Sensors*, vol. 20, no. 3, p. 673, 2020.

[5] F. M. G. Cornelissen, R. Peeters, R. van der Straaten, C. E. E. M. van der Zee, A. De Brabandere, and B. Vanwanseele, "Evaluation of a restoration algorithm applied to clipped tibial acceleration signals," *Sensors*, vol. 23, no. 10, p. 4747, 2023.

[6] J. R. Villar, E. de la Cal, M. Fañez, V. M. González, and J. Sedano, "A study of the influence of the sensor sampling frequency on the performance of wearable fall detectors," *Measurement*, vol. 193, p. 110945, 2022.

[7] A. Díaz-Ramirez *et al.*, "The impact of the accelerometer sampling rate on the performance of machine and deep learning models in wearable fall-detection systems," *Sensors*, vol. 26, no. 1, p. 162, 2026.

[8] NXP Semiconductors, "AN4075 – The Trade-Off Between High Resolution and Low Power Consumption in MEMS Accelerometers," tech. rep., NXP Semiconductors (formerly Freescale), 2013.

[9] S. Arar, "Accelerometer specifications: Measurement range, sensitivity, and noise performance." All About Circuits, technischer Artikel, 2022.

[10] F. Bagalà, C. Becker, A. Cappello, L. Chiari, K. Aminian, J. M. Hausdorff, W. Zijlstra, and J. Klenk, "Evaluation of accelerometer-based fall detection algorithms on real-world falls," *PLOS ONE*, vol. 7, no. 5, p. e37062, 2012.

[11] A. Sucerquia, J. D. López, and J. F. Vargas-Bonilla, "SisFall: A fall and movement dataset," *Sensors*, vol. 17, no. 1, p. 198, 2017.

[12] X. Yu, J. Jang, and S. Xiong, "A large-scale open motion dataset (KFall) and benchmark algorithms for detecting pre-impact fall of the elderly using wearable inertial sensors," *Frontiers in Aging Neuroscience*, vol. 13, p. 692865, 2021.

[13] E. Casilari, J. A. Santoyo-Ramón, and J. M. Cano-García, "UMAFall: A multisensor dataset for the research on automatic fall detection," *Procedia Computer Science*, vol. 110, pp. 32–39, 2017.

[14] M. Saleh, M. Abbas, and R. Le Bouquin Jeannès, "FallAllD: An open dataset of human falls and activities of daily living for classical and deep learning applications," *IEEE Sensors Journal*, vol. 21, no. 2, pp. 1849–1858, 2021.

[15] J. Marques, N. Bento, M. Barandas, and H. Gamboa, "Online fall detection using wrist devices," *Sensors*, vol. 23, no. 3, p. 1146, 2023.

[16] "CAPPIMU: A composite activities dataset for human activity recognition utilizing plantar pressure and IMU sensors." `https://github.com/quiqi/CAPPIMU`, 2024.

[17] "ImbalanSense: Smart insole data for gait imbalance detection." Zenodo, Aalto University, 2026. Lizenz CC BY 4.0.

[18] C. Chatzaki, V. Skaramagkas, N. Tachos, G. Christodoulakis, E. Maniadi, Z. Kefalopoulou, D. I. Fotiadis, and M. Tsiknakis, "The smart-insole dataset: Gait analysis using wearable sensors with a focus on elderly and Parkinson's patients," *Sensors*, vol. 21, no. 8, p. 2821, 2021.