

TH Mittelhessen

Technische Hochschule Mittelhessen - University of Applied Sciences

Studienprojekt 2

Wissenschaftliches Arbeiten

Subject:

Sensor-Based Fall Detection with Machine Learning

Author: Aly Elbermawy

Matriculation number: 5335848

Supervisor: Dr. Kovalev

Industry Partner: TrackTech GmbH

University: Technische Hochschule Mittelhessen, Friedberg

Submitted on: July 24, 2026

Confidentiality Clause

Transmittal, reproduction, dissemination and/or editing of this document as well as utilization of its contents and communication thereof to others without express authorization are prohibited. Offenders will be held liable for payment of damages. All rights created by patent grant or registration of a utility model or design patent are reserved.

Sperrvermerk

Die vorliegende Arbeit beinhaltet interne vertrauliche Informationen der TrackTech GmbH bzw. Clever-Sole. Die Weitergabe des Inhaltes der Arbeit und eventuell beiliegender Zeichnungen und Daten im Gesamten oder in Teilen ist grundsätzlich untersagt. Es dürfen keinerlei Kopien oder Abschriften – auch in digitaler Form – gefertigt werden. Ausnahmen bedürfen der schriftlichen Genehmigung der TrackTech GmbH.

Abstract

Falls are a leading cause of severe injury and reduced quality of life for elderly and care-dependent individuals. A reliable, energy-efficient and everyday-wearable fall-detection system can raise alarms in real time and thereby improve care safety. The novelty of the present project lies in the target form factor: a shoe-insole-integrated inertial sensor, rather than the wrist, hip or waist positions that dominate most public datasets.

The present study, submitted in partial fulfilment of the module *Studienprojekt 2* at TH Mittelhessen, addresses the first of four assigned tasks. Its objective is a literature- and datasheet-based comparison of 3-, 6- and 9-axis sensor configurations in the context of fall detection. The research question is whether a higher number of sensed axes actually improves detection performance and, if so, up to which point the improvement justifies the additional cost in energy, computation and complexity.

The analysis draws on peer-reviewed evaluations of accelerometer-only, IMU-based and MARG-based fall detection algorithms, complemented by manufacturer datasheets of three representative components (MPU-6050, LSM6DSOX, BHI360). It concludes that the transition from three to six axes yields a well-documented, substantial improvement – primarily in specificity, i.e. fewer false alarms – whereas the further step to nine axes adds absolute orientation whose benefit is marginal for the short-duration fall event itself, while introducing new susceptibility to indoor magnetic disturbances. A 6-axis configuration is therefore recommended as the sweet spot for the insole use case, which is also compatible with the leading public 6-axis fall datasets (SisFall, KFall) used in subsequent tasks.

Contents

Abbreviations	vii
1 Einleitung	1
1.1 Überblick	1
1.2 Umfang dieses Kapitels	1
1.3 Struktur	1
2 3-, 6- und 9-Achsen-Sensorsysteme zur Sturzerkennung	2
2.1 Forschungsfrage und Vorgehensweise	2
2.2 Physikalische Bedeutung der Achsengruppen	2
2.3 3-Achsen-Systeme: Nur Beschleunigungssensor	3
2.3.1 Erkennungsprinzip	3
2.3.2 Berichtete Leistungsfähigkeit	3
2.3.3 Zentrale Einschränkung: Falsch-positive Erkennungen	3
2.4 6-Achsen-Systeme: Beschleunigungssensor und Gyroskop	3
2.4.1 Welchen Beitrag das Gyroskop leistet	3
2.4.2 Berichtete Leistungssteigerungen	4
2.4.3 Grenzen des Nutzens des Gyroskops	4
2.5 9-Achsen-Systeme: Zusätzliches Magnetometer	4
2.5.1 Funktion des Magnetometers	4
2.5.2 Warum dies für die Sturzerkennung weniger relevant ist	4
2.5.3 Nachteile: Magnetische Störungen in Innenräumen	5
2.6 Beispielkomponenten (Nachweis durch Datenblätter)	5
2.7 Vergleich auf einen Blick	6
2.8 Begründetes Fazit	6
3 Einfluss der Sensoreigenschaften auf die Erkennungsqualität	8
3.1 Messbereich und Signal-Clipping	8
3.2 Abtastrate	8
3.3 Bit-Auflösung	9
3.4 Rauschdichte	9
3.5 Drift, insbesondere beim Gyroskop	10
3.6 Zusammenfassung	10
4 Ausblick auf Datensätze für das ML-Modell	12
4.1 Übersicht der Datensätze	12
4.2 Einzelbewertung	14
4.3 Verfügbarkeit und Zugänglichkeit	15
4.4 Begründete Entscheidung	16

5	Verlauf der Modellentwicklung (Aufgabe 4 Zwischenstand)	18
5.1	Datenaufbereitung	18
5.2	Modell 1: Schwellwert-Baseline	18
5.3	Modell 2: Random Forest mit Magnitude-Features	19
5.4	Modell 3: 1D-CNN	19
5.5	Vergleich der drei Modelle	20
5.6	TFLite-Export für den Mikrocontroller	20
5.7	Domänenlücke und Mitigationsstrategien	20
5.8	Cross-Position-Transfer: Quantifizierung der Domänenlücke	21
5.8.1	Motivation und Versuchsaufbau	21
5.8.2	Ergebnisse	22
5.8.3	Kreuzvalidierung auf FallAllID	23
5.8.4	Falsch-Positiv-Test auf fußnahen Alltagsdaten	24
5.8.5	Progressives Fine-Tuning	26
5.8.6	Zeitliche Plausibilisierung durch N-von-M-Voting	27
5.8.7	Hard-Negative-Training	28
5.8.8	Interpretation	29
5.8.9	Konsequenzen für den Prototyp	30
5.9	Nächste Schritte	31
5.9.1	Einordnung der durchgeführten Kontrollexperimente	31
5.9.2	Verbleibende Arbeitsschritte	32

List of Figures

5.1	Sensitivität und Spezifität des SisFall-Modells auf den UMAFall-Knöcheldaten vor und nach dem Fine-Tuning.	23
-----	---	----

List of Tables

2.1	Von 3-, 6- und 9-Achsen-Sensorkonfigurationen gemessene physikalische Größen.	2
2.2	Repräsentative Komponenten auf 6- und 9-Achsen-Ebene.	5
2.3	Direkter Vergleich der Achsenkonfigurationen für die Sturzerkennung.	6
3.1	Einfluss der Sensoreigenschaften auf die Sturzerkennungsqualität.	11
4.1	Vergleich der sieben zu bewertenden Sturzdatensätze.	13
4.2	Verfügbarkeit und Zugänglichkeit der betrachteten Datensätze.	16
5.1	Vergleich der drei Sturzerkennungsmodelle auf SisFall (subjektunabhängig). .	20
5.2	Ergebnisse aller Transferexperimente. Alle Werte auf subjektunabhängigen Testsplits; Fine-Tuning mit 60 Epochen.	22
5.3	Clipping-Experiment: Sensitivität des SisFall-Modells bei synthetischer Be- grenzung des Beschleunigungsbereichs.	24
5.4	Einflussfaktoren auf den Zero-Shot-Transfer. Der Erfolg hängt nicht von einem einzelnen Faktor ab, sondern von der Gesamtheit der Domänenunterschiede. .	24
5.5	Falsch-Positiv-Rate nach Aktivität (Entscheidungsschwelle 0,5), UMAFall-Knöchelposition, ausschließlich ADL-Aufzeichnungen.	25
5.6	Vergleich der Transferstrategien auf identischem Testsatz (UMAFall, Knöchel). Alle Werte subjektunabhängig.	26
5.7	N-von-M-Voting bei 0,2s Schrittweite, Entscheidungsschwelle 0,9. Se bezeich- net den Anteil der Sturzaufzeichnungen, in denen mindestens einmal Alarm ausgelöst wurde; FP/Std die Fehlalarme pro Stunde ADL-Aufzeichnung. . . .	27
5.8	Wirkung der Hard-Negative-Gewichtung (Regel 2-von-3, Schwelle 0,9).	28
5.9	Firmware-Vorgaben für die Alarmlogik.	31

Abbreviations

ADL	Activity of Daily Living
ADC	Analog-to-Digital Converter
DoF	Degrees of Freedom
IMU	Inertial Measurement Unit
MARG	Magnetic, Angular Rate and Gravity
MEMS	Micro-Electro-Mechanical Systems
MLC	Machine Learning Core
SVM	Signal Vector Magnitude

1 Einleitung

1.1 Überblick

Stürze gehören zu den häufigsten Ursachen für schwere Verletzungen und langfristige gesundheitliche Komplikationen bei älteren und pflegebedürftigen Menschen, insbesondere bei Personen mit Demenz. Ein zuverlässiges, energieeffizientes und alltagstaugliches automatisches Sturzerkennungssystem auf Basis tragbarer Inertialsensoren kann dazu beitragen, Alarme schnell auszulösen und dadurch die Sicherheit in der Pflege zu erhöhen.

Die Qualität der automatischen Sturzerkennung hängt nicht nur vom verwendeten Machine-Learning-Modell zur Klassifikation ab, sondern auch von der zugrunde liegenden Sensorhardware und den verfügbaren Trainingsdaten. Das vorliegende *Studienprojekt 2* ist daher in vier Aufgaben gegliedert: eine kurze theoretische Bewertung der Sensorkonfiguration und ihrer physikalischen Eigenschaften (Aufgaben 1 und 2), eine Bewertung frei verfügbarer Open-Source-Sturzdatensätze (Aufgabe 3) sowie - als Hauptschwerpunkt - die Entwicklung, das Training und die prototypische Integration eines spezifischen Machine-Learning-Modells (Aufgabe 4).

1.2 Umfang dieses Kapitels

Dieses Dokument behandelt die Aufgaben 1 bis 3 des Projekts. Aufgabe 1 vergleicht die drei grundlegenden Sensorachsenkonfigurationen, Aufgabe 2 bewertet den Einfluss niedrigstufiger Sensoreigenschaften auf die Erkennungsqualität und Aufgabe 3 sichtet die in Frage kommenden Open-Source-Datensätze und begründet die Auswahl für die Modellentwicklung in Aufgabe 4.

1.3 Struktur

Kapitel 2 erläutert die physikalischen Grundlagen jeder Sensorachsengruppe und leitet eine begründete Achsenempfehlung ab. Kapitel 3 untersucht den Einfluss von fünf Sensoreigenschaften auf die Erkennungsqualität. Kapitel 4 bewertet sieben Open-Source-Datensätze anhand der in der Aufgabenstellung genannten Kriterien (Sensorposition, Achsenkonfiguration und Abtastrate, Klassenabdeckung und Probandendiversität, Verfügbarkeit) und begründet die Auswahl der Primär- und Sekundärdatensätze für die Modellentwicklung.

2 3-, 6- und 9-Achsen-Sensorsysteme zur Sturzerkennung

2.1 Forschungsfrage und Vorgehensweise

Die zentrale Fragestellung dieses Kapitels lautet, ob eine höhere Anzahl erfasster Achsen die Genauigkeit der Sturzerkennung statistisch signifikant verbessert und bis zu welchem Punkt diese Verbesserung den zusätzlichen Aufwand hinsichtlich Energieverbrauch, Rechenleistung und Komplexität rechtfertigt. Die Aufgabenstellung verlangt ausdrücklich, dass die daraus abgeleitete Bewertung durch Literatur oder Datenblätter gestützt wird und nicht lediglich auf Behauptungen beruht. Die vorliegende Analyse kombiniert daher zwei voneinander unabhängige Beweislinien: (i) begutachtete wissenschaftliche Studien, die Sensitivität und Spezifität der jeweiligen Achsenkonfigurationen berichten, sowie (ii) Herstellerdatenblätter repräsentativer Komponenten aus dem 6- und 9-Achsen-Bereich.

2.2 Physikalische Bedeutung der Achsengruppen

Die drei Achsenkonfigurationen unterscheiden sich hinsichtlich der physikalischen Größen, die sie messen (Tabelle 2.1):

Table 2.1: Von 3-, 6- und 9-Achsen-Sensorkonfigurationen gemessene physikalische Größen.

Konfiguration	Sensoren	Gemessene Größe
3-Achsen	Dreiachsiger Beschleunigungssensor	Lineare Beschleunigung einschließlich der Erdbeschleunigung entlang der x -, y - und z -Achse, üblicherweise in g angegeben.
6-Achsen (IMU)	Dreiachsiger Beschleunigungssensor + dreiachsiges Gyroskop	Lineare Beschleunigung zusammen mit der Winkelgeschwindigkeit (Roll-, Nick- und Gierrate), üblicherweise in $^{\circ}/s$ angegeben.
9-Achsen (MARG)	Dreiachsiger Beschleunigungssensor + dreiachsiges Gyroskop + dreiachsiges Magnetometer	Lineare Beschleunigung, Winkelgeschwindigkeit und der Magnetfeldvektor der Erde, wodurch mittels Sensorfusionsalgorithmen eine absolute Richtungsbestimmung und vollständige Orientierung ermöglicht werden.

2.3 3-Achsen-Systeme: Nur Beschleunigungssensor

2.3.1 Erkennungsprinzip

Der dominierende Ansatz bei 3-Achsen-Systemen berechnet den Betrag der Beschleunigung (Signal Vector Magnitude (SVM)) und wendet Schwellwerte auf die charakteristische Sturzsignatur an: eine Freifallphase, in der der Betrag gegen 0 g fällt, gefolgt von einem ausgeprägten Aufprallmaximum. Ein häufig zitierter Schwellwertalgorithmus von Bourke verwendet einen unteren Freifall-Schwellwert von 0.65 g und einen oberen Aufprall-Schwellwert von 2.8 g, optional ergänzt durch eine Überwachung der Körperhaltung nach dem Aufprall (“Long-Lie”) [1].

2.3.2 Berichtete Leistungsfähigkeit

Schwellwertbasierte Algorithmen, die ausschließlich Beschleunigungssensoren verwenden, erreichen unter Laborbedingungen typischerweise Sensitivitäts- und Spezifitätswerte im Bereich von 80–95 % [2]. Bei sorgfältig simulierten Laborstürzen berichten einzelne Algorithmen sogar nahezu perfekte Ergebnisse. Wurde derselbe leistungsstärkste Algorithmus jedoch anhand einer Datenbank mit *realen* Stürzen älterer Menschen bewertet, sank die Sensitivität auf 83 % (Spezifität 97 %) [1]. Diese Diskrepanz stellt einen gut dokumentierten Realitätscheck für sämtliche Laborergebnisse in diesem Forschungsgebiet dar.

2.3.3 Zentrale Einschränkung: Falsch-positive Erkennungen

Die ausschließliche Verwendung des Beschleunigungsbetrags erlaubt keine zuverlässige Unterscheidung zwischen tatsächlichen Stürzen und sturzähnlichen Aktivitäten des täglichen Lebens (Activity of Daily Livings (ADLs)), wie beispielsweise schnellem Hinsetzen, Hinlegen, Laufen oder Springen, da all diese vergleichbar hohe Beschleunigungsspitzen erzeugen können [3]. Eine Absenkung des Erkennungsschwellwertes, um mehr Stürze zu erfassen, erhöht unmittelbar die Rate falsch-positiver Alarme, ein grundlegender Zielkonflikt zwischen Sensitivität und Spezifität des Einzelmodalitätsansatzes [2]. Im Pflegekontext untergraben häufige Fehlalarme die Akzeptanz der Nutzer und führen nachweislich zu Alarmmüdigkeit.

2.4 6-Achsen-Systeme: Beschleunigungssensor und Gyroskop

2.4.1 Welchen Beitrag das Gyroskop leistet

Stürze gehen mit einer charakteristischen schnellen Änderung der Körperorientierung (Rotation in Richtung der Horizontalen) einher, die bei ADLs wie dem Hinsetzen nicht in derselben Kombination aus Rotationsgeschwindigkeit und Beschleunigung auftritt. Die vom Gyroskop gemessene Winkelgeschwindigkeit liefert daher ein unabhängiges Unterscheidungsmerkmal genau dort, wo das Signal des Beschleunigungssensors mehrdeutig ist.

2.4.2 Berichtete Leistungssteigerungen

Zwei unabhängige quantitative Ergebnisse kommen zu derselben Schlussfolgerung. In einem auf der Brust getragenen System mit 702 Aufzeichnungen von 36 Probanden erhöhte die Ergänzung eines beschleunigungsbasierten Algorithmus durch Gyroskop-Schwellwerte die *Spezifität* von 82.72 % auf 96.2 %, während gleichzeitig eine Sensitivität von 96.3 % erhalten blieb (Schwellwerte mittels ROC-Analyse optimiert) [3]. In einer Smartphone-basierten Studie mit frei variierenden Gerätepositionen übertraf die Kombination aus Beschleunigungssensor und Gyroskop die reine Beschleunigungssensor-Konfiguration um mehr als 15 Prozentpunkte hinsichtlich der Genauigkeit [4]. Beide Ergebnisse identifizieren die Reduktion falsch-positiver Erkennungen als den wesentlichen Beitrag des Gyroskops.

2.4.3 Grenzen des Nutzens des Gyroskops

Der Zugewinn ist jedoch nicht uneingeschränkt. Studien, die die Mehrdeutigkeit des Beschleunigungssensors bereits auf andere Weise kompensieren – etwa durch zwei Sensorpositionen oder die Fusion mit einem Barometer-, berichten von geringeren zusätzlichen Vorteilen durch das Gyroskop [5, 6]. Der Vorteil einer 6-Achsen-Konfiguration ist daher insbesondere im Szenario mit nur einem Sensor an einer einzigen Position am größten, genau der Einlagenkonfiguration, die dieses Projekt verfolgt.

2.5 9-Achsen-Systeme: Zusätzliches Magnetometer

2.5.1 Funktion des Magnetometers

Die auf dem Gyroskop basierende Orientierung wird durch numerische Integration der Winkelgeschwindigkeit bestimmt, wodurch sich Messfehler im Laufe der Zeit aufsummieren. Roetenberg et al. berichten, dass eine ausschließlich auf dem Gyroskop basierende Integration innerhalb von 45 s um etwa 10° abdriften kann [7]. Das Magnetometer misst das Magnetfeld der Erde und stellt dadurch eine *absolute* Richtungsreferenz bereit. In Kombination mit Beschleunigungssensor und Gyroskop in einem Kalman- oder Madgwick-Filter korrigiert es diese Drift und liefert eine stabile absolute Orientierung (Gier, Nick und Roll).

2.5.2 Warum dies für die Sturzerkennung weniger relevant ist

Ein Sturz ist ein kurzzeitiges Ereignis, die kritische Phase vom Verlust des Gleichgewichts bis zum Aufprall dauert typischerweise nur ein bis wenige Sekunden. Innerhalb dieses Zeitraums ist die Gyroskopdrift gering. Die Driftkorrektur, welche den Hauptbeitrag des Magnetometers darstellt, kommt daher in erster Linie der *langfristigen* Orientierungsbestimmung zugute und nicht der Erkennung eines kurzen, hochdynamischen Ereignisses. Die mit sechs Achsen messbare relative Orientierungsänderung reicht aus, um die Kinematik eines Sturzes zu charakterisieren.

2.5.3 Nachteile: Magnetische Störungen in Innenräumen

Messwerte von Magnetometern werden in Innenräumen systematisch verfälscht: Ferromagnetische Materialien in Gebäudestrukturen, Haushaltsgeräten und Möbeln verändern das lokale Magnetfeld, verursachen Richtungsfehler, die häufig 5° überschreiten, und erschweren dadurch mobile Anwendungen [8–10]. Da ältere Menschen den größten Teil ihrer Zeit in Innenräumen verbringen, erfordert ein robuster Betrieb Kalibrierungs- und Störkompensationsalgorithmen, also zusätzlichen Rechenaufwand [8, 10] zusätzlich zum höheren Energieverbrauch und Integrationsaufwand einer dritten Sensormodalität sowie einer vollständigen 9-Degrees of Freedom (DoF)-Sensorfusion.

2.6 Beispielkomponenten (Nachweis durch Datenblätter)

Die drei in der Aufgabenstellung genannten repräsentativen Komponenten werden in Tabelle 2.2 verglichen. Sämtliche Angaben sind typische Werte unter den jeweiligen Herstellerbedingungen und müssen für den finalen Bericht anhand der Originaldatenblätter erneut überprüft werden.

Table 2.2: Repräsentative Komponenten auf 6- und 9-Achsen-Ebene.

Komponente	Konfig.	Messbereiche	Stromaufnahme	Besonderheiten
MPU-6050 [11]	6-Achsen IMU	$\pm 2/4/8/16$ g; ± 250 – $2000^\circ/\text{s}$	≈ 3.9 mA	Klassische kostengünstige Referenz mit 16-Bit-ADCs; alle Sensoren aktiv; Referenz für den 6-Achsen-Vergleich.
LSM6DSOX [12]	6-Achsen IMU	± 2 – 16 g; ± 125 – $2000^\circ/\text{s}$	0.55 mA	Hochleistungsmodus; etwa $7\times$ geringere Stromaufnahme als der MPU-6050; integrierter MLC und hardwarebasierte Freifallerkennung.
BHI360 [13] (9-DoF externes Magnetometer)	6-Achsen IMU Geräteabhängig	± 600 μA	Führt die BSX- Fusionsbibliothek direkt auf dem Chip aus und entlastet dadurch den Hauptprozessor von der Sensorfusion.	

Der Effizienzunterschied zwischen dem MPU-6050 (Generation um 2010) und dem LSM6DSOX/BHI360 zeigt außerdem, dass die *Sensorgeneration* den Energiebedarf ebenso stark beeinflussen kann wie die Anzahl der Achsen.

2.7 Vergleich auf einen Blick

Table 2.3: Direkter Vergleich der Achsenkonfigurationen für die Sturzerkennung.

	3-Achsen	6-Achsen	9-Achsen
Erfasst	Aufprallmaximum, Freifallphase (SVM)	+ Rotationsgeschwindigkeit → Sturzkinematik	+ absolute Orientierung / Himmelsrichtung
Stärken	Minimaler Aufwand hinsichtlich Kosten, Energie und Komplexität	Großer Spezifitätsgewinn (82.7 → 96.2 % [3]; über 15 Prozentpunkte Genauigkeit [4])	Driftkorrigierte langfristige Orientierung [7]
Schwächen	Falsch-positive Erkennungen durch sturzähnliche ADLs [2, 3]; geringere Sensitivität bei realen Stürzen [1]	Höhere Stromaufnahme; Drift spielt nur deshalb kaum eine Rolle, weil Stürze kurz sind	Magnetische Störungen in Innenräumen [8–10]; zusätzlicher Energie-, Rechen- und Kalibrierungsaufwand
Nutzen für die Sturzerkennung	Basislösung, praktikabel, aber anfällig für Alarmmüdigkeit	Hoch, behebt den wesentlichen Schwachpunkt	Gering, korrigiert einen Fehler, der sich innerhalb von 1-2s kaum aufbaut

2.8 Begründetes Fazit

Von drei auf sechs Achsen: eindeutig gerechtfertigt. Der Übergang adressiert den dokumentierten Hauptschwachpunkt der ausschließlich auf Beschleunigungssensoren basierenden Sturzerkennung - falsch-positive Erkennungen durch sturzähnliche ADLs - mit gemessenen Spezifitätssteigerungen von etwa $\approx 83\%$ auf $\approx 96\%$ [3] sowie Genauigkeitssteigerungen von mehr als 15 Prozentpunkten [4]. Dies geschieht zum Preis einer einzigen zusätzlichen Micro-Electro-Mechanical Systems (MEMS)-Sensormodalität, deren Stromaufnahme bei modernen Bauteilen gering ausfällt (0.55 mA für eine vollständige 6-Achsen-LSM6DSOX [12]).

Von sechs auf neun Achsen: für diesen Anwendungsfall nicht verhältnismäßig. Der Hauptbeitrag des Magnetometers, absolute Richtungsbestimmung und langfristige Driftkorrektur [7] adressiert ein Problem, das bei einem 1-2 Sekunden dauernden Sturzereignis praktisch nicht relevant ist, führt jedoch gleichzeitig ein neues Problem ein: Richtungsfehler durch ferromagnetische Verzerrungen genau in den Innenraumumgebungen, in denen ältere Menschen leben [8–10], sowie zusätzlichen Energieverbrauch, Rechenaufwand und Kalibrierungsbedarf. Keine der in dieser Literaturübersicht betrachteten Studien zeigt einen Genauigkeitsgewinn durch das Magnetometer, der mit dem Beitrag des Gyroskops vergleichbar wäre.

Empfehlung: Eine 6-Achsen-Konfiguration stellt den besten Kompromiss für die einlagenbasierte Sturzerkennung dar. Dies wird zusätzlich dadurch unterstützt, dass die führenden öffentlich verfügbaren Sturzdatensätze (SisFall, KFall) selbst auf 6-Achsen-Aufzeichnungen basieren, wodurch zugleich die Kompatibilität der Trainingsdaten für das im Rahmen von Aufgabe 4 zu entwickelnde Machine-Learning-Modell sichergestellt wird.

3 Einfluss der Sensoreigenschaften auf die Erkennungsqualität

In Kapitel 2 wurde die Wahl einer sechsachsigen IMU auf der Ebene begründet, *welche* Achsen erfasst werden sollen. Das vorliegende Kapitel ergänzt diese Argumentation um eine zweite Ebene und fragt, *wie präzise* diese Achsen erfasst werden müssen. Betrachtet werden fünf niedrigstufige Datenblattgrößen, nämlich Messbereich, Abtastrate, Bit-Auflösung, Rauschdichte und Drift, sowie deren jeweiliger Einfluss auf die Sturzerkennung. Gemäß der Aufgabenstellung wird der Umfang bewusst kompakt gehalten und stützt sich vollständig auf die Fachliteratur; eigene Messreihen sind nicht vorgesehen.

3.1 Messbereich und Signal-Clipping

Der Messbereich legt fest, wie große Beschleunigungen ein Sensor darstellen kann, bevor er in die Sättigung gerät. Ein Sturz besteht aus zwei dynamischen Phasen mit stark unterschiedlicher Amplitude. In der freien Fallphase sinkt der Betrag der gemessenen Beschleunigung gegen 0 g, worauf innerhalb weniger Millisekunden der Aufprall folgt, dessen Spitzenwert typischerweise ein Mehrfaches der Erdbeschleunigung erreicht. In der Literatur häufig zitierte Schwellwertverfahren setzen den oberen Impact-Schwellwert an der Hüfte im Bereich von 2,0 g bis 2,8 g an [1, 14]. An peripheren Körperstellen fallen die lokalen Spitzenwerte allerdings deutlich höher aus; Untersuchungen zur Tibia-Beschleunigung im Alltag berichten Werte, die im Knöchelbereich 16 g bis 24 g überschreiten können [15].

Wird der Messbereich zu klein gewählt, kommt es zum sogenannten Clipping. Das Analogsignal wird auf den größten darstellbaren Wert abgeschnitten, und in der Zeitreihe zeigen sich charakteristische flache Plateaus. Dabei wird gerade dasjenige Merkmal verzerrt, das für die Sturzerkennung die höchste Trennschärfe aufweist, nämlich der Impact-Peak. Vergleichende Messungen belegen einen Genauigkeitsverlust bei der Peak-Tibial-Acceleration von etwa 6,25 % bei ± 16 g und 28,17 % bei ± 8 g gegenüber einer Referenz mit ± 70 g [15]. Ein Messbereich von ± 2 g, wie er in einfachen Konsumbausteinen üblich ist, reicht daher an keiner Körperposition aus. ± 8 g stellt eine praxistaugliche Untergrenze dar, während ± 16 g, wie im SisFall-Datensatz verwendet [16], insbesondere für periphere Positionen wie die geplante Anbringung in der Schuhsohle einen sinnvollen Sicherheitspuffer bietet.

3.2 Abtastrate

Die Abtastrate bestimmt, mit welcher zeitlichen Auflösung sich die charakteristische Signatur eines Sturzes rekonstruieren lässt. Menschliche Bewegungen sind spektral von tiefen Frequenzen dominiert, und die kritische Phase eines Sturzes umfasst nur einige hundert Millisekunden. Nach dem Nyquist-Kriterium sind daher bereits Abtastraten im Bereich einiger zehn Hertz

ausreichend, um das relevante Frequenzband abzudecken.

Zwei unabhängig voneinander durchgeführte empirische Arbeiten kommen zu einem übereinstimmenden Ergebnis. Villar et al. zeigen, dass eine Abtastfrequenz von 15 Hz bis 20 Hz genügt, um mit einem Convolutional Neural Network eine Sensitivität und Spezifität von über 95 % zu erreichen, während höhere Frequenzen keinen nennenswerten Zusatzgewinn liefern [17]. Eine aktuellere Untersuchung auf dem SisFall-Datensatz trainierte fünf Klassifikatoren bei 10, 20, 50 und 100 Hz. Als bester Kompromiss wurde ein CNN-LSTM-Modell bei 20 Hz identifiziert, das eine Genauigkeit von 98,9 %, eine Sensitivität von 96,7 % und eine Spezifität von 99,6 % erreicht und dabei gleichzeitig das übertragene Datenvolumen deutlich reduziert [18]. Werte unterhalb von 10 Hz beginnen, kritische Details der Aufprallphase zu verlieren, während Werte oberhalb von etwa 100 Hz im Wesentlichen nur die Datenrate und den Energiebedarf erhöhen, ohne dass die Klassifikationsleistung weiter zunimmt.

Für ein sohlenbasiertes System, das ein batteriebetriebenes Wearable mit einem auf begrenzter Hardware ausgeführten ML-Modell kombiniert, stellt somit eine Abtastrate zwischen 20 Hz und 50 Hz einen aus praktischer Sicht sinnvollen Arbeitspunkt dar.

3.3 Bit-Auflösung

Digital ausgegebene MEMS-Beschleunigungssensoren quantisieren das Analogsignal mit einer festen Anzahl von Bits, in der Regel zwischen zwölf und sechzehn. Für die nominelle Auflösung q in Einheiten von g gilt $q = \text{FSR}/2^N$, wobei FSR die Vollbereichsspanne und N die Bit-Breite bezeichnet. Für einen 16-Bit-ADC bei $\pm 16\text{ g}$ folgt daraus $q \approx 0,5\text{ mg}$ pro Code. Eine höhere Auflösung erlaubt eine feinere Unterscheidung geringfügiger Bewegungen, etwa langsames Hinsetzen im Vergleich zum Einleiten eines Sturzes, was der merkmalsbasierten Machine-Learning-Stufe in Aufgabe 4 zugutekommt.

Die nominelle Auflösung stellt allerdings eine obere Schranke dar. Die effektive Bitanzahl richtet sich nach dem Verhältnis von Vollbereichsspanne zum integrierten Sensorrauschen. Veröffentlichte Beispiele belegen, dass ein als 16-Bit deklarierter Baustein nach Abzug des sensoreigenen Rauschens nur etwa 8,5 rauschfreie Bits liefert [19]. In der Praxis gehören 12- bis 16-Bit-Wandler in Wearables zur Sturzerkennung zum Stand der Technik und stellen keinen limitierenden Faktor der Klassifikationsgüte dar. Praktisch relevanter ist die im folgenden Abschnitt behandelte Rauschdichte.

3.4 Rauschdichte

Die Rauschdichte n_d , in Datenblättern typischerweise in $\mu\text{g}/\sqrt{\text{Hz}}$ für den Beschleunigungssensor beziehungsweise in $\text{mdps}/\sqrt{\text{Hz}}$ für das Gyroskop angegeben, quantifiziert das dem Nutzsignal überlagerte stochastische Grundrauschen. Für das effektive RMS-Rauschen am Klassifikatoreingang gilt

$$\sigma_{\text{RMS}} = n_d \cdot \sqrt{\text{BW}_{\text{NEB}}}, \quad (3.1)$$

wobei BW_{NEB} die rauschäquivalente Bandbreite des digitalen Filters bezeichnet [20]. Für einen typischen Konsumbaustein mit $n_d \approx 126 \mu\text{g}/\sqrt{\text{Hz}}$ und einer Bandbreite von 200 Hz ergibt sich hieraus $\sigma_{\text{RMS}} \approx 1,8 \text{ mg}$ [20]. Eine verbreitete Faustregel fordert, dass das kleinste zu detektierende Merkmal mindestens eine Größenordnung über σ_{RMS} liegen sollte [20].

Diese Anforderung ist für die Sturzerkennung leicht zu erfüllen. Die dominanten Impact-Peaks liegen im Bereich mehrerer g, sodass das Grundrauschen die Aufprallphase in der Praxis nicht beeinflusst. Relevant wird die Rauschdichte hingegen in der Merkmalsextraktion einer Machine-Learning-Pipeline (vgl. Aufgabe 4), in der feine Statistiken wie Varianz, Kurtosis oder Ableitungen der Signalmagnitude herangezogen werden, um sturzähnliche Alltagsaktivitäten von tatsächlichen Stürzen zu trennen. Rauscharme Bausteine wie der LSM6DSOX [12] bringen an dieser Stelle einen kleinen, aber reproduzierbaren Vorteil für den Klassifikator, und dies ohne relevanten Zusatzaufwand, da sie zugleich einen geringeren Stromverbrauch aufweisen.

3.5 Drift, insbesondere beim Gyroskop

Das Ausgangssignal eines Gyroskops enthält einen langsam veränderlichen Bias, dessen spektrale Fluktuationen im tiefen Frequenzbereich von einem Anteil mit $1/f$ -Charakteristik dominiert werden [21]. Die zugehörige Kenngröße, die Bias-Instabilität, wird üblicherweise über die Allan-Varianz quantifiziert. Für typische kostengünstige MEMS-Gyroskope liegt sie in der Größenordnung von $3,6^\circ/\text{h}$ [22]. Bausteine der MPU-6050-Klasse zeigen auf allen drei Achsen ein vergleichbares Verhalten [23].

Ob dieser Drift praxisrelevant wird, hängt entscheidend vom Beobachtungsfenster ab. Bei einer Integration der Winkelgeschwindigkeit zur Bestimmung der Orientierung akkumuliert sich der Fehler mit der Zeit. Roetenberg et al. weisen für eine rein gyroskopische Integration einen bias-bedingten Orientierungsfehler von rund 10° innerhalb von 45 Sekunden nach [7]. Für ein Sturzereignis, dessen relevante Zeitspanne im Bereich von ein bis zwei Sekunden liegt, ist der Driftbeitrag jedoch verschwindend gering im Vergleich zu den während des Sturzes auftretenden Rotationsraten. Dieser Befund deckt sich mit der Schlussfolgerung aus Kapitel 2, wonach die driftkompensierende Funktion des Magnetometers für die eigentliche Sturzerkennung nur einen marginalen Nutzen liefert.

3.6 Zusammenfassung

Die fünf betrachteten Eigenschaften wirken nicht isoliert, sondern greifen ineinander (Tabelle 3.1). Für einen Machine-Learning-basierten Sturzdetektor in Sohlenkonfiguration ergibt sich hieraus als empfohlener Arbeitspunkt eine sechssachsige IMU mit einem Beschleunigungs-Messbereich von $\pm 16 \text{ g}$, einem Gyroskop-Messbereich von ± 1000 bis $\pm 2000^\circ/\text{s}$, einer Abtastrate zwischen 20 Hz und 50 Hz, mindestens 12 Bit Auflösung, geringer Rauschdichte (unterhalb von etwa $100 \mu\text{g}/\sqrt{\text{Hz}}$) sowie einer nicht weiter kompensierten Gyroskop-Drift, da deren Beitrag über die kurze Sturzdauer vernachlässigbar bleibt. Diese Anforderungen werden vom in Kapitel 2

diskutierten LSM6DSOX abgedeckt und stehen im Einklang mit der Aufnahmecharakteristik des SisFall-Datensatzes, der in den Aufgaben 3 und 4 verwendet wird.

Table 3.1: Einfluss der Sensoreigenschaften auf die Sturzerkennungsqualität.

Eigenschaft	Primärer Effekt	Empfohlener Bereich
Messbereich	Verhindert Clipping des Impact-Peaks; ein zu kleiner Bereich verzerrt das trennschärfste Merkmal [14, 15]	mindestens ± 8 g, empfohlen ± 16 g
Abtastrate	Zeitliche Rekonstruktion der Sturzsiganatur; höhere Raten erhöhen den Energiebedarf ohne Genauigkeitsgewinn [17, 18]	20 Hz bis 50 Hz
Bit-Auflösung	Feinauflösung der Merkmalsextraktion; effektive Bitzahl durch das Rauschen begrenzt [19]	mindestens 12 Bit
Rauschdichte	Bestimmt die minimal auflösbare Signalgröße; wirkt sich vor allem auf die Unterscheidung von ADL und Präaufprall aus [20]	$\leq 100 \mu\text{g}/\sqrt{\text{Hz}}$
Gyroskop-Drift	Langzeitfehler der Orientierungsbestimmung; auf der Zeitskala eines Sturzes vernachlässigbar [7, 21]	für kurze Ereignisse unkritisch

4 Ausblick auf Datensätze für das ML-Modell

Für die Entwicklung des eigenen Machine-Learning-Modells in Aufgabe 4 stehen mehrere frei verfügbare Sturzdatensätze zur Auswahl. Die Aufgabenstellung nennt mindestens sieben Kandidaten, die im Folgenden hinsichtlich ihrer Eignung für den angestrebten Anwendungsfall bewertet werden: eine schuhsohlenintegrierte (*Insole*-)Sturzerkennung bei älteren, gegebenenfalls kognitiv eingeschränkten Personen. Die Bewertungskriterien orientieren sich an der Aufgabenstellung und umfassen die Sensorposition am Körper und deren Übertragbarkeit auf eine Fußsohle, die Achsenkonfiguration und Abtastrate im Vergleich zur geplanten Sensorik, die Abdeckung verschiedener Sturz- und ADL-Klassen, die Diversität der Probanden sowie die Verfügbarkeit und Zugänglichkeit der Rohdaten.

Die Aufgabenstellung enthält bereits eine erste Einschätzung zur Eignung der sieben Datensätze. Diese wurde im Rahmen der vorliegenden Bearbeitung anhand der Originalpublikationen und der offiziellen Datensatzquellen eigenständig geprüft, vertieft und dort präzisiert oder korrigiert, wo die tatsächlichen Datenblätter von der Aufgabenstellung abweichen. Die entsprechenden Anpassungen sind in den nachfolgenden Abschnitten kenntlich gemacht.

4.1 Übersicht der Datensätze

Tabelle 4.1 fasst die wesentlichen Eckdaten der sieben Datensätze zusammen. Im Anschluss wird jeder Datensatz einzeln hinsichtlich seiner Stärken und Einschränkungen für den vorliegenden Anwendungsfall eingeordnet.

Table 4.1: Vergleich der sieben zu bewertenden Sturzdatensätze.

Datensatz	Sensorik / Position	Achsen	Hz	Probanden	Eignung für Insole
SisFall [16]	2 Beschl.-Sensoren (ADXL345 ± 16 g, MMA8451Q ± 8 g) + Gyroskop (ITG3200 $\pm 2000^\circ/\text{s}$), am Gürtel (Hüfte)	6 ($2 \times 3 + 3$)	200	38 (23 jung, 15 ältere)	Gut geeignet: passende Achsenkonfiguration, hohe Abtastrate, etablierter Benchmark mit vielen Vergleichswerten in der Literatur.
MobiFall / MobiAct [24, 25]	Smartphone (Samsung Galaxy S3) in der Hosentasche	6–9 (variabel)	≈ 20 –87	11 / 57	Bedingt geeignet: Smartphone-Sensorik (oft nur ± 2 g) unterscheidet sich von einer Insole; Trageposition und Messbereich weichen ab.
UMAFall [26]	4 $\times$ SensorTag (MPU-9250) an Brust, Hüfte, Handgelenk, Knöchel + Smartphone in der Tasche	9	20 (Tags) / 200 (Smartphone)	19 (19–68 J.)	Bedingt geeignet: Mehrknoten-Aufbau interessant, aber IMU-Abtastrate nur 20 Hz; Knöcheldaten vorhanden, jedoch nur 3 Sturztypen.
KFall [27]	9-Achsen-IMU (MTw Awinda) am unteren Rücken; bereitgestellt werden Beschl., Winkelgeschw. und Euler-Winkel	6 + Euler	100	32	Gut geeignet: hohe Abtastrate, 15 Sturztypen, zeitliche Annotation des Aufprallzeitpunkts (Pre-Impact), umfangreicher Benchmark.
FallAllD [28]	3 $\times$ IMU (LSM9DS1) an Nacken, Handgelenk und Taille; Beschl. ± 8 g, Gyro $\pm 2000^\circ/\text{s}$, Mag, Baro	9 (+ Baro)	238 / 476 (Beschl.)	15	Bedingt geeignet: Tailendaten nutzbar, hohe Abtastrate, aber nur 15 (junge) Probanden und Messbereich ± 8 g kann an peripheren Positionen clippen (vgl. Abschnitt 3.1).
UniMiB SHAR [29]	Smartphone (Samsung Galaxy Nexus) in der Hosentasche	3	50	30 (18–60 J.)	Eingeschränkt geeignet: rein 3-achsig (nur Beschleunigungssensor), daher für einen theoretischen 3- vs. 6-Achsen-Vergleich hilfreich, aber nicht für ein realistisches 6-Achsen-Modell.
WEDA-FALL [30]	Fitbit Sense Smartwatch am Handgelenk	6	50	25 (14 jung, 11 ältere >80 J.)	Bedingt geeignet: Handgelenk-Position weicht stark von der Fußposition ab; niedrige Abtastrate (50 Hz); enthält jedoch Daten älterer Probanden, was für Kreuzvalidierung nützlich sein kann.

4.2 Einzelbewertung

SisFall wurde an der Universidad de Antioquia erhoben und umfasst 4505 Aufzeichnungen (2707 ADL, 1798 simulierte Stürze) von 38 Probanden, darunter 15 Personen im Alter von 60 bis 75 Jahren [16]. Die Sensoreinheit wurde am Gürtel (Hüfte) befestigt und besteht aus *zwei* Beschleunigungssensoren (ADXL345 mit ± 16 g und MMA8451Q mit ± 8 g) sowie einem Gyroskop (ITG3200 mit $\pm 2000^\circ/\text{s}$), aufgezeichnet mit einer Abtastrate von 200 Hz. Die redundante Beschleunigungsmessung entspricht der Angabe der Aufgabenstellung von „zwei Beschleunigungssensoren + Gyroskop“ und wurde in einer früheren Fassung dieser Arbeit unzutreffend als Einzelsensor beschrieben. SisFall ist der am häufigsten zitierte Benchmark für die sensorbasierte Sturzerkennung, was eine direkte Vergleichbarkeit der eigenen Ergebnisse mit der Literatur ermöglicht. Die 6-Achsen-Konfiguration (Beschleunigung + Gyroskop) stimmt mit der in Kapitel 2 empfohlenen Achsenwahl überein. Einschränkend ist anzumerken, dass die älteren Probanden nur ADL durchführten und keine simulierten Stürze, sodass die Sturzdaten ausschließlich von jungen Erwachsenen stammen.

MobiFall und MobiAct basieren auf Smartphone-Sensorik und wurden an der Technischen Hochschule Kreta erhoben [24, 25]. MobiAct umfasst 57 Probanden, 4 Sturztypen und 9 ADL; die Daten wurden mit dem eingebauten Beschleunigungssensor und Gyroskop eines Samsung Galaxy S3 aufgezeichnet. Der Messbereich der Smartphone-Beschleunigungssensoren liegt häufig nur bei ± 2 g, was für die Sturzerkennung zu Clipping führen kann (vgl. Abschnitt 3.1). Darüber hinaus unterscheidet sich die Trageposition (Hosentasche) grundlegend von einer Insole, sodass eine Übertragbarkeit der Bewegungsmuster auf die Fußsohle nicht ohne Weiteres gegeben ist.

UMAFall setzt einen Mehrknoten-Aufbau mit vier SensorTags (MPU-9250, je Beschleunigungssensor, Gyroskop und Magnetometer) und einem Smartphone ein [26]. Durch die gleichzeitige Erfassung an Brust, Hüfte, Handgelenk und Knöchel ermöglicht dieser Datensatz die Untersuchung positionsabhängiger Effekte. Die Abtastrate der SensorTags beträgt allerdings nur 20 Hz, und es sind lediglich drei Sturztypen enthalten. Für den vorliegenden Anwendungsfall bieten die Knöcheldata zwar eine gewisse Nähe zur Fußposition, die geringe Abtastrate und begrenzte Sturzdiversität schränken den praktischen Nutzen jedoch ein.

KFall wurde am KAIST in Südkorea erhoben und umfasst 5075 Aufzeichnungen (2729 ADL, 2346 Stürze) von 32 Probanden [27]. Zum Einsatz kam eine 9-Achsen-IMU (Xsens MTw Awinda) am unteren Rücken; die veröffentlichten Datenfiles enthalten die 3-Achsen-Beschleunigung, die 3-Achsen-Winkelgeschwindigkeit sowie die per Sensorfusion abgeleiteten Euler-Winkel bei 100 Hz. Für den Vergleich mit einer geplanten reinen 6-Achsen-Sensorik können die Euler-Kanäle verworfen und lediglich Beschleunigung und Winkelgeschwindigkeit verwendet werden. Eine Besonderheit von KFall ist die zeitliche Annotation des Sturzbeginns und des Aufprallzeitpunkts anhand synchronisierter Videoaufnahmen, was den Datensatz insbesondere für die Pre-Impact-Erkennung wertvoll macht. KFall bietet damit eine gute Ergänzung zu SisFall, da die simulierten Sturztypen aus SisFall übernommen wurden, die Abtastrate hinreichend hoch ist und die Pre-Impact-Annotation Zusatzinformationen für die Merkmalsextraktion liefert.

Einschränkend ist, dass sämtliche Probanden junge Erwachsene waren.

FallAllID enthält Daten von drei gleichzeitig getragenen IMUs (LSM9DS1), die am Nacken, am Handgelenk und an der Taille befestigt waren [28]. Damit weicht die Sensorposition von der Angabe in der Aufgabenstellung (Hals, Brust, Taille) ab; entscheidend ist die Position am Handgelenk anstelle der Brust, wie die offizielle Beschreibung des Datensatzes auf IEEE DataPort bestätigt. Die Abtastrate ist mit 238 Hz für Beschleunigungssensor und Gyroskop hoch, die Sensoren umfassen zusätzlich ein Magnetometer und ein Barometer. Der Datensatz deckt zahlreiche Sturz- und ADL-Typen ab und ist hinsichtlich der Bewegungsvielfalt umfangreicher als die meisten anderen betrachteten Kandidaten. Einschränkend sind der gegenüber SisFall geringere Messbereich von ± 8 g sowie die kleine Probandenzahl von 15 (jungen) Personen. Für den vorliegenden Anwendungsfall sind vor allem die Aufzeichnungen am Taillensensor relevant, da sie in der Kinematik am ehesten den bisherigen Benchmark-Datensätzen entsprechen.

UniMiB SHAR ist ein reiner 3-Achsen-Datensatz (Beschleunigungssensor, 50 Hz) von Smartphone-Aufzeichnungen aus der Hosentasche [29]. Er umfasst 11 771 Samples von 30 Probanden mit 9 ADL und 8 Sturztypen. Da kein Gyroskop vorhanden ist, eignet sich dieser Datensatz nicht für die Entwicklung eines 6-Achsen-Modells, kann aber hilfsweise als Vergleichsbasis für die Frage herangezogen werden, welchen Mehrwert die sechste Achse bringt (vgl. Kapitel 2).

WEDA-FALL wurde mit einer Fitbit Sense Smartwatch am Handgelenk aufgenommen und enthält Beschleunigungs- und Gyroskop-Daten mit einer nativen Abtastrate von 50 Hz [30]. Nach Angabe der Aufgabenstellung stellt WEDA-FALL zusätzlich vordefinierte Downsampling-Varianten bei 40, 25, 10 und 5 Hz bereit. Diese Mehrfach-Abtastraten bilden ein zusätzliches Argument für die Aufnahme von WEDA-FALL in die engere Auswahl: Der Einfluss der in Kapitel 3 diskutierten Abtastrate lässt sich damit an identischen Bewegungssequenzen kontrolliert isolieren, was in keinem der übrigen Datensätze möglich ist. Eine weitere Stärke ist die Einbeziehung von 11 älteren Probanden (über 80 Jahre), was unter den hier betrachteten Datensätzen einzigartig ist. Die Handgelenk-Position weicht jedoch stark von einer Fußsohle ab, und die vergleichsweise niedrige native Abtastrate begrenzt die Auflösung hochdynamischer Phasen. WEDA-FALL ist daher vor allem für handgelenkbasierte Szenarien relevant und bietet sich für eine Kreuzvalidierung des Modells sowie für gezielte Ablationsstudien zur Abtastrate an.

4.3 Verfügbarkeit und Zugänglichkeit

Neben den inhaltlichen Kriterien nennt die Aufgabenstellung ausdrücklich die *Verfügbarkeit und Zugänglichkeit* der Datensätze als Bewertungskriterium. Tabelle 4.2 stellt für jeden der sieben Kandidaten die offizielle Bezugsquelle, die Art des Zugangs sowie die Lizenz zusammen. Der Zugang reicht dabei von einem unmittelbaren Direktdownload ohne Registrierung (UMAFall, KFall, WEDA-FALL) über einfache Kontoerstellungen (FallAllID via IEEE DataPort) bis hin zu einem formal zu unterzeichnenden Nutzungsvertrag mit dem herausgebenden Institut (MobiFall/MobiAct). Für die zeitliche Planung des ML-Teils in Aufgabe 4 ist insbesondere zu berücksichtigen, dass die Freigabe der MobiFall/MobiAct-Daten eine mehrtägige

Bearbeitungszeit erfordert und daher frühzeitig zu beantragen ist. Für SisFall wurde im Rahmen dieser Arbeit festgestellt, dass die in mehreren Publikationen zitierte URL zeitweise nicht erreichbar war; die Daten sind derzeit jedoch wieder über die Projektseite des SISTEMIC-Labors an der Universidad de Antioquia abrufbar.

Table 4.2: Verfügbarkeit und Zugänglichkeit der betrachteten Datensätze.

Datensatz	Bezugsquelle	Zugangsverfahren	Lizenz
SisFall	SISTEMIC, Univ. de Antioquia (Kolumbien)	Direktdownload; URL zeitweise nicht erreichbar	CC BY 4.0
MobiFall / MobiAct	BMI Lab, Hellenic Mediterranean University (Griechenland)	Auf Anfrage per E-Mail; unterschiedlicher Nutzungsvertrag erforderlich	Nur nicht- kommerzielle Forschung
UMAFall	Figshare/Univ. de Málaga (DOI 10.6084/m9.figshare.4214283)	Direktdownload ohne Registrierung	Angabe der Autoren- Publikationen
KFall	KAIST, Google Sites (<i>sites.google.com/view/kfalldataset</i>)	Direktdownload ohne Registrierung	Zitierpflicht
FallAllD	IEEE DataPort (Open Access)	Kostenfreier IEEE-Account (keine IEEE-Mitgliedschaft erforderlich)	Open Access, Zitierpflicht
UniMiB SHAR	SAL-Lab, Univ. Milano-Bicocca (Italien)	Direktdownload; Spiegelkopie auf Kaggle verfügbar	Nur nicht- kommerzielle Forschung
WEDA- FALL	GitHub-Repository von J. Marques (IST Lissabon)	Direktdownload / <code>git clone</code>	Zitierpflicht

Alle in dieser Übersicht genannten Datensätze sind für den akademischen Gebrauch grundsätzlich zugänglich; die formalen Anforderungen unterscheiden sich jedoch erheblich hinsichtlich Aufwand und Bearbeitungszeit. Für die weitere Bearbeitung in Aufgabe 4 wurde sichergestellt, dass die im nächsten Abschnitt als Primär- und Sekundärdatensätze ausgewählten Ressourcen ohne administrative Verzögerungen zur Verfügung stehen.

4.4 Begründete Entscheidung

Auf Basis der oben aufgeführten Kriterien wird **SisFall** als primärer Datensatz für die Modellentwicklung in Aufgabe 4 ausgewählt. Die Gründe für diese Wahl lassen sich wie folgt zusammenfassen:

1. Die **6-Achsen-Konfiguration** stimmt mit der in Kapitel 2 begründeten Empfehlung überein.
2. Der **Messbereich** von ± 16 g bietet den in Abschnitt 3.1 diskutierten Sicherheitspuffer

gegen Clipping, insbesondere für periphere Körperpositionen.

3. Die **hohe Abtastrate** von 200 Hz erlaubt ein Downsampling auf den in Abschnitt 3.2 empfohlenen Bereich (20–50 Hz) ohne Informationsverlust.
4. Die **große Probandenzahl** (38, davon 15 Ältere) und die Vielfalt an Sturz- und ADL-Typen (15 bzw. 19) ermöglichen eine belastbare probandenübergreifende Validierung.
5. Der **etablierte Benchmarkstatus** in der Literatur stellt sicher, dass die eigenen Ergebnisse unmittelbar mit publizierten Arbeiten verglichen werden können.

Als ergänzender Datensatz bietet sich **KFall** an, da er eine vergleichbare Sensorik, eine ausreichende Abtastrate und insbesondere die zeitliche Pre-Impact-Annotation liefert, die für zukünftige Erweiterungen des Modells relevant sein kann.

5 Verlauf der Modellentwicklung (Aufgabe 4 Zwischenstand)

Die vorausgehenden Kapitel haben die theoretischen Grundlagen gelegt: Kapitel 2 begründet die Wahl einer 6-Achsen-IMU, Kapitel 3 leitet den empfohlenen Arbeitspunkt ab (± 16 g, 20–50 Hz, ≥ 12 Bit) und Kapitel 4 wählt SisFall als primären Datensatz. Das vorliegende Kapitel dokumentiert den bisherigen Verlauf der praktischen Modellentwicklung im Rahmen von Aufgabe 4 und stellt die ersten quantitativen Ergebnisse vor. Sämtliche Experimente wurden mit Python 3.12 unter Verwendung von NumPy, SciPy, scikit-learn und TensorFlow/Keras durchgeführt. Der vollständige Quellcode ist im begleitenden Repository verfügbar.

5.1 Datenaufbereitung

Als Trainingsdatensatz dient SisFall [16] mit 4505 Aufzeichnungen (2707 ADL, 1798 simulierte Stürze) von 38 Probanden. Die Rohdaten liegen als kommaseparierte Textdateien mit neun Spalten vor (zwei Beschleunigungssensoren und ein Gyroskop, jeweils als ADC-Rohwerte). Für die Modellentwicklung werden ausschließlich die Kanäle des ADXL345 (± 16 g) und des ITG3200 ($\pm 2000^\circ/\text{s}$) verwendet, da sie der in Kapitel 3 empfohlenen Spezifikation entsprechen und zugleich mit dem für den Prototyp vorgesehenen MPU-6050 kompatibel sind. Die ADC-Rohwerte werden anhand der Herstellerkonstanten in physikalische Einheiten umgerechnet:

$$a [\text{g}] = \text{raw} \cdot \frac{2 \cdot 16}{2^{13}}, \quad \omega [^\circ/\text{s}] = \text{raw} \cdot \frac{2 \cdot 2000}{2^{16}}. \quad (5.1)$$

Anschließend wird das Signal von der ursprünglichen Abtastrate (200 Hz) auf die Zielrate (50 Hz) heruntergetastet. Die Segmentierung erfolgt in gleitenden Fenstern der Länge 2 s mit 50 % Überlappung. Bei Sturzaufzeichnungen wird das Fenster auf den Zeitpunkt des maximalen Beschleunigungsbetrags (Impact) zentriert, um sicherzustellen, dass das Klassifikationsziel tatsächlich die sturzrelevante Signatur enthält und nicht einen beliebigen ruhigen Abschnitt derselben Aufnahme. Die resultierenden Fenster haben die Dimension 100×6 (100 Abtastwerte $\times$ 6 Kanäle).

5.2 Modell 1: Schwellwert-Baseline

Als erste Referenz dient ein klassischer Schwellwertalgorithmus nach Bourke [1]: Ein Fenster wird genau dann als Sturz klassifiziert, wenn der Betrag der Beschleunigung sowohl einen unteren Freifall-Schwellwert von 0,6 g unterschreitet als auch einen oberen Impact-Schwellwert von 2,0 g überschreitet. Dieser Algorithmus benötigt weder Training noch Merkmalsextraktion und bildet damit die einfachste realisierbare Baseline.

Ergebnis: Sensitivität 96,7 %, Spezifität 76,8 %, Genauigkeit 77,5 %. Die hohe Sensitivität

bestätigt, dass das Schwellwertverfahren die meisten Stürze erkennt. Die niedrige Spezifität zeigt jedoch das in Kapitel 2 diskutierte Kernproblem: Sturzähnliche Alltagsaktivitäten wie schnelles Hinsetzen lösen ebenfalls Alarm aus.

5.3 Modell 2: Random Forest mit Magnitude-Features

Um die Spezifität zu verbessern, werden aus jedem Fenster 18 rotationsinvariante Merkmale extrahiert, die ausschließlich auf dem Betrag (SVM) der Beschleunigung und der Winkelgeschwindigkeit basieren. Zu den Merkmalen zählen unter anderem Mittelwert, Standardabweichung, Maximum, Minimum, Spannweite, RMS-Wert, Energie, Schiefe, Kurtosis, Jerk-Standardabweichung und Signal Magnitude Area. Die bewusste Beschränkung auf Betragsgrößen macht die Merkmale weitgehend unabhängig von der Orientierung des Sensors am Körper und trägt damit zur Robustheit gegenüber dem in Abschnitt 5.7 diskutierten Positionswechsel bei.

Ein Random-Forest-Klassifikator mit 200 Bäumen und balancierter Klassengewichtung wird mittels subjektunabhängiger Kreuzvalidierung (GroupKFold, 5 Folds) bewertet, wobei die Gruppierungsvariable der Proband ist. Damit wird sichergestellt, dass keine Daten desselben Probanden gleichzeitig in Training und Test auftreten.

Ergebnis: Sensitivität 94,2 %, Spezifität 99,6 %, Genauigkeit 99,4 %. Die Spezifität steigt gegenüber der Schwellwert-Baseline von 76,8 % auf 99,6 %, was die Anzahl falsch-positiver Alarme um den Faktor 50 reduziert. Die Feature-Importance-Analyse des Random Forest bestätigt die Schlussfolgerung aus Kapitel 2: Vier der fünf wichtigsten Merkmale basieren auf dem Gyroskop (`gyr_std`, `gyr_max`, `gyr_energy`, `gyr_rms`), was den Beitrag der sechsten Achse zur Falsch-Positiv-Reduktion quantitativ belegt.

5.4 Modell 3: 1D-CNN

Als drittes und leistungsfähigstes Modell wird ein eindimensionales Convolutional Neural Network (1D-CNN) trainiert, das direkt auf den rohen 6-Kanal-Fenstern (100×6) arbeitet und keine handgefertigte Merkmalsextraktion benötigt. Die Architektur umfasst drei Faltungsblöcke mit aufsteigender Filterzahl (32, 64, 128), jeweils gefolgt von Batch-Normalisierung und Max-Pooling, sowie einen Global-Average-Pooling-Kopf und zwei vollvernetzte Schichten mit Dropout ($p = 0,3$). Das Modell wird mit dem Adam-Optimierer (Lernrate 10^{-3}), binärer Kreuzentropie und klassenbalancierten Gewichten über 30 Epochen trainiert.

Die Bewertung erfolgt auf einem subjektunabhängigen Testsplit (25 % der Probanden, 10 Subjekte, insgesamt 13 031 Fenster).

Ergebnis: Sensitivität 98,0 %, Spezifität 99,7 %, Genauigkeit 99,6 %. Im Vergleich zum Random Forest sinkt die Anzahl übersehener Stürze von 105 auf 18 (False Negatives), während die Anzahl der Fehlalarme von 215 auf 39 (False Positives) zurückgeht. Das Modell umfasst 45 601 Parameter (178 KB) und konvergiert innerhalb von 30 Epochen ohne Anzeichen von Overfitting, wie die Trainingskurven in Abbildung ?? belegen.

5.5 Vergleich der drei Modelle

Tabelle 5.1 fasst die Ergebnisse zusammen.

Table 5.1: Vergleich der drei Sturzerkennungsmodelle auf SisFall (subjektunabhängig).

Modell	Sensitivität	Spezifität	Genauigkeit	FP	FN
Schwellwert (Bourke)	96,7 %	76,8 %	77,5 %	11 503	59
Random Forest	94,2 %	99,6 %	99,4 %	215	105
1D-CNN	98,0 %	99,7 %	99,6 %	39	18

Der stufenweise Aufbau zeigt, dass jedes nachfolgende Modell den vorhergehenden Schwachpunkt adressiert: Der Random Forest behebt die niedrige Spezifität der Schwellwertmethode, und das 1D-CNN verbessert zusätzlich die Sensitivität bei gleichzeitig nochmals reduzierter Fehlalarmrate.

5.6 TFLite-Export für den Mikrocontroller

Für den Einsatz auf dem ESP32-C6 wird das trainierte Keras-Modell mittels des TensorFlow-Lite-Konverters in ein vollständig int8-quantisiertes Modell überführt. Die Quantisierung verwendet einen repräsentativen Kalibrierungsdatensatz aus 200 zufällig gewählten Trainingsfenstern. Das resultierende `.tflite`-Modell hat eine Größe von lediglich **64 KB** und passt damit problemlos in den 4 MB großen Flash-Speicher des ESP32-C6. Die Inferenzzeit für ein einzelnes Fenster wird auf dem Zielprozessor im Bereich weniger Millisekunden erwartet, sodass eine Echtzeitklassifikation bei der gewählten Abtastrate (50 Hz, Fenster alle 1 s) gewährleistet ist.

5.7 Domänenlücke und Mitigationsstrategien

Der SisFall-Datensatz wurde mit einer am Gürtel (Hüfte) getragenen Sensoreinheit aufgenommen, während das Zielsystem eine schuhsohlenintegrierte Anbringung vorsieht. Diese Positionänderung stellt die wesentliche Domänenlücke dar, da sich die Kinematik der Fußbewegung grundlegend von der des Rumpfes unterscheidet: Beim Gehen erzeugt der Fersenaufsatz (Heel Strike) Beschleunigungsspitzen, die denen eines leichten Stoßereignisses ähneln und somit die Falsch-Positiv-Rate erhöhen können.

Um die Übertragbarkeit zu verbessern, wurden bereits in der aktuellen Pipeline mehrere Maßnahmen umgesetzt:

1. **Rotationsinvariante Merkmale:** Die Random-Forest-Features basieren ausschließlich auf Betragsgrößen (SVM), die unabhängig von der Orientierung des Sensors sind.
2. **Per-Window-Normalisierung:** Jedes Fenster wird vor der Eingabe in das CNN auf Mittelwert 0 und Standardabweichung 1 normiert, wodurch positionsabhängige Gleichanteile (z. B. unterschiedliche Gravitationsprojektion) eliminiert werden.

3. **Subjektunabhängige Validierung:** Die Aufteilung nach Probanden stellt sicher, dass die berichteten Kennzahlen nicht durch probandenspezifische Muster überschätzt werden.

Für die verbleibende Domänenlücke ist ein *Pilot-Fußdatensatz* geplant: Mit dem für den Prototyp vorgesehenen MPU-6050 auf dem ESP32-C6 werden Daten direkt am Fuß aufgezeichnet (Gehen, Laufen, Treppensteigen, Hinsetzen sowie simulierte Stürze auf eine Matte). Anschließend werden die letzten Schichten des trainierten CNN mittels Transfer Learning auf diesen Datensatz feinabgestimmt (Fine-Tuning). Um die Wirksamkeit dieses Vorgehens bereits vor Verfügbarkeit der eigenen Hardware zu überprüfen, wurde der UMAFall-Knöcheldatensatz [26] als Zwischenschritt herangezogen; die Ergebnisse sind in Abschnitt 5.8 dargestellt.

5.8 Cross-Position-Transfer: Quantifizierung der Domänenlücke

5.8.1 Motivation und Versuchsaufbau

Die in Abschnitt 5.7 beschriebene Domänenlücke wurde bislang lediglich argumentativ begründet. Um sie *quantitativ* zu erfassen, wurde ein Transferexperiment durchgeführt. Als Zielposition dient der Knöchelsensor des UMAFall-Datensatzes [26], da dieser unter allen öffentlich verfügbaren Sturzdatensätzen die größte Nähe zur geplanten Sohlenposition aufweist. Ein fußsohlenbasierter öffentlicher Datensatz existiert nach derzeitigem Kenntnisstand nicht; diese Lücke in der Literatur ist zugleich ein wesentliches Alleinstellungsmerkmal des vorliegenden Projekts.

UMAFall verwendet fünf gleichzeitig getragene Sensoren, deren Zuordnung (Sensor-ID zu Körperposition) im Dateikopf jeder Aufnahme dokumentiert ist. Diese Zuordnung ist *nicht* über alle Dateien identisch, weshalb sie bei der Auswertung dateiweise ausgelesen wird. Aus den Aufzeichnungen wurden ausschließlich die Kanäle des Knöchelsensors extrahiert, Beschleunigungs- und Gyroskopströme zeitlich synchronisiert und von der nativen Abtastrate (20 Hz) auf die Eingangsrate des Modells (50 Hz) hochgetastet. Die Fensterung erfolgte analog zur SisFall-Pipeline. Insgesamt standen 6800 Fenster von 19 Probanden zur Verfügung (471 Stürze, 6329 ADL).

Ergänzend wurde derselbe Transfer auf KFall [27] angewendet (unterer Rücken, 100 Hz, 32 Probanden, 15 Sturzarten, 5075 Aufnahmen). KFall dient dabei als Gegenprobe: Da sich dieser Datensatz in Probandenkollektiv, Sensorhardware und Protokoll ebenso deutlich von SisFall unterscheidet wie UMAFall, jedoch eine deutlich höhere Aufnahmequalität aufweist, lässt sich unterscheiden, ob ein beobachteter Leistungsabfall dem Datensatzwechsel an sich oder den spezifischen Eigenschaften eines Datensatzes zuzuschreiben ist.

Bei der Aufbereitung von KFall wurde die Zuordnung der Aufgaben-IDs zu den Klassen (T01–T21 = ADL, T22–T36 = Sturz) nicht aus der Dokumentation übernommen, sondern empirisch überprüft: Der Median der Spitzenbeschleunigung steigt exakt ab T22 sprunghaft an (1,84 g gegenüber 4,62 g), was die angenommene Grenze bestätigt. Bemerkenswert ist dabei eine

deutliche Überlappung der Wertebereiche – einzelne ADL-Aufgaben (T20: 4,49 g) erreichen höhere Spitzenwerte als einzelne Sturzarten (T35: 2,23 g). Dies belegt unmittelbar, weshalb rein schwellwertbasierte Verfahren keine hohe Spezifität erreichen können, und begründet den Einsatz von Modellen, die den gesamten zeitlichen Verlauf auswerten.

Es wurden zwei Bedingungen verglichen:

- **Zero-Shot:** Das unverändert auf SisFall (Hüfte) trainierte 1D-CNN wird ohne jede Anpassung auf die Knöcheldata angewendet.
- **Fine-Tuning:** Die vorderen Faltungsblöcke werden eingefroren, die übrigen Schichten mit kleiner Lernrate (10^{-4}) auf einem Teil der Knöcheldata nachtrainiert. Die Bewertung erfolgt subjektunabhängig auf demselben Testsplit wie im Zero-Shot-Fall, sodass beide Bedingungen direkt vergleichbar sind.

5.8.2 Ergebnisse

Tabelle 5.2 und Abbildung 5.1 fassen die Ergebnisse zusammen.

Table 5.2: Ergebnisse aller Transferexperimente. Alle Werte auf subjektunabhängigen Testsplits; Fine-Tuning mit 60 Epochen.

Datensatz	Position	Bedingung	Sensit.	Spezif.	Genauigk.
SisFall (Referenz, 50 Hz)	Hüfte	Test	98,0 %	99,7 %	99,6 %
SisFall (20 Hz)	Hüfte	Test	96,8 %	99,3 %	99,1 %
KFall	unt. Rücken	Zero-Shot	83,5 %	94,9 %	91,7 %
		Fine-Tuned	96,4 %	96,9 %	96,8 %
UMAFall	Taille	Zero-Shot	42,2 %	97,4 %	92,6 %
		Fine-Tuned	92,2 %	97,3 %	96,9 %
UMAFall	Knöchel	Zero-Shot	34,8 %	92,2 %	88,5 %
		Fine-Tuned	80,1 %	94,7 %	93,8 %
UMAFall (20 Hz)	Knöchel	Zero-Shot	34,0 %	95,6 %	91,6 %
		Fine-Tuned	78,0 %	95,0 %	93,9 %
FallAllID	Taille	Zero-Shot	13,6 %	98,8 %	97,5 %
		Fine-Tuned	84,6 %	98,7 %	98,5 %




Figure 5.1: Sensitivität und Spezifität des SisFall-Modells auf den UMAFall-Knöcheldaten vor und nach dem Fine-Tuning.

5.8.3 Kreuzvalidierung auf FallAlID

Als dritter externer Datensatz wurde FallAlID [28] herangezogen. Dieser zeichnet sich durch eine hohe native Abtastrate von 238 Hz, 35 Sturztypen und drei simultane Sensorpositionen (Nacken, Handgelenk, Taille) aus. Für den Transferversuch wurde ausschließlich der Tail-lensensor (Device 3) verwendet, da diese Position der Hüftposition von SisFall am nächsten kommt. Die Rohdaten liegen als separate Dateien für Beschleunigung und Drehrate vor (LSM9DS1-Sensor, Umrechnung: $ACC = raw \times 0,000244 \text{ g}$, $GYR = raw \times 0,07^\circ/\text{s}$).

Verglichen mit den vorangegangenen Transferversuchen liefert FallAlID ein überraschendes Ergebnis: Obwohl die Abtastrate (238 Hz) höher ist als bei jedem anderen hier betrachteten Datensatz, fällt die Zero-Shot-Sensitivität auf lediglich 13,6 % – deutlich unter dem KFall-Ergebnis (83,5 %) und sogar unter dem UMAFall-Ergebnis (42,2 %). Fine-Tuning hebt die Sensitivität auf 84,6 % bei einer Spezifität von 98,7 %, was zeigt, dass die Daten ausreichend Information für die Sturzerkennung enthalten.

Kontrollexperiment: Clipping bei $\pm 8 \text{ g}$

Der LSM9DS1-Sensor in FallAlID misst mit einem Bereich von $\pm 8 \text{ g}$, während SisFall ($\pm 16 \text{ g}$) und KFall ($\pm 16 \text{ g}$) den doppelten Bereich abdecken. Um zu prüfen, ob das *Clipping* hoher Beschleunigungsspitzen durch den eingeschränkten Messbereich den Zero-Shot-Einbruch verursacht, wurde ein Kontrollexperiment durchgeführt: Die SisFall-Testdaten wurden synthetisch bei $\pm 8 \text{ g}$, $\pm 4 \text{ g}$ und $\pm 2 \text{ g}$ begrenzt und erneut evaluiert.

Table 5.3: Clipping-Experiment: Sensitivität des SisFall-Modells bei synthetischer Begrenzung des Beschleunigungsbereichs.

Bereich	Sensit.	Spezif.	Genauigk.
± 16 g (Original)	98,7 %	99,0 %	99,0 %
± 8 g	98,7 %	99,0 %	99,0 %
± 4 g	98,3 %	99,3 %	99,3 %
± 2 g	98,0 %	99,9 %	99,8 %

Das Ergebnis ist eindeutig: Die Begrenzung auf ± 8 g verändert die Klassifikationsleistung nicht, da nur 0,5 % aller SisFall-Fenster überhaupt Spitzenwerte oberhalb von 8 g aufweisen. Selbst bei ± 2 g sinkt die Sensitivität lediglich um 0,7 Prozentpunkte. Der eingeschränkte Messbereich des LSM9DS1 scheidet damit als Ursache für den Zero-Shot-Einbruch aus.

Ursachenanalyse

Die Kombination aus hoher Abtastrate, ausreichendem Messbereich *und* dennoch niedrigem Zero-Shot-Ergebnis legt nahe, dass die sensorspezifischen Signalcharakteristiken den Transfererfolg maßgeblich beeinflussen. Unterschiedliche Sensoren erzeugen unterschiedliche Signalformen desselben physikalischen Ereignisses, bedingt durch Unterschiede in der internen Filterung, der Rauschcharakteristik und der Ansprechzeit. Das CNN erlernt diese hardware-spezifischen Muster, die sich beim Wechsel der Hardware nicht übertragen. Der Erfolg des Fine-Tunings (84,6 %) bestätigt, dass die relevanten physikalischen Informationen vorhanden sind – sie sind lediglich in einer Form kodiert, die das auf ADXL345/ITG3200-Daten trainierte Modell nicht unmittelbar erkennt.

Tabelle 5.4 fasst die Einflussfaktoren über alle drei externen Datensätze zusammen.

Table 5.4: Einflussfaktoren auf den Zero-Shot-Transfer. Der Erfolg hängt nicht von einem einzelnen Faktor ab, sondern von der Gesamtheit der Domänenunterschiede.

Datensatz	Hz	Bereich	Sensor	ZS-Se	FT-Se
KFall	100	± 16 g	Xsens MTw	83,5 %	96,4 %
UMAFall	20	± 16 g	SensorTag	42,2 %	92,2 %
FallAllID	238	± 8 g	LSM9DS1	13,6 %	84,6 %

5.8.4 Falsch-Positiv-Test auf fußnahen Alltagsdaten

Alle bisherigen Transferversuche bewerten die Sensitivität, also die Fähigkeit, Stürze zu erkennen. Für den praktischen Einsatz ist jedoch die Falsch-Positiv-Rate mindestens ebenso entscheidend: Ein System, das bei jedem zweiten Schritt Alarm auslöst, ist unbrauchbar, unabhängig von seiner Sensitivität.

Vorbemerkung zur Smart Insole Database

Ursprünglich war für diesen Test die Smart Insole Database (Datensatz `tg0uk/Smart_Insole_Database`) vorgesehen, da sie als einzige öffentliche Quelle Bewegungsdaten direkt aus einer Schuhsohle enthält. Die Prüfung der veröffentlichten Dateien ergab jedoch, dass diese entgegen der Angabe in der Dokumentation *keine* IMU-Kanäle enthalten. Jede der 30 Dateien (fünf Probanden $\times$ sechs Aktivitäten) umfasst ausschließlich 38 CapSense-Druckelektroden sowie die Bodenreaktionskräfte der Kraftmessplatte (F_x , F_y , F_z). Beschleunigungs- und Drehratenkanäle fehlen vollständig. Der Datensatz ist damit für die vorliegende Fragestellung nicht verwendbar.

Dies ist der vierte im Projektverlauf dokumentierte Fall, in dem eine Quellenangabe von den tatsächlichen Daten abweicht, und bestätigt das methodische Prinzip, Spezifikationen grundsätzlich gegen die Primärdaten zu prüfen.

Als nächstbeste fußnahe Quelle wurden daher die UMAFall-Knöcheldaten herangezogen, beschränkt auf ADL-Aufzeichnungen.

Versuchsaufbau und Ergebnis

Das auf SisFall trainierte CNN wurde ohne Anpassung auf sämtliche ADL-Aufzeichnungen der UMAFall-Knöchelposition angewendet (6329 Fenster, entsprechend rund 1,76 Stunden Aufzeichnungszeit). Da keine Stürze enthalten sind, ist jede positive Klassifikation per Definition ein Fehlalarm.

Table 5.5: Falsch-Positiv-Rate nach Aktivität (Entscheidungsschwelle 0,5), UMAFall-Knöchelposition, ausschließlich ADL-Aufzeichnungen.

Aktivität	Fenster	FP	Rate	max. p
Joggen	259	46	17,76 %	1,000
Tür öffnen	563	32	5,68 %	1,000
Gehen	713	38	5,33 %	1,000
Treppe abwärts	259	12	4,63 %	1,000
Treppe aufwärts	255	8	3,14 %	1,000
Hinlegen (Bett)	624	18	2,88 %	1,000
Arme heben	567	13	2,29 %	1,000
Telefonieren	610	11	1,80 %	1,000
Sitzen/Aufstehen	699	11	1,57 %	1,000
Hüpfen	584	8	1,37 %	0,996
Bücken	648	8	1,23 %	1,000
Klatschen	548	3	0,55 %	0,996
Gesamt	6329	208	3,29 %	—

Bei einer Gesamtrate von 3,29 % entspricht dies hochgerechnet rund 118 Fehlalarmen pro Stunde ununterbrochener Aufzeichnung. Ein solches System wäre im Alltag nicht einsetzbar.

Aufschlussreich ist die Verteilung: Die höchsten Raten treten bei *Joggen* (17,76 %), *Gehen*

(5,33 %) und *Treppensteigen* auf – also genau bei jenen Aktivitäten, bei denen der Fuß wiederholt auf den Boden aufschlägt. Der Fersenauftritt erzeugt am Knöchel einen kurzen, steilen Beschleunigungsimpuls, der dem Aufprallereignis eines Sturzes an der Hüfte formal ähnelt. Das Modell erkennt dieses Muster korrekt als Impact – die Zuordnung zur Klasse „Sturz“ ist jedoch im fußnahen Kontext falsch.

Bemerkenswert ist ferner, dass die maximale Klassenwahrscheinlichkeit in fast allen Aktivitäten bei 1,000 liegt. Das Modell ist sich seiner Fehlklassifikation also nicht etwa unsicher, sondern maximal zuversichtlich. Eine bloße Anhebung der Entscheidungsschwelle löst das Problem daher nicht vollständig.

5.8.5 Progressives Fine-Tuning

Die vorangegangenen Experimente zeigen, dass Fine-Tuning die Domänenlücke zuverlässig schließt. Offen bleibt, ob die *Reihenfolge* der Anpassungsschritte eine Rolle spielt. Für den Einsatz in der Insole ist dies unmittelbar relevant: Sollte das Modell direkt von SisFall auf die Fußdaten angepasst werden, oder empfiehlt sich ein Zwischenschritt über einen weiteren Sturzdatensatz?

Verglichen wurden drei Strategien auf einem *identischen*, subjektunabhängigen Testsatz der UMAFall-Knöcheldaten:

Table 5.6: Vergleich der Transferstrategien auf identischem Testsatz (UMAFall, Knöchel). Alle Werte subjektunabhängig.

	Strategie	Sensit.	Spezif.	Genauigk.
A	Zero-Shot (SisFall)	30,6 %	96,0 %	94,8 %
B	Direkt: SisFall → UMAFall	33,3 %	95,2 %	94,1 %
C1	Zwischenstand nach KFall-Stufe	22,2 %	96,0 %	94,7 %
C2	Progressiv: SisFall → KFall → UMAFall	75,0 %	97,8 %	97,4 %

Das progressive Vorgehen übertrifft die direkte Anpassung um 41,7 Prozentpunkte Sensitivität, bei gleichzeitig *höherer* Spezifität (97,8 % gegenüber 95,2 %).

Besonders aufschlussreich ist der Zwischenstand C1: Nach der KFall-Stufe allein *sinkt* die Sensitivität auf den UMAFall-Knöcheldaten von 30,6 % auf 22,2 %. Die Zwischenstufe verbessert die unmittelbare Leistung also nicht – sie verschlechtert sie sogar. Erst der darauffolgende Anpassungsschritt profitiert erheblich von ihr.

Eine plausible Erklärung liefert die Betrachtung der gelernten Merkmalsrepräsentation: Ein ausschließlich auf SisFall trainiertes Modell kodiert Stürze in der spezifischen Signalfom des ADXL345/ITG3200. Die KFall-Stufe konfrontiert es mit einer zweiten, davon abweichenden Ausprägung desselben physikalischen Ereignisses. Die resultierende Repräsentation ist allgemeiner und damit leichter an eine dritte Domäne anpassbar, auch wenn sie für keine der beiden Ausgangsdomänen optimal ist.

Anmerkung: Die Absolutwerte in Tabelle 5.6 weichen von denen in Tabelle 5.2 ab, da hier ein anderer Datenaufteilungs-Seed und ein einheitliches Fine-Tuning-Protokoll für alle drei Strategien verwendet wurde. Für den hier angestellten Vergleich ist dies unerheblich, da alle drei Strategien auf demselben Testsatz und mit identischen Hyperparametern bewertet wurden.

5.8.6 Zeitliche Plausibilisierung durch N-von-M-Voting

Der Falsch-Positiv-Test (Abschnitt 5.8.4) zeigt, dass eine Entscheidung auf Basis eines einzelnen Fensters für den praktischen Einsatz ungeeignet ist. Naheliegend ist daher eine zeitliche Plausibilisierung: Ein Alarm wird erst ausgelöst, wenn innerhalb der letzten M Entscheidungen mindestens N positiv ausfallen. Die zugrundeliegende Annahme lautet, dass ein Sturz aufgrund seiner Dauer mehrere aufeinanderfolgende positive Fenster erzeugt, ein einzelner Fersenauftritt hingegen nur ein isoliertes.

Einfluss der Fensterschrittweite

Ein erster Versuch mit der bislang verwendeten Schrittweite von 1,0 s (50 % Überlappung) ließ die Sensitivität bereits bei der Regel *3-von-3* auf null fallen. Die Ursache liegt in der Fensterung selbst: Bei einer Aufprallphase von 50–100 ms und einer Schrittweite von 1,0 s liegt das Aufprallereignis in nur einem einzigen Fenster. Aufeinanderfolgende positive Fenster können konstruktionsbedingt gar nicht entstehen, sodass jede Regel mit $N \geq 2$ zwangsläufig scheitern muss.

Die Schrittweite wurde daher auf 0,2 s (90 % Überlappung) reduziert. Das Aufprallereignis erscheint dann in bis zu zehn aufeinanderfolgenden Fenstern, wobei seine relative Position innerhalb des Fensters schrittweise wandert. Da das Modell auf impact-zentrierten Fenstern trainiert wurde, reagiert es am deutlichsten, wenn der Aufprall nahe der Fenstermitte liegt.

Ergebnis

Tabelle 5.7 stellt die Regeln für das unveränderte SisFall-Modell und für das auf Knöcheldaten feinabgestimmte Modell gegenüber (Entscheidungsschwelle jeweils 0,9, subjektunabhängiger Testsatz).

Table 5.7: N-von-M-Voting bei 0,2 s Schrittweite, Entscheidungsschwelle 0,9. Se bezeichnet den Anteil der Sturzaufzeichnungen, in denen mindestens einmal Alarm ausgelöst wurde; FP/Std die Fehlalarme pro Stunde ADL-Aufzeichnung.

Regel	Basismodell		Feinabgestimmt	
	Se	FP/Std	Se	FP/Std
1-von-1	40,4 %	212,4	100,0 %	280,8
2-von-3	29,8 %	100,0	97,9 %	124,6
3-von-5	17,0 %	63,2	93,6 %	73,7
5-von-7	8,5 %	29,8	83,0 %	21,1
7-von-10	6,4 %	10,5	68,1 %	10,5

Für das feinabgestimmte Modell reduziert die Regel *5-von-7* die Fehlalarmrate von 1192 auf 21,1 pro Stunde – eine Verringerung um 98 % – bei einem Rückgang der Sensitivität von 100 % auf 83,0 %. Dies stellt für den vorgesehenen Einsatzzweck einen vertretbaren Kompromiss dar.

Voting ersetzt keine Domänenanpassung

Der Vergleich beider Modellspalten in Tabelle 5.7 führt zu einem Befund, der über die reine Parameterwahl hinausgeht. Beim Übergang von *1-von-1* zu *5-von-7* verliert das Basismodell 78 % seiner Sensitivität (40,4 % auf 8,5 %), das feinabgestimmte Modell hingegen nur 17 % (100 % auf 83,0 %).

Die Erklärung liegt in der zeitlichen Struktur der Ausgaben. Ein nicht angepasstes Modell erzeugt auf fremden Daten *vereinzelte*, zeitlich unzusammenhängende Positivmeldungen; diese werden durch die Voting-Regel systematisch verworfen. Ein domänenangepasstes Modell erzeugt dagegen einen *zusammenhängenden* Block positiver Fenster um das Aufprallereignis, der die Regel zuverlässig passiert.

Die zeitliche Plausibilisierung ist damit kein Ersatz für die Domänenanpassung, sondern setzt diese voraus. Für die Firmware ergibt sich daraus eine klare Reihenfolge: zuerst Fine-Tuning auf Fußdaten, danach Voting zur Unterdrückung der verbleibenden Fehlalarme.

5.8.7 Hard-Negative-Training

Da die Fehlalarme überwiegend bei Aktivitäten mit wiederholtem Bodenkontakt auftreten, lag die Vermutung nahe, diese Fenster im Training gezielt höher zu gewichten. Getestet wurde eine Gewichtung mit Faktor 3,0 für alle ADL-Fenster mit einer Spitzenbeschleunigung oberhalb von 1,8 g – dies betraf 1401 Fenster beziehungsweise 32,9 % aller ADL-Fenster.

Table 5.8: Wirkung der Hard-Negative-Gewichtung (Regel 2-von-3, Schwelle 0,9).

Variante	Sensit.	FP/Std
Basismodell (SisFall, ohne Anpassung)	6,4 %	10,4
Fine-Tuning ohne Gewichtung	72,3 %	13,9
Fine-Tuning mit Hard Negatives	63,8 %	13,9

Die Gewichtung erzielte nicht die erhoffte Wirkung: Die Fehlalarmrate blieb unverändert, während die Sensitivität um 8,5 Prozentpunkte zurückging. Der Ansatz wird daher nicht weiterverfolgt.

Aufschlussreich ist gleichwohl der Vergleich der ersten beiden Zeilen: Das schlichte Fine-Tuning hebt die Sensitivität von 6,4 % auf 72,3 %. Die Domänenanpassung selbst ist damit um ein Vielfaches wirksamer als jede der hier untersuchten Zusatzmaßnahmen.

5.8.8 Interpretation

Die Kombination der Experimente – einschließlich des FallAllD-Versuchs und des zugehörigen Clipping-Kontroll-experiments – erlaubt eine differenziertere Aussage, als sie aus einem einzelnen Transferversuch ableitbar gewesen wäre.

Erstens gelingt der Transfer zwischen qualitativ hochwertigen Datensätzen gut – aber nur bei ähnlicher Sensorhardware. Auf KFall erreicht das unveränderte SisFall-Modell ohne jede Anpassung eine Sensitivität von 83,5 % bei einer Spezifität von 94,9 % – und das, obwohl sich Probandenkollektiv (Südkorea statt Kolumbien), Sensorhardware (Xsens MTw Awinda statt ADXL345/ITG3200) und Aufnahmeprotokoll vollständig unterscheiden. FallAllD hingegen erreicht bei noch höherer Abtastrate (238 Hz) nur 13,6 %. Das Clipping-Kontroll-experiment (Abschnitt 5.8.3) schließt den Messbereich (± 8 g) als Ursache aus. Der entscheidende Unterschied liegt daher in den sensorspezifischen Signalcharakteristiken des LSM9DS1 gegenüber dem ADXL345/ITG3200.

Zweitens ist die native Abtastrate ein notwendiger, aber kein hinreichender Faktor. UMAFall zeigt, dass eine zu niedrige native Abtastrate (20 Hz) den Transfer verhindert. FallAllD zeigt umgekehrt, dass eine hohe Abtastrate allein ihn nicht garantiert. Beide Ergebnisse zusammen ergeben: Guter Zero-Shot-Transfer erfordert sowohl eine ausreichende Abtastrate *als auch* eine hinreichend ähnliche Signalcharakteristik der Hardware.

Drittens bestätigt sich die Abtastratenempfehlung aus Kapitel 3, jedoch mit einer wichtigen Präzisierung. Eine Reduktion von 50 Hz auf 20 Hz kostet bei korrektem Heruntertasten lediglich rund einen Prozentpunkt Sensitivität (98,0 % auf 96,8 %). Die Empfehlung gilt jedoch *nur* für gefiltertes Heruntertasten, nicht für eine native Erfassung mit 20 Hz.

Viertens ist der reine Positionseffekt moderat. Innerhalb von UMAFall, also bei identischer Hardware und identischem Protokoll, kostet der Wechsel von der Taille zum Knöchel im Zero-Shot-Fall 7,4 Prozentpunkte (42,2 % auf 34,8 %) und nach dem Fine-Tuning 12,1 Prozentpunkte (92,2 % auf 80,1 %). Die Sensorposition ist damit ein realer, aber nicht der dominierende Faktor. Für das Vorhaben ist dies ein günstiger Befund, da er die grundsätzliche Machbarkeit der fußnahen Anbringung stützt.

Fünftens ist Transfer Learning in allen Konfigurationen wirksam, wobei der erforderliche Umfang mit der Ausgangsqualität skaliert: Auf KFall genügt eine Verbesserung um 12,9 Prozentpunkte (83,5 % auf 96,4 %), auf FallAllD sind es 71,0 Prozentpunkte (13,6 % auf 84,6 %). In keiner Konfiguration verschlechterte sich dabei die Spezifität.

Sechstens ist die Falsch-Positiv-Rate bei fußnaher Anbringung das kritischere Problem als die Sensitivität. Der Test auf fußnahen ADL-Daten (Abschnitt 5.8.4) ergibt ohne Anpassung 3,29 % Fehlalarme, konzentriert auf Aktivitäten mit wiederholtem Bodenkontakt (Joggen: 17,76 %, Gehen: 5,33 %). Da das Modell diese Fehlklassifikationen mit maximaler Konfidenz ($p = 1,000$) trifft, greift eine reine Anhebung der Entscheidungsschwelle zu kurz. Erforderlich sind stattdessen domänenspezifische Trainingsdaten sowie ergänzende Mechanismen wie eine zeitliche Mehrheitsentscheidung über mehrere aufeinanderfolgende Fen-

ster.

Siebtens ist die Reihenfolge der Anpassungsschritte entscheidend. Das progressive Fine-Tuning (Abschnitt 5.8.5) übertrifft die direkte Anpassung um 41,7 Prozentpunkte Sensitivität bei gleichzeitig höherer Spezifität. Bemerkenswert ist, dass die Zwischenstufe für sich genommen die Leistung *verschlechtert* (30,6 % auf 22,2 %) und ihr Nutzen sich erst im nachfolgenden Anpassungsschritt zeigt. Der Zwischenschritt wirkt demnach nicht als Leistungsverbesserung, sondern als Verallgemeinerung der gelernten Merkmalsrepräsentation.

Achtens ergänzen sich zeitliche Plausibilisierung und Domänenanpassung, ersetzen einander aber nicht. Die N-von-M-Regel *5-von-7* senkt die Fehlalarmrate des angepassten Modells um 98 % bei einem Sensitivitätsverlust von 17 Prozentpunkten (Abschnitt 5.8.6). Auf das nicht angepasste Modell angewendet, vernichtet dieselbe Regel jedoch 78 % der Sensitivität. Der Grund liegt in der zeitlichen Struktur der Modellausgaben: Nur ein domänenangepasstes Modell erzeugt um den Aufprall herum einen zusammenhängenden Block positiver Fenster, den die Regel passieren lässt. Für die Umsetzung folgt daraus eine feste Reihenfolge – erst Anpassung, dann Voting.

Ergänzend ist festzuhalten, dass eine gezielte Höhergewichtung impactstarker ADL-Fenster (Hard Negatives, Abschnitt 5.8.7) keine Verbesserung erbrachte. Die Domänenanpassung selbst erwies sich in allen Versuchen als die mit Abstand wirksamste Einzelmaßnahme.

5.8.9 Konsequenzen für den Prototyp

Aus den Experimenten ergeben sich zwei unmittelbar umsetzbare Vorgaben für die Firmware des ESP32-C6.

Erfassung mit hoher Rate und anschließendes Heruntertasten. Der Vergleich der beiden 20-Hz-Bedingungen zeigt, dass die *Art* der Ratenreduktion entscheidend ist. Der MPU-6050 ist daher mit einer Ausgangsdatenrate von mindestens 100 Hz zu betreiben; das integrierte digitale Tiefpassfilter (DLPF) ist zu aktivieren, und die Reduktion auf die Modelleingangsrate (20–50 Hz) erfolgt anschließend softwareseitig. Eine direkte Konfiguration des Sensors auf 20 Hz ist zu vermeiden, da sie denselben Informationsverlust verursachen würde, der bei UMAFall beobachtet wurde.

Erhebung eines Pilotdatensatzes ist zwingend erforderlich. Das FallAllD-Experiment verdeutlicht, dass selbst bei idealer Abtastrate und vergleichbarer Sensorposition ein Hardwarewechsel den Zero-Shot-Transfer auf unter 14 % Sensitivität drücken kann. Fine-Tuning hebt die Leistung zuverlässig an – auf KFall auf 96,4 %, auf FallAllD auf 84,6 % –, setzt aber Trainingsdaten der Zielhardware voraus. Da der MPU-6050 eine weitere, gegenüber allen betrachteten Datensätzen abweichende Sensorhardware *und* eine abweichende Sensorposition darstellt, ist die Anpassung an domänenspezifische Daten nicht optional, sondern Voraussetzung für ein einsatzfähiges System.

Konfiguration des Messbereichs. Das Clipping-Experiment zeigt, dass ± 8 g für die Sturzerkennung ausreichend sind; ein ± 16 g-Bereich bringt keinen messbaren Vorteil. Der MPU-

6050 sollte dennoch auf $\pm 16\text{g}$ konfiguriert werden, um Headroom für extreme Stürze zu gewährleisten und die Signalcharakteristik der SisFall-Trainingsdaten bestmöglich zu approximieren.

Trainingsstrategie: progressiv statt direkt. Aus Abschnitt 5.8.5 ergibt sich eine konkrete Handlungsanweisung für die Anpassung an die Zielhardware. Das Modell ist nicht unmittelbar von SisFall auf die Fußdaten anzupassen, sondern über eine Zwischenstufe:

$$\text{SisFall} \longrightarrow \text{KFall} \longrightarrow \text{Pilotdaten (Fuß, MPU-6050)}$$

Der Zwischenschritt kostet keinen zusätzlichen Aufwand bei der Datenerhebung, da KFall bereits vorliegt, verbessert die Anpassungsfähigkeit des Modells jedoch erheblich.

Mehrstufige Alarmauslösung mit konkreten Parametern. Aus Abschnitt 5.8.6 ergibt sich ein unmittelbar umsetzbarer Betriebspunkt für die Firmware:

Table 5.9: Firmware-Vorgaben für die Alarmlogik.

Parameter	Wert
Abtastrate des Sensors (ODR)	$\geq 100\text{ Hz}$, DLPF aktiv
Messbereich	$\pm 16\text{ g}$
Modelleingang	100×6 (2 s @ 50 Hz)
Inferenzintervall	200 ms
Ringpuffer für Entscheidungen	7
Entscheidungsschwelle	0,9
Alarmbedingung	≥ 5 von 7 positiv

Bei einem Inferenzintervall von 200 ms und einer geschätzten Inferenzzeit von etwa 10 ms ergibt sich eine Rechenlast von rund 5 % – der ESP32-C6 ist damit deutlich unterfordert, sodass ausreichend Reserven für Funkübertragung und Energiesparmodi verbleiben. Die konkrete Inferenzzeit ist nach der Hardware-Integration zu verifizieren.

5.9 Nächste Schritte

5.9.1 Einordnung der durchgeführten Kontrollexperimente

Die in den Abschnitten 5.8 bis 5.8.7 berichteten Experimente umfassen drei externe Datensätze (KFall, UMAFall, FallAllID), ein Clipping-Kontrollexperiment, einen Falsch-Positiv-Test auf fußnahen Alltagsdaten, einen Vergleich dreier Transferstrategien sowie zwei Versuche zur Verringerung der Fehlalarmrate.

Insgesamt wurden fünf Hypothesen widerlegt – die vermutete Dominanz der Sensorposition, die alleinige Erklärungskraft der Abtastrate, der Einfluss des Messbereichs, die Wirksamkeit einer Hard-Negative-Gewichtung sowie die Annahme, eine Einzelfensterentscheidung ließe sich unabhängig von der Fensterschrittweite plausibilisieren. Bestätigt wurden vier: die konsistente Wirksamkeit des Fine-Tunings, die dominierende Rolle sensorspezifischer Signalcharak-

teristiken beim Domänentransfer, der Vorteil eines progressiven gegenüber einem direkten Anpassungsvorgehen und die Wirksamkeit der zeitlichen Plausibilisierung – letztere allerdings nur in Verbindung mit einem domänenangepassten Modell.

5.9.2 Verbleibende Arbeitsschritte

Die folgenden Arbeitsschritte sind für den verbleibenden Projektzeitraum geplant:

1. **Hardware-Integration:** Aufbau des ESP32-C6 + MPU-6050 Prototyps, Portierung des int8-TF Lite-Modells mittels `esp-tflite-micro` oder Edge Impulse und Messung der On-Device-Inferenzzeit sowie des Energieverbrauchs.
2. **Pilotdatenerhebung am Fuß:** Aufzeichnung eines kleinen Fußdatensatzes (Gehen, Laufen, Treppen, Hinsetzen sowie simulierte Stürze auf Matte) zur Validierung und zum Fine-Tuning.
3. **Progressive Domänenanpassung:** Schrittweises Fine-Tuning des CNN: SisFall → KFall → Pilotdaten, um die Domänenlücke zwischen den öffentlichen Datensätzen und der Zielhardware systematisch zu schließen.
4. **Verifikation der Alarmlogik auf Zielhardware:** Die in Tabelle 5.9 festgelegten Parameter der Voting-Regel sind nach der Pilotdatenerhebung auf den tatsächlichen Fußdaten nachzujustieren, da sie bislang an UMAFall-Knöcheldaten bestimmt wurden.
5. **Long-Lie-Erkennung:** Implementierung einer zweiten Erkennungsstufe, die nach einem erkannten Sturz die Bewegungslosigkeit überwacht und bei anhaltender Liegeposition (> 60 s) einen Notfallalarm auslöst.

Bibliography

- [1] F. Bagalà, C. Becker, A. Cappello, L. Chiari, K. Aminian, J. M. Hausdorff, W. Zijlstra, and J. Klenk, “Evaluation of accelerometer-based fall detection algorithms on real-world falls,” *PLOS ONE*, vol. 7, no. 5, p. e37062, 2012.
- [2] A. Dinh, Y. Shi, D. Teng, A. Ralhan, L. Chen, V. D. Bui, H. Nguyen, D.-H. Le, W.-Y. Ko, K.-H. Ihn, and H. H. Nguyen, “A fall and near-fall assessment and evaluation system,” *Open Biomedical Engineering Journal*, vol. 3, pp. 1–7, 2009.
- [3] Q. T. Huynh, U. D. Nguyen, L. B. Irazabal, N. Ghassemian, and B. Q. Tran, “Optimization of an accelerometer and gyroscope-based fall detection algorithm,” *Journal of Sensors*, vol. 2015, p. Article ID 452078, 2015.
- [4] A. Hakim, M. S. Huq, S. Shanta, and B. S. K. K. Ibrahim, “Smartphone based data mining for fall detection: Analysis and design,” *Procedia Computer Science*, vol. 105, pp. 46–51, 2017.
- [5] A. Aggarwal *et al.*, “Fall detection using knowledge-distillation-based LSTM for offline embedded and low-power devices.” *arXiv preprint* arXiv:2308.12481, 2023.
- [6] P. Author, “Enhancing real-world fall detection using commodity devices: A systematic study,” *Sensors*, vol. 25, no. 17, p. 5249, 2025.
- [7] D. Roetenberg, H. J. Luinge, C. T. M. Baten, and P. H. Veltink, “Compensation of magnetic disturbances improves inertial and magnetic sensing of human body segment orientation,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 13, no. 3, pp. 395–405, 2005.
- [8] I. Weygers, M. Kok, M. Konings, H. Hallez, H. De Vroey, and K. Claeys, “Inertial sensor-based lower limb joint kinematics: A methodological systematic review,” *Sensors*, vol. 20, no. 3, p. 673, 2020.
- [9] S. Yang, M. Liu, W. Du, *et al.*, “NeurIT: Pushing the limit of neural inertial tracking for indoor robotic IoT.” *arXiv preprint* arXiv:2404.08939, 2024.
- [10] W. H. K. de Vries, H. E. J. Veeger, C. T. M. Baten, and F. C. T. van der Helm, “Magnetic distortion in motion labs, implications for validating inertial magnetic sensors,” *Gait & Posture*, vol. 29, no. 4, pp. 535–541, 2009.
- [11] InvenSense Inc. (TDK), “MPU-6000/MPU-6050 Product Specification, Revision 3.4,” tech. rep., InvenSense Inc., Sunnyvale, CA, USA, 2013. Datasheet number PS-MPU-6000A-00.
- [12] STMicroelectronics, “LSM6DSOX: iNEMO Inertial Module with Machine Learning

- Core,” tech. rep., STMicroelectronics, Geneva, Switzerland, 2020. Datasheet DS12140, Rev. 2.
- [13] Bosch Sensortec GmbH, “BHI360: Smart Sensor with Integrated IMU and On-Chip Sensor Fusion,” tech. rep., Bosch Sensortec GmbH, Reutlingen, Germany, 2023. Preliminary Datasheet.
- [14] Bulliot, B. and others, “Personal system for the detection of a risky situation and alert.” U.S. Patent 10,152,869, 2018. Cited for the widely used 0.6 g / 2.0 g fall threshold pair. Replace with a peer-reviewed source (e.g. Bourke) before final submission if preferred.
- [15] F. M. G. Cornelissen, R. Peeters, R. van der Straaten, C. E. E. M. van der Zee, A. De Brabandere, and B. Vanwanseele, “Evaluation of a restoration algorithm applied to clipped tibial acceleration signals,” *Sensors*, vol. 23, no. 10, p. 4747, 2023.
- [16] A. Sucerquia, J. D. López, and J. F. Vargas-Bonilla, “SisFall: A fall and movement dataset,” *Sensors*, vol. 17, no. 1, p. 198, 2017.
- [17] J. R. Villar, E. de la Cal, M. Fañez, V. M. González, and J. Sedano, “A study of the influence of the sensor sampling frequency on the performance of wearable fall detectors,” *Measurement*, vol. 193, p. 110945, 2022.
- [18] A. Díaz-Ramírez *et al.*, “The impact of the accelerometer sampling rate on the performance of machine and deep learning models in wearable fall-detection systems,” *Sensors*, vol. 26, no. 1, p. 162, 2026.
- [19] NXP Semiconductors, “AN4075 – The Trade-Off Between High Resolution and Low Power Consumption in MEMS Accelerometers,” tech. rep., NXP Semiconductors (formerly Freescale), 2013. Application note. Discusses effective number of bits in noise-limited MEMS accelerometers.
- [20] S. Arar, “Accelerometer specifications: Measurement range, sensitivity, and noise performance,” 2022. Technical article. Cited for the RMS-noise/bandwidth relation and the “10× noise floor” rule of thumb. Consider replacing with an appropriate NXP or ADI application note for the final submission.
- [21] M. Vagner, P. Beneš, and Z. Havránek, “MEMS gyroscope performance comparison using Allan variance method,” *Recent Researches in Applied Electrical Engineering*, pp. 199–204, 2011.
- [22] D. S. Ilcev, “Bias drift estimation for MEMS gyroscope used in inertial navigation,” *Geodesy and Cartography*, vol. 66, no. 1, pp. 61–79, 2017.
- [23] M. Ilyas, K.-S. Kim, J. Cho, and S. Park, “Strapdown inertial navigation systems for positioning mobile robots – MEMS gyroscopes random errors analysis using Allan variance method,” *Sensors*, vol. 20, no. 17, p. 4741, 2020.
- [24] G. Vavoulas, M. Pediaditis, E. G. Spanakis, and M. Tsiknakis, “The MobiFall dataset:

- An initial evaluation of fall detection algorithms using smartphones,” in *Proceedings of the 13th IEEE International Conference on BioInformatics and BioEngineering*, pp. 1–4, 2014.
- [25] G. Vavoulas, C. Chatzaki, T. Malliotakis, M. Pediaditis, and M. Tsiknakis, “The MobiAct dataset: Recognition of activities of daily living using smartphones,” in *Proceedings of the International Conference on Information and Communication Technologies for Ageing Well and e-Health (ICT4AWE)*, pp. 143–151, 2016.
- [26] E. Casilari, J. A. Santoyo-Ramón, and J. M. Cano-García, “UMAFall: A multisensor dataset for the research on automatic fall detection,” *Procedia Computer Science*, vol. 110, pp. 32–39, 2017.
- [27] X. Yu, J. Jang, and S. Xiong, “A large-scale open motion dataset (KFall) and benchmark algorithms for detecting pre-impact fall of the elderly using wearable inertial sensors,” *Frontiers in Aging Neuroscience*, vol. 13, p. 692865, 2021.
- [28] M. Saleh, M. Abbas, and R. Le Bouquin Jeannès, “FallAllD: An open dataset of human falls and activities of daily living for classical and deep learning applications,” *IEEE Sensors Journal*, vol. 21, no. 2, pp. 1849–1858, 2021.
- [29] D. Micucci, M. Mobilio, and P. Napoletano, “UniMiB SHAR: A dataset for human activity recognition using acceleration data from smartphones,” *Applied Sciences*, vol. 7, no. 10, p. 1101, 2017.
- [30] J. Marques, N. Bento, M. Barandas, and H. Gamboa, “Online fall detection using wrist devices,” *Sensors*, vol. 23, no. 3, p. 1146, 2023.

Versicherung

Ich versichere, dass ich diese Arbeit selbstständig verfasst und keine anderen als die angegebenen Hilfsmittel benutzt habe. Die den benutzten Hilfsmitteln wörtlich oder inhaltlich entnommenen Stellen habe ich unter Quellenangaben kenntlich gemacht. Die Arbeit hat in gleicher oder ähnlicher Form noch keiner anderen Prüfungsbehörde vorgelegen.

I declare that I have authored this thesis independently, that I have not used other than the declared sources / resources and that I have explicitly marked all material which has been quoted either literally or by content from the used sources.

Place, Date

Aly Elbermawy