

TH Mittelhessen

Technische Hochschule Mittelhessen - University of Applied Sciences

Studienprojekt 2

Wissenschaftliches Arbeiten

Subject:

Sensor-Based Fall Detection with Machine Learning

Author: Aly Elbermawy

Matriculation number: 5335848

Supervisor: Dr. Kovalev

Industry Partner: TrackTech GmbH

University: Technische Hochschule Mittelhessen, Friedberg

Submitted on: July 24, 2026

Confidentiality Clause

Transmittal, reproduction, dissemination and/or editing of this document as well as utilization of its contents and communication thereof to others without express authorization are prohibited. Offenders will be held liable for payment of damages. All rights created by patent grant or registration of a utility model or design patent are reserved.

Sperrvermerk

Die vorliegende Arbeit beinhaltet interne vertrauliche Informationen der TrackTech GmbH bzw. Clever-Sole. Die Weitergabe des Inhaltes der Arbeit und eventuell beiliegender Zeichnungen und Daten im Gesamten oder in Teilen ist grundsätzlich untersagt. Es dürfen keinerlei Kopien oder Abschriften – auch in digitaler Form – gefertigt werden. Ausnahmen bedürfen der schriftlichen Genehmigung der TrackTech GmbH.

Abstract

Falls are a leading cause of severe injury and reduced quality of life for elderly and care-dependent individuals. A reliable, energy-efficient and everyday-wearable fall-detection system can raise alarms in real time and thereby improve care safety. The novelty of the present project lies in the target form factor: a shoe-insole-integrated inertial sensor, rather than the wrist, hip or waist positions that dominate most public datasets.

The present study, submitted in partial fulfilment of the module *Studienprojekt 2* at TH Mittelhessen, addresses the first of four assigned tasks. Its objective is a literature- and datasheet-based comparison of 3-, 6- and 9-axis sensor configurations in the context of fall detection. The research question is whether a higher number of sensed axes actually improves detection performance and, if so, up to which point the improvement justifies the additional cost in energy, computation and complexity.

The analysis draws on peer-reviewed evaluations of accelerometer-only, IMU-based and MARG-based fall detection algorithms, complemented by manufacturer datasheets of three representative components (MPU-6050, LSM6DSOX, BHI360). It concludes that the transition from three to six axes yields a well-documented, substantial improvement – primarily in specificity, i.e. fewer false alarms – whereas the further step to nine axes adds absolute orientation whose benefit is marginal for the short-duration fall event itself, while introducing new susceptibility to indoor magnetic disturbances. A 6-axis configuration is therefore recommended as the sweet spot for the insole use case, which is also compatible with the leading public 6-axis fall datasets (SisFall, KFall) used in subsequent tasks.

Contents

Abbreviations	vii
1 Einleitung	1
1.1 Überblick	1
1.2 Umfang dieses Kapitels	1
1.3 Struktur	1
2 3-, 6- und 9-Achsen-Sensorsysteme zur Sturzerkennung	2
2.1 Forschungsfrage und Vorgehensweise	2
2.2 Physikalische Bedeutung der Achsengruppen	2
2.3 3-Achsen-Systeme: Nur Beschleunigungssensor	3
2.3.1 Erkennungsprinzip	3
2.3.2 Berichtete Leistungsfähigkeit	3
2.3.3 Zentrale Einschränkung: Falsch-positive Erkennungen	3
2.4 6-Achsen-Systeme: Beschleunigungssensor und Gyroskop	3
2.4.1 Welchen Beitrag das Gyroskop leistet	3
2.4.2 Berichtete Leistungssteigerungen	4
2.4.3 Grenzen des Nutzens des Gyroskops	4
2.5 9-Achsen-Systeme: Zusätzliches Magnetometer	4
2.5.1 Funktion des Magnetometers	4
2.5.2 Warum dies für die Sturzerkennung weniger relevant ist	4
2.5.3 Nachteile: Magnetische Störungen in Innenräumen	5
2.6 Beispielkomponenten (Nachweis durch Datenblätter)	5
2.7 Vergleich auf einen Blick	6
2.8 Begründetes Fazit	6
3 Einfluss der Sensoreigenschaften auf die Erkennungsqualität	8
3.1 Messbereich und Signal-Clipping	8
3.2 Abtastrate	8
3.3 Bit-Auflösung	9
3.4 Rauschdichte	9
3.5 Drift, insbesondere beim Gyroskop	10
3.6 Zusammenfassung	10
4 Ausblick auf Datensätze für das ML-Modell	12
4.1 Übersicht der Datensätze	12
4.2 Einzelbewertung	14
4.3 Verfügbarkeit und Zugänglichkeit	15
4.4 Begründete Entscheidung	16

5	Verlauf der Modellentwicklung (Aufgabe 4 Zwischenstand)	18
5.1	Datenaufbereitung	18
5.2	Modell 1: Schwellwert-Baseline	18
5.3	Modell 2: Random Forest mit Magnitude-Features	19
5.4	Modell 3: 1D-CNN	19
5.5	Vergleich der drei Modelle	20
5.6	TFLite-Export für den Mikrocontroller	20
5.7	Domänenlücke und Mitigationsstrategien	20
5.8	Cross-Position-Transfer: Quantifizierung der Domänenlücke	21
5.8.1	Motivation und Versuchsaufbau	21
5.8.2	Ergebnisse	22
5.8.3	Interpretation	22
5.9	Nächste Schritte	23
5.9.1	Geplante Kontrollexperimente	23
5.9.2	Weitere Arbeitsschritte	23

List of Figures

5.1	Sensitivität und Spezifität des SisFall-Modells auf den UMAFall-Knöcheldaten vor und nach dem Fine-Tuning.	22
-----	---	----

List of Tables

2.1	Von 3-, 6- und 9-Achsen-Sensorkonfigurationen gemessene physikalische Größen.	2
2.2	Repräsentative Komponenten auf 6- und 9-Achsen-Ebene.	5
2.3	Direkter Vergleich der Achsenkonfigurationen für die Sturzerkennung.	6
3.1	Einfluss der Sensoreigenschaften auf die Sturzerkennungsqualität.	11
4.1	Vergleich der sieben zu bewertenden Sturzdatensätze.	13
4.2	Verfügbarkeit und Zugänglichkeit der betrachteten Datensätze.	16
5.1	Vergleich der drei Sturzerkennungsmodelle auf SisFall (subjektunabhängig). .	20
5.2	Cross-Position-Transfer vom Hüft- auf den Knöchelsensor (identischer, subjektunabhängiger Testsplitt).	22

Abbreviations

ADL	Activity of Daily Living
ADC	Analog-to-Digital Converter
DoF	Degrees of Freedom
IMU	Inertial Measurement Unit
MARG	Magnetic, Angular Rate and Gravity
MEMS	Micro-Electro-Mechanical Systems
MLC	Machine Learning Core
SVM	Signal Vector Magnitude

1 Einleitung

1.1 Überblick

Stürze gehören zu den häufigsten Ursachen für schwere Verletzungen und langfristige gesundheitliche Komplikationen bei älteren und pflegebedürftigen Menschen, insbesondere bei Personen mit Demenz. Ein zuverlässiges, energieeffizientes und alltagstaugliches automatisches Sturzerkennungssystem auf Basis tragbarer Inertialsensoren kann dazu beitragen, Alarme schnell auszulösen und dadurch die Sicherheit in der Pflege zu erhöhen.

Die Qualität der automatischen Sturzerkennung hängt nicht nur vom verwendeten Machine-Learning-Modell zur Klassifikation ab, sondern auch von der zugrunde liegenden Sensorhardware und den verfügbaren Trainingsdaten. Das vorliegende *Studienprojekt 2* ist daher in vier Aufgaben gegliedert: eine kurze theoretische Bewertung der Sensorkonfiguration und ihrer physikalischen Eigenschaften (Aufgaben 1 und 2), eine Bewertung frei verfügbarer Open-Source-Sturzdatensätze (Aufgabe 3) sowie - als Hauptschwerpunkt - die Entwicklung, das Training und die prototypische Integration eines spezifischen Machine-Learning-Modells (Aufgabe 4).

1.2 Umfang dieses Kapitels

Dieses Dokument behandelt die Aufgaben 1 bis 3 des Projekts. Aufgabe 1 vergleicht die drei grundlegenden Sensorachsenkonfigurationen, Aufgabe 2 bewertet den Einfluss niedrigstufiger Sensoreigenschaften auf die Erkennungsqualität und Aufgabe 3 sichtet die in Frage kommenden Open-Source-Datensätze und begründet die Auswahl für die Modellentwicklung in Aufgabe 4.

1.3 Struktur

Kapitel 2 erläutert die physikalischen Grundlagen jeder Sensorachsengruppe und leitet eine begründete Achsenempfehlung ab. Kapitel 3 untersucht den Einfluss von fünf Sensoreigenschaften auf die Erkennungsqualität. Kapitel 4 bewertet sieben Open-Source-Datensätze anhand der in der Aufgabenstellung genannten Kriterien (Sensorposition, Achsenkonfiguration und Abtastrate, Klassenabdeckung und Probandendiversität, Verfügbarkeit) und begründet die Auswahl der Primär- und Sekundärdatensätze für die Modellentwicklung.

2 3-, 6- und 9-Achsen-Sensorsysteme zur Sturzerkennung

2.1 Forschungsfrage und Vorgehensweise

Die zentrale Fragestellung dieses Kapitels lautet, ob eine höhere Anzahl erfasster Achsen die Genauigkeit der Sturzerkennung statistisch signifikant verbessert und bis zu welchem Punkt diese Verbesserung den zusätzlichen Aufwand hinsichtlich Energieverbrauch, Rechenleistung und Komplexität rechtfertigt. Die Aufgabenstellung verlangt ausdrücklich, dass die daraus abgeleitete Bewertung durch Literatur oder Datenblätter gestützt wird und nicht lediglich auf Behauptungen beruht. Die vorliegende Analyse kombiniert daher zwei voneinander unabhängige Beweislinien: (i) begutachtete wissenschaftliche Studien, die Sensitivität und Spezifität der jeweiligen Achsenkonfigurationen berichten, sowie (ii) Herstellerdatenblätter repräsentativer Komponenten aus dem 6- und 9-Achsen-Bereich.

2.2 Physikalische Bedeutung der Achsengruppen

Die drei Achsenkonfigurationen unterscheiden sich hinsichtlich der physikalischen Größen, die sie messen (Tabelle 2.1):

Table 2.1: Von 3-, 6- und 9-Achsen-Sensorkonfigurationen gemessene physikalische Größen.

Konfiguration	Sensoren	Gemessene Größe
3-Achsen	Dreiachsiger Beschleunigungssensor	Lineare Beschleunigung einschließlich der Erdbeschleunigung entlang der x -, y - und z -Achse, üblicherweise in g angegeben.
6-Achsen (IMU)	Dreiachsiger Beschleunigungssensor + dreiachsiges Gyroskop	Lineare Beschleunigung zusammen mit der Winkelgeschwindigkeit (Roll-, Nick- und Gierrate), üblicherweise in $^{\circ}/s$ angegeben.
9-Achsen (MARG)	Dreiachsiger Beschleunigungssensor + dreiachsiges Gyroskop + dreiachsiges Magnetometer	Lineare Beschleunigung, Winkelgeschwindigkeit und der Magnetfeldvektor der Erde, wodurch mittels Sensorfusionsalgorithmen eine absolute Richtungsbestimmung und vollständige Orientierung ermöglicht werden.

2.3 3-Achsen-Systeme: Nur Beschleunigungssensor

2.3.1 Erkennungsprinzip

Der dominierende Ansatz bei 3-Achsen-Systemen berechnet den Betrag der Beschleunigung (Signal Vector Magnitude (SVM)) und wendet Schwellwerte auf die charakteristische Sturzsignatur an: eine Freifallphase, in der der Betrag gegen 0 g fällt, gefolgt von einem ausgeprägten Aufprallmaximum. Ein häufig zitierter Schwellwertalgorithmus von Bourke verwendet einen unteren Freifall-Schwellwert von 0.65 g und einen oberen Aufprall-Schwellwert von 2.8 g, optional ergänzt durch eine Überwachung der Körperhaltung nach dem Aufprall (“Long-Lie”) [1].

2.3.2 Berichtete Leistungsfähigkeit

Schwellwertbasierte Algorithmen, die ausschließlich Beschleunigungssensoren verwenden, erreichen unter Laborbedingungen typischerweise Sensitivitäts- und Spezifitätswerte im Bereich von 80–95 % [2]. Bei sorgfältig simulierten Laborstürzen berichten einzelne Algorithmen sogar nahezu perfekte Ergebnisse. Wurde derselbe leistungsstärkste Algorithmus jedoch anhand einer Datenbank mit *realen* Stürzen älterer Menschen bewertet, sank die Sensitivität auf 83 % (Spezifität 97 %) [1]. Diese Diskrepanz stellt einen gut dokumentierten Realitätscheck für sämtliche Laborergebnisse in diesem Forschungsgebiet dar.

2.3.3 Zentrale Einschränkung: Falsch-positive Erkennungen

Die ausschließliche Verwendung des Beschleunigungsbetrags erlaubt keine zuverlässige Unterscheidung zwischen tatsächlichen Stürzen und sturzähnlichen Aktivitäten des täglichen Lebens (Activity of Daily Livings (ADLs)), wie beispielsweise schnellem Hinsetzen, Hinlegen, Laufen oder Springen, da all diese vergleichbar hohe Beschleunigungsspitzen erzeugen können [3]. Eine Absenkung des Erkennungsschwellwertes, um mehr Stürze zu erfassen, erhöht unmittelbar die Rate falsch-positiver Alarme, ein grundlegender Zielkonflikt zwischen Sensitivität und Spezifität des Einzelmodalitätsansatzes [2]. Im Pflegekontext untergraben häufige Fehlalarme die Akzeptanz der Nutzer und führen nachweislich zu Alarmmüdigkeit.

2.4 6-Achsen-Systeme: Beschleunigungssensor und Gyroskop

2.4.1 Welchen Beitrag das Gyroskop leistet

Stürze gehen mit einer charakteristischen schnellen Änderung der Körperorientierung (Rotation in Richtung der Horizontalen) einher, die bei ADLs wie dem Hinsetzen nicht in derselben Kombination aus Rotationsgeschwindigkeit und Beschleunigung auftritt. Die vom Gyroskop gemessene Winkelgeschwindigkeit liefert daher ein unabhängiges Unterscheidungsmerkmal genau dort, wo das Signal des Beschleunigungssensors mehrdeutig ist.

2.4.2 Berichtete Leistungssteigerungen

Zwei unabhängige quantitative Ergebnisse kommen zu derselben Schlussfolgerung. In einem auf der Brust getragenen System mit 702 Aufzeichnungen von 36 Probanden erhöhte die Ergänzung eines beschleunigungsbasierten Algorithmus durch Gyroskop-Schwellwerte die *Spezifität* von 82.72 % auf 96.2 %, während gleichzeitig eine Sensitivität von 96.3 % erhalten blieb (Schwellwerte mittels ROC-Analyse optimiert) [3]. In einer Smartphone-basierten Studie mit frei variierenden Gerätepositionen übertraf die Kombination aus Beschleunigungssensor und Gyroskop die reine Beschleunigungssensor-Konfiguration um mehr als 15 Prozentpunkte hinsichtlich der Genauigkeit [4]. Beide Ergebnisse identifizieren die Reduktion falsch-positiver Erkennungen als den wesentlichen Beitrag des Gyroskops.

2.4.3 Grenzen des Nutzens des Gyroskops

Der Zugewinn ist jedoch nicht uneingeschränkt. Studien, die die Mehrdeutigkeit des Beschleunigungssensors bereits auf andere Weise kompensieren – etwa durch zwei Sensorpositionen oder die Fusion mit einem Barometer-, berichten von geringeren zusätzlichen Vorteilen durch das Gyroskop [5, 6]. Der Vorteil einer 6-Achsen-Konfiguration ist daher insbesondere im Szenario mit nur einem Sensor an einer einzigen Position am größten, genau der Einlagenkonfiguration, die dieses Projekt verfolgt.

2.5 9-Achsen-Systeme: Zusätzliches Magnetometer

2.5.1 Funktion des Magnetometers

Die auf dem Gyroskop basierende Orientierung wird durch numerische Integration der Winkelgeschwindigkeit bestimmt, wodurch sich Messfehler im Laufe der Zeit aufsummieren. Roetenberg et al. berichten, dass eine ausschließlich auf dem Gyroskop basierende Integration innerhalb von 45 s um etwa 10° abdriften kann [7]. Das Magnetometer misst das Magnetfeld der Erde und stellt dadurch eine *absolute* Richtungsreferenz bereit. In Kombination mit Beschleunigungssensor und Gyroskop in einem Kalman- oder Madgwick-Filter korrigiert es diese Drift und liefert eine stabile absolute Orientierung (Gier, Nick und Roll).

2.5.2 Warum dies für die Sturzerkennung weniger relevant ist

Ein Sturz ist ein kurzzeitiges Ereignis, die kritische Phase vom Verlust des Gleichgewichts bis zum Aufprall dauert typischerweise nur ein bis wenige Sekunden. Innerhalb dieses Zeitraums ist die Gyroskopdrift gering. Die Driftkorrektur, welche den Hauptbeitrag des Magnetometers darstellt, kommt daher in erster Linie der *langfristigen* Orientierungsbestimmung zugute und nicht der Erkennung eines kurzen, hochdynamischen Ereignisses. Die mit sechs Achsen messbare relative Orientierungsänderung reicht aus, um die Kinematik eines Sturzes zu charakterisieren.

2.5.3 Nachteile: Magnetische Störungen in Innenräumen

Messwerte von Magnetometern werden in Innenräumen systematisch verfälscht: Ferromagnetische Materialien in Gebäudestrukturen, Haushaltsgeräten und Möbeln verändern das lokale Magnetfeld, verursachen Richtungsfehler, die häufig 5° überschreiten, und erschweren dadurch mobile Anwendungen [8–10]. Da ältere Menschen den größten Teil ihrer Zeit in Innenräumen verbringen, erfordert ein robuster Betrieb Kalibrierungs- und Störkompensationsalgorithmen, also zusätzlichen Rechenaufwand [8, 10] zusätzlich zum höheren Energieverbrauch und Integrationsaufwand einer dritten Sensormodalität sowie einer vollständigen 9-Degrees of Freedom (DoF)-Sensorfusion.

2.6 Beispielkomponenten (Nachweis durch Datenblätter)

Die drei in der Aufgabenstellung genannten repräsentativen Komponenten werden in Tabelle 2.2 verglichen. Sämtliche Angaben sind typische Werte unter den jeweiligen Herstellerbedingungen und müssen für den finalen Bericht anhand der Originaldatenblätter erneut überprüft werden.

Table 2.2: Repräsentative Komponenten auf 6- und 9-Achsen-Ebene.

Komponente	Konfig.	Messbereiche	Stromaufnahme	Besonderheiten
MPU-6050 [11]	6-Achsen IMU	$\pm 2/4/8/16$ g; ± 250 – $2000^\circ/\text{s}$	≈ 3.9 mA	Klassische kostengünstige Referenz mit 16-Bit-ADCs; alle Sensoren aktiv; Referenz für den 6-Achsen-Vergleich.
LSM6DSOX [12]	6-Achsen IMU	± 2 – 16 g; ± 125 – $2000^\circ/\text{s}$	0.55 mA	Hochleistungsmodus; etwa $7\times$ geringere Stromaufnahme als der MPU-6050; integrierter MLC und hardwarebasierte Freifallerkennung.
BHI360 [13] (9-DoF externes Magnetometer)	6-Achsen IMU Geräteabhängig	± 600 μA	Führt die BSX- Fusionsbibliothek direkt auf dem Chip aus und entlastet dadurch den Hauptprozessor von der Sensorfusion.	

Der Effizienzunterschied zwischen dem MPU-6050 (Generation um 2010) und dem LSM6DSOX/BHI360 zeigt außerdem, dass die *Sensorgeneration* den Energiebedarf ebenso stark beeinflussen kann wie die Anzahl der Achsen.

2.7 Vergleich auf einen Blick

Table 2.3: Direkter Vergleich der Achsenkonfigurationen für die Sturzerkennung.

	3-Achsen	6-Achsen	9-Achsen
Erfasst	Aufprallmaximum, Freifallphase (SVM)	+ Rotationsgeschwindigkeit → Sturzkinematik	+ absolute Orientierung / Himmelsrichtung
Stärken	Minimaler Aufwand hinsichtlich Kosten, Energie und Komplexität	Großer Spezifitätsgewinn (82.7 → 96.2 % [3]; über 15 Prozentpunkte Genauigkeit [4])	Driftkorrigierte langfristige Orientierung [7]
Schwächen	Falsch-positive Erkennungen durch sturzähnliche ADLs [2, 3]; geringere Sensitivität bei realen Stürzen [1]	Höhere Stromaufnahme; Drift spielt nur deshalb kaum eine Rolle, weil Stürze kurz sind	Magnetische Störungen in Innenräumen [8–10]; zusätzlicher Energie-, Rechen- und Kalibrierungsaufwand
Nutzen für die Sturzerkennung	Basislösung, praktikabel, aber anfällig für Alarmmüdigkeit	Hoch, behebt den wesentlichen Schwachpunkt	Gering, korrigiert einen Fehler, der sich innerhalb von 1-2s kaum aufbaut

2.8 Begründetes Fazit

Von drei auf sechs Achsen: eindeutig gerechtfertigt. Der Übergang adressiert den dokumentierten Hauptschwachpunkt der ausschließlich auf Beschleunigungssensoren basierenden Sturzerkennung - falsch-positive Erkennungen durch sturzähnliche ADLs - mit gemessenen Spezifitätssteigerungen von etwa $\approx 83\%$ auf $\approx 96\%$ [3] sowie Genauigkeitssteigerungen von mehr als 15 Prozentpunkten [4]. Dies geschieht zum Preis einer einzigen zusätzlichen Micro-Electro-Mechanical Systems (MEMS)-Sensormodalität, deren Stromaufnahme bei modernen Bauteilen gering ausfällt (0.55 mA für eine vollständige 6-Achsen-LSM6DSOX [12]).

Von sechs auf neun Achsen: für diesen Anwendungsfall nicht verhältnismäßig. Der Hauptbeitrag des Magnetometers, absolute Richtungsbestimmung und langfristige Driftkorrektur [7] adressiert ein Problem, das bei einem 1-2 Sekunden dauernden Sturzereignis praktisch nicht relevant ist, führt jedoch gleichzeitig ein neues Problem ein: Richtungsfehler durch ferromagnetische Verzerrungen genau in den Innenraumumgebungen, in denen ältere Menschen leben [8–10], sowie zusätzlichen Energieverbrauch, Rechenaufwand und Kalibrierungsbedarf. Keine der in dieser Literaturübersicht betrachteten Studien zeigt einen Genauigkeitsgewinn durch das Magnetometer, der mit dem Beitrag des Gyroskops vergleichbar wäre.

Empfehlung: Eine 6-Achsen-Konfiguration stellt den besten Kompromiss für die einlagenbasierte Sturzerkennung dar. Dies wird zusätzlich dadurch unterstützt, dass die führenden öffentlich verfügbaren Sturzdatensätze (SisFall, KFall) selbst auf 6-Achsen-Aufzeichnungen basieren, wodurch zugleich die Kompatibilität der Trainingsdaten für das im Rahmen von Aufgabe 4 zu entwickelnde Machine-Learning-Modell sichergestellt wird.

3 Einfluss der Sensoreigenschaften auf die Erkennungsqualität

In Kapitel 2 wurde die Wahl einer sechsachsigen IMU auf der Ebene begründet, *welche* Achsen erfasst werden sollen. Das vorliegende Kapitel ergänzt diese Argumentation um eine zweite Ebene und fragt, *wie präzise* diese Achsen erfasst werden müssen. Betrachtet werden fünf niedrigstufige Datenblattgrößen, nämlich Messbereich, Abtastrate, Bit-Auflösung, Rauschdichte und Drift, sowie deren jeweiliger Einfluss auf die Sturzerkennung. Gemäß der Aufgabenstellung wird der Umfang bewusst kompakt gehalten und stützt sich vollständig auf die Fachliteratur; eigene Messreihen sind nicht vorgesehen.

3.1 Messbereich und Signal-Clipping

Der Messbereich legt fest, wie große Beschleunigungen ein Sensor darstellen kann, bevor er in die Sättigung gerät. Ein Sturz besteht aus zwei dynamischen Phasen mit stark unterschiedlicher Amplitude. In der freien Fallphase sinkt der Betrag der gemessenen Beschleunigung gegen 0 g, worauf innerhalb weniger Millisekunden der Aufprall folgt, dessen Spitzenwert typischerweise ein Mehrfaches der Erdbeschleunigung erreicht. In der Literatur häufig zitierte Schwellwertverfahren setzen den oberen Impact-Schwellwert an der Hüfte im Bereich von 2,0 g bis 2,8 g an [1, 14]. An peripheren Körperstellen fallen die lokalen Spitzenwerte allerdings deutlich höher aus; Untersuchungen zur Tibia-Beschleunigung im Alltag berichten Werte, die im Knöchelbereich 16 g bis 24 g überschreiten können [15].

Wird der Messbereich zu klein gewählt, kommt es zum sogenannten Clipping. Das Analogsignal wird auf den größten darstellbaren Wert abgeschnitten, und in der Zeitreihe zeigen sich charakteristische flache Plateaus. Dabei wird gerade dasjenige Merkmal verzerrt, das für die Sturzerkennung die höchste Trennschärfe aufweist, nämlich der Impact-Peak. Vergleichende Messungen belegen einen Genauigkeitsverlust bei der Peak-Tibial-Acceleration von etwa 6,25 % bei ± 16 g und 28,17 % bei ± 8 g gegenüber einer Referenz mit ± 70 g [15]. Ein Messbereich von ± 2 g, wie er in einfachen Konsumbausteinen üblich ist, reicht daher an keiner Körperposition aus. ± 8 g stellt eine praxistaugliche Untergrenze dar, während ± 16 g, wie im SisFall-Datensatz verwendet [16], insbesondere für periphere Positionen wie die geplante Anbringung in der Schuhsohle einen sinnvollen Sicherheitspuffer bietet.

3.2 Abtastrate

Die Abtastrate bestimmt, mit welcher zeitlichen Auflösung sich die charakteristische Signatur eines Sturzes rekonstruieren lässt. Menschliche Bewegungen sind spektral von tiefen Frequenzen dominiert, und die kritische Phase eines Sturzes umfasst nur einige hundert Millisekunden. Nach dem Nyquist-Kriterium sind daher bereits Abtastraten im Bereich einiger zehn Hertz

ausreichend, um das relevante Frequenzband abzudecken.

Zwei unabhängig voneinander durchgeführte empirische Arbeiten kommen zu einem übereinstimmenden Ergebnis. Villar et al. zeigen, dass eine Abtastfrequenz von 15 Hz bis 20 Hz genügt, um mit einem Convolutional Neural Network eine Sensitivität und Spezifität von über 95 % zu erreichen, während höhere Frequenzen keinen nennenswerten Zusatzgewinn liefern [17]. Eine aktuellere Untersuchung auf dem SisFall-Datensatz trainierte fünf Klassifikatoren bei 10, 20, 50 und 100 Hz. Als bester Kompromiss wurde ein CNN-LSTM-Modell bei 20 Hz identifiziert, das eine Genauigkeit von 98,9 %, eine Sensitivität von 96,7 % und eine Spezifität von 99,6 % erreicht und dabei gleichzeitig das übertragene Datenvolumen deutlich reduziert [18]. Werte unterhalb von 10 Hz beginnen, kritische Details der Aufprallphase zu verlieren, während Werte oberhalb von etwa 100 Hz im Wesentlichen nur die Datenrate und den Energiebedarf erhöhen, ohne dass die Klassifikationsleistung weiter zunimmt.

Für ein sohlenbasiertes System, das ein batteriebetriebenes Wearable mit einem auf begrenzter Hardware ausgeführten ML-Modell kombiniert, stellt somit eine Abtastrate zwischen 20 Hz und 50 Hz einen aus praktischer Sicht sinnvollen Arbeitspunkt dar.

3.3 Bit-Auflösung

Digital ausgegebene MEMS-Beschleunigungssensoren quantisieren das Analogsignal mit einer festen Anzahl von Bits, in der Regel zwischen zwölf und sechzehn. Für die nominelle Auflösung q in Einheiten von g gilt $q = \text{FSR}/2^N$, wobei FSR die Vollbereichsspanne und N die Bit-Breite bezeichnet. Für einen 16-Bit-ADC bei $\pm 16\text{ g}$ folgt daraus $q \approx 0,5\text{ mg}$ pro Code. Eine höhere Auflösung erlaubt eine feinere Unterscheidung geringfügiger Bewegungen, etwa langsames Hinsetzen im Vergleich zum Einleiten eines Sturzes, was der merkmalsbasierten Machine-Learning-Stufe in Aufgabe 4 zugutekommt.

Die nominelle Auflösung stellt allerdings eine obere Schranke dar. Die effektive Bitanzahl richtet sich nach dem Verhältnis von Vollbereichsspanne zum integrierten Sensorrauschen. Veröffentlichte Beispiele belegen, dass ein als 16-Bit deklarierter Baustein nach Abzug des sensoreigenen Rauschens nur etwa 8,5 rauschfreie Bits liefert [19]. In der Praxis gehören 12- bis 16-Bit-Wandler in Wearables zur Sturzerkennung zum Stand der Technik und stellen keinen limitierenden Faktor der Klassifikationsgüte dar. Praktisch relevanter ist die im folgenden Abschnitt behandelte Rauschdichte.

3.4 Rauschdichte

Die Rauschdichte n_d , in Datenblättern typischerweise in $\mu\text{g}/\sqrt{\text{Hz}}$ für den Beschleunigungssensor beziehungsweise in $\text{mdps}/\sqrt{\text{Hz}}$ für das Gyroskop angegeben, quantifiziert das dem Nutzsignal überlagerte stochastische Grundrauschen. Für das effektive RMS-Rauschen am Klassifikatoreingang gilt

$$\sigma_{\text{RMS}} = n_d \cdot \sqrt{\text{BW}_{\text{NEB}}}, \quad (3.1)$$

wobei BW_{NEB} die rauschäquivalente Bandbreite des digitalen Filters bezeichnet [20]. Für einen typischen Konsumbaustein mit $n_d \approx 126 \mu\text{g}/\sqrt{\text{Hz}}$ und einer Bandbreite von 200 Hz ergibt sich hieraus $\sigma_{\text{RMS}} \approx 1,8 \text{ mg}$ [20]. Eine verbreitete Faustregel fordert, dass das kleinste zu detektierende Merkmal mindestens eine Größenordnung über σ_{RMS} liegen sollte [20].

Diese Anforderung ist für die Sturzerkennung leicht zu erfüllen. Die dominanten Impact-Peaks liegen im Bereich mehrerer g, sodass das Grundrauschen die Aufprallphase in der Praxis nicht beeinflusst. Relevant wird die Rauschdichte hingegen in der Merkmalsextraktion einer Machine-Learning-Pipeline (vgl. Aufgabe 4), in der feine Statistiken wie Varianz, Kurtosis oder Ableitungen der Signalmagnitude herangezogen werden, um sturzähnliche Alltagsaktivitäten von tatsächlichen Stürzen zu trennen. Rauscharme Bausteine wie der LSM6DSOX [12] bringen an dieser Stelle einen kleinen, aber reproduzierbaren Vorteil für den Klassifikator, und dies ohne relevanten Zusatzaufwand, da sie zugleich einen geringeren Stromverbrauch aufweisen.

3.5 Drift, insbesondere beim Gyroskop

Das Ausgangssignal eines Gyroskops enthält einen langsam veränderlichen Bias, dessen spektrale Fluktuationen im tiefen Frequenzbereich von einem Anteil mit $1/f$ -Charakteristik dominiert werden [21]. Die zugehörige Kenngröße, die Bias-Instabilität, wird üblicherweise über die Allan-Varianz quantifiziert. Für typische kostengünstige MEMS-Gyroskope liegt sie in der Größenordnung von $3,6^\circ/\text{h}$ [22]. Bausteine der MPU-6050-Klasse zeigen auf allen drei Achsen ein vergleichbares Verhalten [23].

Ob dieser Drift praxisrelevant wird, hängt entscheidend vom Beobachtungsfenster ab. Bei einer Integration der Winkelgeschwindigkeit zur Bestimmung der Orientierung akkumuliert sich der Fehler mit der Zeit. Roetenberg et al. weisen für eine rein gyroskopische Integration einen bias-bedingten Orientierungsfehler von rund 10° innerhalb von 45 Sekunden nach [7]. Für ein Sturzereignis, dessen relevante Zeitspanne im Bereich von ein bis zwei Sekunden liegt, ist der Driftbeitrag jedoch verschwindend gering im Vergleich zu den während des Sturzes auftretenden Rotationsraten. Dieser Befund deckt sich mit der Schlussfolgerung aus Kapitel 2, wonach die driftkompensierende Funktion des Magnetometers für die eigentliche Sturzerkennung nur einen marginalen Nutzen liefert.

3.6 Zusammenfassung

Die fünf betrachteten Eigenschaften wirken nicht isoliert, sondern greifen ineinander (Tabelle 3.1). Für einen Machine-Learning-basierten Sturzdetektor in Sohlenkonfiguration ergibt sich hieraus als empfohlener Arbeitspunkt eine sechssachsige IMU mit einem Beschleunigungs-Messbereich von $\pm 16 \text{ g}$, einem Gyroskop-Messbereich von ± 1000 bis $\pm 2000^\circ/\text{s}$, einer Abtastrate zwischen 20 Hz und 50 Hz, mindestens 12 Bit Auflösung, geringer Rauschdichte (unterhalb von etwa $100 \mu\text{g}/\sqrt{\text{Hz}}$) sowie einer nicht weiter kompensierten Gyroskop-Drift, da deren Beitrag über die kurze Sturzdauer vernachlässigbar bleibt. Diese Anforderungen werden vom in Kapitel 2

diskutierten LSM6DSOX abgedeckt und stehen im Einklang mit der Aufnahmecharakteristik des SisFall-Datensatzes, der in den Aufgaben 3 und 4 verwendet wird.

Table 3.1: Einfluss der Sensoreigenschaften auf die Sturzerkennungsqualität.

Eigenschaft	Primärer Effekt	Empfohlener Bereich
Messbereich	Verhindert Clipping des Impact-Peaks; ein zu kleiner Bereich verzerrt das trennschärfste Merkmal [14, 15]	mindestens ± 8 g, empfohlen ± 16 g
Abtastrate	Zeitliche Rekonstruktion der Sturzsiganatur; höhere Raten erhöhen den Energiebedarf ohne Genauigkeitsgewinn [17, 18]	20 Hz bis 50 Hz
Bit-Auflösung	Feinauflösung der Merkmalsextraktion; effektive Bitzahl durch das Rauschen begrenzt [19]	mindestens 12 Bit
Rauschdichte	Bestimmt die minimal auflösbare Signalgröße; wirkt sich vor allem auf die Unterscheidung von ADL und Präaufprall aus [20]	$\leq 100 \mu\text{g}/\sqrt{\text{Hz}}$
Gyroskop-Drift	Langzeitfehler der Orientierungsbestimmung; auf der Zeitskala eines Sturzes vernachlässigbar [7, 21]	für kurze Ereignisse unkritisch

4 Ausblick auf Datensätze für das ML-Modell

Für die Entwicklung des eigenen Machine-Learning-Modells in Aufgabe 4 stehen mehrere frei verfügbare Sturzdatensätze zur Auswahl. Die Aufgabenstellung nennt mindestens sieben Kandidaten, die im Folgenden hinsichtlich ihrer Eignung für den angestrebten Anwendungsfall bewertet werden: eine schuhsohlenintegrierte (*Insole*-)Sturzerkennung bei älteren, gegebenenfalls kognitiv eingeschränkten Personen. Die Bewertungskriterien orientieren sich an der Aufgabenstellung und umfassen die Sensorposition am Körper und deren Übertragbarkeit auf eine Fußsohle, die Achsenkonfiguration und Abtastrate im Vergleich zur geplanten Sensorik, die Abdeckung verschiedener Sturz- und ADL-Klassen, die Diversität der Probanden sowie die Verfügbarkeit und Zugänglichkeit der Rohdaten.

Die Aufgabenstellung enthält bereits eine erste Einschätzung zur Eignung der sieben Datensätze. Diese wurde im Rahmen der vorliegenden Bearbeitung anhand der Originalpublikationen und der offiziellen Datensatzquellen eigenständig geprüft, vertieft und dort präzisiert oder korrigiert, wo die tatsächlichen Datenblätter von der Aufgabenstellung abweichen. Die entsprechenden Anpassungen sind in den nachfolgenden Abschnitten kenntlich gemacht.

4.1 Übersicht der Datensätze

Tabelle 4.1 fasst die wesentlichen Eckdaten der sieben Datensätze zusammen. Im Anschluss wird jeder Datensatz einzeln hinsichtlich seiner Stärken und Einschränkungen für den vorliegenden Anwendungsfall eingeordnet.

Table 4.1: Vergleich der sieben zu bewertenden Sturzdatensätze.

Datensatz	Sensorik / Position	Achsen	Hz	Probanden	Eignung für Insole
SisFall [16]	2 Beschl.-Sensoren (ADXL345 ± 16 g, MMA8451Q ± 8 g) + Gyroskop (ITG3200 $\pm 2000^\circ/\text{s}$), am Gürtel (Hüfte)	6 ($2 \times 3 + 3$)	200	38 (23 jung, 15 ältere)	Gut geeignet: passende Achsenkonfiguration, hohe Abtastrate, etablierter Benchmark mit vielen Vergleichswerten in der Literatur.
MobiFall / MobiAct [24, 25]	Smartphone (Samsung Galaxy S3) in der Hosentasche	6–9 (variabel)	≈ 20 –87	11 / 57	Bedingt geeignet: Smartphone-Sensorik (oft nur ± 2 g) unterscheidet sich von einer Insole; Trageposition und Messbereich weichen ab.
UMAFall [26]	4 $\times$ SensorTag (MPU-9250) an Brust, Hüfte, Handgelenk, Knöchel + Smartphone in der Tasche	9	20 (Tags) / 200 (Smartphone)	19 (19–68 J.)	Bedingt geeignet: Mehrknoten-Aufbau interessant, aber IMU-Abtastrate nur 20 Hz; Knöcheldaten vorhanden, jedoch nur 3 Sturztypen.
KFall [27]	9-Achsen-IMU (MTw Awinda) am unteren Rücken; bereitgestellt werden Beschl., Winkelgeschw. und Euler-Winkel	6 + Euler	100	32	Gut geeignet: hohe Abtastrate, 15 Sturztypen, zeitliche Annotation des Aufprallzeitpunkts (Pre-Impact), umfangreicher Benchmark.
FallAllD [28]	3 $\times$ IMU (LSM9DS1) an Nacken, Handgelenk und Taille; Beschl. ± 8 g, Gyro $\pm 2000^\circ/\text{s}$, Mag, Baro	9 (+ Baro)	238 / 476 (Beschl.)	15	Bedingt geeignet: Tailendaten nutzbar, hohe Abtastrate, aber nur 15 (junge) Probanden und Messbereich ± 8 g kann an peripheren Positionen clippen (vgl. Abschnitt 3.1).
UniMiB SHAR [29]	Smartphone (Samsung Galaxy Nexus) in der Hosentasche	3	50	30 (18–60 J.)	Eingeschränkt geeignet: rein 3-achsig (nur Beschleunigungssensor), daher für einen theoretischen 3- vs. 6-Achsen-Vergleich hilfreich, aber nicht für ein realistisches 6-Achsen-Modell.
WEDA-FALL [30]	Fitbit Sense Smartwatch am Handgelenk	6	50	25 (14 jung, 11 ältere >80 J.)	Bedingt geeignet: Handgelenk-Position weicht stark von der Fußposition ab; niedrige Abtastrate (50 Hz); enthält jedoch Daten älterer Probanden, was für Kreuzvalidierung nützlich sein kann.

4.2 Einzelbewertung

SisFall wurde an der Universidad de Antioquia erhoben und umfasst 4505 Aufzeichnungen (2707 ADL, 1798 simulierte Stürze) von 38 Probanden, darunter 15 Personen im Alter von 60 bis 75 Jahren [16]. Die Sensoreinheit wurde am Gürtel (Hüfte) befestigt und besteht aus *zwei* Beschleunigungssensoren (ADXL345 mit ± 16 g und MMA8451Q mit ± 8 g) sowie einem Gyroskop (ITG3200 mit $\pm 2000^\circ/\text{s}$), aufgezeichnet mit einer Abtastrate von 200 Hz. Die redundante Beschleunigungsmessung entspricht der Angabe der Aufgabenstellung von „zwei Beschleunigungssensoren + Gyroskop“ und wurde in einer früheren Fassung dieser Arbeit unzutreffend als Einzelsensor beschrieben. SisFall ist der am häufigsten zitierte Benchmark für die sensorbasierte Sturzerkennung, was eine direkte Vergleichbarkeit der eigenen Ergebnisse mit der Literatur ermöglicht. Die 6-Achsen-Konfiguration (Beschleunigung + Gyroskop) stimmt mit der in Kapitel 2 empfohlenen Achsenwahl überein. Einschränkend ist anzumerken, dass die älteren Probanden nur ADL durchführten und keine simulierten Stürze, sodass die Sturzdaten ausschließlich von jungen Erwachsenen stammen.

MobiFall und MobiAct basieren auf Smartphone-Sensorik und wurden an der Technischen Hochschule Kreta erhoben [24, 25]. MobiAct umfasst 57 Probanden, 4 Sturztypen und 9 ADL; die Daten wurden mit dem eingebauten Beschleunigungssensor und Gyroskop eines Samsung Galaxy S3 aufgezeichnet. Der Messbereich der Smartphone-Beschleunigungssensoren liegt häufig nur bei ± 2 g, was für die Sturzerkennung zu Clipping führen kann (vgl. Abschnitt 3.1). Darüber hinaus unterscheidet sich die Trageposition (Hosentasche) grundlegend von einer Insole, sodass eine Übertragbarkeit der Bewegungsmuster auf die Fußsohle nicht ohne Weiteres gegeben ist.

UMAFall setzt einen Mehrknoten-Aufbau mit vier SensorTags (MPU-9250, je Beschleunigungssensor, Gyroskop und Magnetometer) und einem Smartphone ein [26]. Durch die gleichzeitige Erfassung an Brust, Hüfte, Handgelenk und Knöchel ermöglicht dieser Datensatz die Untersuchung positionsabhängiger Effekte. Die Abtastrate der SensorTags beträgt allerdings nur 20 Hz, und es sind lediglich drei Sturztypen enthalten. Für den vorliegenden Anwendungsfall bieten die Knöcheldata zwar eine gewisse Nähe zur Fußposition, die geringe Abtastrate und begrenzte Sturzdiversität schränken den praktischen Nutzen jedoch ein.

KFall wurde am KAIST in Südkorea erhoben und umfasst 5075 Aufzeichnungen (2729 ADL, 2346 Stürze) von 32 Probanden [27]. Zum Einsatz kam eine 9-Achsen-IMU (Xsens MTw Awinda) am unteren Rücken; die veröffentlichten Datenfiles enthalten die 3-Achsen-Beschleunigung, die 3-Achsen-Winkelgeschwindigkeit sowie die per Sensorfusion abgeleiteten Euler-Winkel bei 100 Hz. Für den Vergleich mit einer geplanten reinen 6-Achsen-Sensorik können die Euler-Kanäle verworfen und lediglich Beschleunigung und Winkelgeschwindigkeit verwendet werden. Eine Besonderheit von KFall ist die zeitliche Annotation des Sturzbeginns und des Aufprallzeitpunkts anhand synchronisierter Videoaufnahmen, was den Datensatz insbesondere für die Pre-Impact-Erkennung wertvoll macht. KFall bietet damit eine gute Ergänzung zu SisFall, da die simulierten Sturztypen aus SisFall übernommen wurden, die Abtastrate hinreichend hoch ist und die Pre-Impact-Annotation Zusatzinformationen für die Merkmalsextraktion liefert.

Einschränkend ist, dass sämtliche Probanden junge Erwachsene waren.

FallAllID enthält Daten von drei gleichzeitig getragenen IMUs (LSM9DS1), die am Nacken, am Handgelenk und an der Taille befestigt waren [28]. Damit weicht die Sensorposition von der Angabe in der Aufgabenstellung (Hals, Brust, Taille) ab; entscheidend ist die Position am Handgelenk anstelle der Brust, wie die offizielle Beschreibung des Datensatzes auf IEEE DataPort bestätigt. Die Abtastrate ist mit 238 Hz für Beschleunigungssensor und Gyroskop hoch, die Sensoren umfassen zusätzlich ein Magnetometer und ein Barometer. Der Datensatz deckt zahlreiche Sturz- und ADL-Typen ab und ist hinsichtlich der Bewegungsvielfalt umfangreicher als die meisten anderen betrachteten Kandidaten. Einschränkend sind der gegenüber SisFall geringere Messbereich von ± 8 g sowie die kleine Probandenzahl von 15 (jungen) Personen. Für den vorliegenden Anwendungsfall sind vor allem die Aufzeichnungen am Taillensensor relevant, da sie in der Kinematik am ehesten den bisherigen Benchmark-Datensätzen entsprechen.

UniMiB SHAR ist ein reiner 3-Achsen-Datensatz (Beschleunigungssensor, 50 Hz) von Smartphone-Aufzeichnungen aus der Hosentasche [29]. Er umfasst 11 771 Samples von 30 Probanden mit 9 ADL und 8 Sturztypen. Da kein Gyroskop vorhanden ist, eignet sich dieser Datensatz nicht für die Entwicklung eines 6-Achsen-Modells, kann aber hilfsweise als Vergleichsbasis für die Frage herangezogen werden, welchen Mehrwert die sechste Achse bringt (vgl. Kapitel 2).

WEDA-FALL wurde mit einer Fitbit Sense Smartwatch am Handgelenk aufgenommen und enthält Beschleunigungs- und Gyroskop-Daten mit einer nativen Abtastrate von 50 Hz [30]. Nach Angabe der Aufgabenstellung stellt WEDA-FALL zusätzlich vordefinierte Downsampling-Varianten bei 40, 25, 10 und 5 Hz bereit. Diese Mehrfach-Abtastraten bilden ein zusätzliches Argument für die Aufnahme von WEDA-FALL in die engere Auswahl: Der Einfluss der in Kapitel 3 diskutierten Abtastrate lässt sich damit an identischen Bewegungssequenzen kontrolliert isolieren, was in keinem der übrigen Datensätze möglich ist. Eine weitere Stärke ist die Einbeziehung von 11 älteren Probanden (über 80 Jahre), was unter den hier betrachteten Datensätzen einzigartig ist. Die Handgelenk-Position weicht jedoch stark von einer Fußsohle ab, und die vergleichsweise niedrige native Abtastrate begrenzt die Auflösung hochdynamischer Phasen. WEDA-FALL ist daher vor allem für handgelenkbasierte Szenarien relevant und bietet sich für eine Kreuzvalidierung des Modells sowie für gezielte Ablationsstudien zur Abtastrate an.

4.3 Verfügbarkeit und Zugänglichkeit

Neben den inhaltlichen Kriterien nennt die Aufgabenstellung ausdrücklich die *Verfügbarkeit und Zugänglichkeit* der Datensätze als Bewertungskriterium. Tabelle 4.2 stellt für jeden der sieben Kandidaten die offizielle Bezugsquelle, die Art des Zugangs sowie die Lizenz zusammen. Der Zugang reicht dabei von einem unmittelbaren Direktdownload ohne Registrierung (UMAFall, KFall, WEDA-FALL) über einfache Kontoerstellungen (FallAllID via IEEE DataPort) bis hin zu einem formal zu unterzeichnenden Nutzungsvertrag mit dem herausgebenden Institut (MobiFall/MobiAct). Für die zeitliche Planung des ML-Teils in Aufgabe 4 ist insbesondere zu berücksichtigen, dass die Freigabe der MobiFall/MobiAct-Daten eine mehrtägige

Bearbeitungszeit erfordert und daher frühzeitig zu beantragen ist. Für SisFall wurde im Rahmen dieser Arbeit festgestellt, dass die in mehreren Publikationen zitierte URL zeitweise nicht erreichbar war; die Daten sind derzeit jedoch wieder über die Projektseite des SISTEMIC-Labors an der Universidad de Antioquia abrufbar.

Table 4.2: Verfügbarkeit und Zugänglichkeit der betrachteten Datensätze.

Datensatz	Bezugsquelle	Zugangsverfahren	Lizenz
SisFall	SISTEMIC, Univ. de Antioquia (Kolumbien)	Direktdownload; URL zeitweise nicht erreichbar	CC BY 4.0
MobiFall / MobiAct	BMI Lab, Hellenic Mediterranean University (Griechenland)	Auf Anfrage per E-Mail; unterschiedlicher Nutzungsvertrag erforderlich	Nur nicht- kommerzielle Forschung
UMAFall	Figshare/Univ. de Málaga (DOI 10.6084/m9.figshare.4214283)	Direktdownload ohne Registrierung	Angabe der Autoren- Publikationen
KFall	KAIST, Google Sites (sites.google.com/view/kfalldataset)	Direktdownload ohne Registrierung	Zitierpflicht
FallAllD	IEEE DataPort (Open Access)	Kostenfreier IEEE-Account (keine IEEE-Mitgliedschaft erforderlich)	Open Access, Zitierpflicht
UniMiB SHAR	SAL-Lab, Univ. Milano-Bicocca (Italien)	Direktdownload; Spiegelkopie auf Kaggle verfügbar	Nur nicht- kommerzielle Forschung
WEDA- FALL	GitHub-Repository von J. Marques (IST Lissabon)	Direktdownload / <code>git clone</code>	Zitierpflicht

Alle in dieser Übersicht genannten Datensätze sind für den akademischen Gebrauch grundsätzlich zugänglich; die formalen Anforderungen unterscheiden sich jedoch erheblich hinsichtlich Aufwand und Bearbeitungszeit. Für die weitere Bearbeitung in Aufgabe 4 wurde sichergestellt, dass die im nächsten Abschnitt als Primär- und Sekundärdatensätze ausgewählten Ressourcen ohne administrative Verzögerungen zur Verfügung stehen.

4.4 Begründete Entscheidung

Auf Basis der oben aufgeführten Kriterien wird **SisFall** als primärer Datensatz für die Modellentwicklung in Aufgabe 4 ausgewählt. Die Gründe für diese Wahl lassen sich wie folgt zusammenfassen:

1. Die **6-Achsen-Konfiguration** stimmt mit der in Kapitel 2 begründeten Empfehlung überein.
2. Der **Messbereich** von ± 16 g bietet den in Abschnitt 3.1 diskutierten Sicherheitspuffer

gegen Clipping, insbesondere für periphere Körperpositionen.

3. Die **hohe Abtastrate** von 200 Hz erlaubt ein Downsampling auf den in Abschnitt 3.2 empfohlenen Bereich (20–50 Hz) ohne Informationsverlust.
4. Die **große Probandenzahl** (38, davon 15 Ältere) und die Vielfalt an Sturz- und ADL-Typen (15 bzw. 19) ermöglichen eine belastbare probandenübergreifende Validierung.
5. Der **etablierte Benchmarkstatus** in der Literatur stellt sicher, dass die eigenen Ergebnisse unmittelbar mit publizierten Arbeiten verglichen werden können.

Als ergänzender Datensatz bietet sich **KFall** an, da er eine vergleichbare Sensorik, eine ausreichende Abtastrate und insbesondere die zeitliche Pre-Impact-Annotation liefert, die für zukünftige Erweiterungen des Modells relevant sein kann.

5 Verlauf der Modellentwicklung (Aufgabe 4 Zwischenstand)

Die vorausgehenden Kapitel haben die theoretischen Grundlagen gelegt: Kapitel 2 begründet die Wahl einer 6-Achsen-IMU, Kapitel 3 leitet den empfohlenen Arbeitspunkt ab (± 16 g, 20–50 Hz, ≥ 12 Bit) und Kapitel 4 wählt SisFall als primären Datensatz. Das vorliegende Kapitel dokumentiert den bisherigen Verlauf der praktischen Modellentwicklung im Rahmen von Aufgabe 4 und stellt die ersten quantitativen Ergebnisse vor. Sämtliche Experimente wurden mit Python 3.12 unter Verwendung von NumPy, SciPy, scikit-learn und TensorFlow/Keras durchgeführt. Der vollständige Quellcode ist im begleitenden Repository verfügbar.

5.1 Datenaufbereitung

Als Trainingsdatensatz dient SisFall [16] mit 4505 Aufzeichnungen (2707 ADL, 1798 simulierte Stürze) von 38 Probanden. Die Rohdaten liegen als kommaseparierte Textdateien mit neun Spalten vor (zwei Beschleunigungssensoren und ein Gyroskop, jeweils als ADC-Rohwerte). Für die Modellentwicklung werden ausschließlich die Kanäle des ADXL345 (± 16 g) und des ITG3200 ($\pm 2000^\circ/\text{s}$) verwendet, da sie der in Kapitel 3 empfohlenen Spezifikation entsprechen und zugleich mit dem für den Prototyp vorgesehenen MPU-6050 kompatibel sind. Die ADC-Rohwerte werden anhand der Herstellerkonstanten in physikalische Einheiten umgerechnet:

$$a [\text{g}] = \text{raw} \cdot \frac{2 \cdot 16}{2^{13}}, \quad \omega [^\circ/\text{s}] = \text{raw} \cdot \frac{2 \cdot 2000}{2^{16}}. \quad (5.1)$$

Anschließend wird das Signal von der ursprünglichen Abtastrate (200 Hz) auf die Zielrate (50 Hz) heruntergetastet. Die Segmentierung erfolgt in gleitenden Fenstern der Länge 2 s mit 50 % Überlappung. Bei Sturzaufzeichnungen wird das Fenster auf den Zeitpunkt des maximalen Beschleunigungsbetrags (Impact) zentriert, um sicherzustellen, dass das Klassifikationsziel tatsächlich die sturzrelevante Signatur enthält und nicht einen beliebigen ruhigen Abschnitt derselben Aufnahme. Die resultierenden Fenster haben die Dimension 100×6 (100 Abtastwerte $\times$ 6 Kanäle).

5.2 Modell 1: Schwellwert-Baseline

Als erste Referenz dient ein klassischer Schwellwertalgorithmus nach Bourke [1]: Ein Fenster wird genau dann als Sturz klassifiziert, wenn der Betrag der Beschleunigung sowohl einen unteren Freifall-Schwellwert von 0,6 g unterschreitet als auch einen oberen Impact-Schwellwert von 2,0 g überschreitet. Dieser Algorithmus benötigt weder Training noch Merkmalsextraktion und bildet damit die einfachste realisierbare Baseline.

Ergebnis: Sensitivität 96,7 %, Spezifität 76,8 %, Genauigkeit 77,5 %. Die hohe Sensitivität

bestätigt, dass das Schwellwertverfahren die meisten Stürze erkennt. Die niedrige Spezifität zeigt jedoch das in Kapitel 2 diskutierte Kernproblem: Sturzähnliche Alltagsaktivitäten wie schnelles Hinsetzen lösen ebenfalls Alarm aus.

5.3 Modell 2: Random Forest mit Magnitude-Features

Um die Spezifität zu verbessern, werden aus jedem Fenster 18 rotationsinvariante Merkmale extrahiert, die ausschließlich auf dem Betrag (SVM) der Beschleunigung und der Winkelgeschwindigkeit basieren. Zu den Merkmalen zählen unter anderem Mittelwert, Standardabweichung, Maximum, Minimum, Spannweite, RMS-Wert, Energie, Schiefe, Kurtosis, Jerk-Standardabweichung und Signal Magnitude Area. Die bewusste Beschränkung auf Betragsgrößen macht die Merkmale weitgehend unabhängig von der Orientierung des Sensors am Körper und trägt damit zur Robustheit gegenüber dem in Abschnitt 5.7 diskutierten Positionswechsel bei.

Ein Random-Forest-Klassifikator mit 200 Bäumen und balancierter Klassengewichtung wird mittels subjektunabhängiger Kreuzvalidierung (GroupKFold, 5 Folds) bewertet, wobei die Gruppierungsvariable der Proband ist. Damit wird sichergestellt, dass keine Daten desselben Probanden gleichzeitig in Training und Test auftreten.

Ergebnis: Sensitivität 94,2 %, Spezifität 99,6 %, Genauigkeit 99,4 %. Die Spezifität steigt gegenüber der Schwellwert-Baseline von 76,8 % auf 99,6 %, was die Anzahl falsch-positiver Alarme um den Faktor 50 reduziert. Die Feature-Importance-Analyse des Random Forest bestätigt die Schlussfolgerung aus Kapitel 2: Vier der fünf wichtigsten Merkmale basieren auf dem Gyroskop (`gyr_std`, `gyr_max`, `gyr_energy`, `gyr_rms`), was den Beitrag der sechsten Achse zur Falsch-Positiv-Reduktion quantitativ belegt.

5.4 Modell 3: 1D-CNN

Als drittes und leistungsfähigstes Modell wird ein eindimensionales Convolutional Neural Network (1D-CNN) trainiert, das direkt auf den rohen 6-Kanal-Fenstern (100×6) arbeitet und keine handgefertigte Merkmalsextraktion benötigt. Die Architektur umfasst drei Faltungsblöcke mit aufsteigender Filterzahl (32, 64, 128), jeweils gefolgt von Batch-Normalisierung und Max-Pooling, sowie einen Global-Average-Pooling-Kopf und zwei vollvernetzte Schichten mit Dropout ($p = 0,3$). Das Modell wird mit dem Adam-Optimierer (Lernrate 10^{-3}), binärer Kreuzentropie und klassenbalancierten Gewichten über 30 Epochen trainiert.

Die Bewertung erfolgt auf einem subjektunabhängigen Testsplit (25 % der Probanden, 10 Subjekte, insgesamt 13 031 Fenster).

Ergebnis: Sensitivität 98,0 %, Spezifität 99,7 %, Genauigkeit 99,6 %. Im Vergleich zum Random Forest sinkt die Anzahl übersehener Stürze von 105 auf 18 (False Negatives), während die Anzahl der Fehlalarme von 215 auf 39 (False Positives) zurückgeht. Das Modell umfasst 45 601 Parameter (178 KB) und konvergiert innerhalb von 30 Epochen ohne Anzeichen von Overfitting, wie die Trainingskurven in Abbildung ?? belegen.

5.5 Vergleich der drei Modelle

Tabelle 5.1 fasst die Ergebnisse zusammen.

Table 5.1: Vergleich der drei Sturzerkennungsmodelle auf SisFall (subjektunabhängig).

Modell	Sensitivität	Spezifität	Genauigkeit	FP	FN
Schwellwert (Bourke)	96,7 %	76,8 %	77,5 %	11 503	59
Random Forest	94,2 %	99,6 %	99,4 %	215	105
1D-CNN	98,0 %	99,7 %	99,6 %	39	18

Der stufenweise Aufbau zeigt, dass jedes nachfolgende Modell den vorhergehenden Schwachpunkt adressiert: Der Random Forest behebt die niedrige Spezifität der Schwellwertmethode, und das 1D-CNN verbessert zusätzlich die Sensitivität bei gleichzeitig nochmals reduzierter Fehlalarmrate.

5.6 TFLite-Export für den Mikrocontroller

Für den Einsatz auf dem ESP32-C6 wird das trainierte Keras-Modell mittels des TensorFlow-Lite-Konverters in ein vollständig int8-quantisiertes Modell überführt. Die Quantisierung verwendet einen repräsentativen Kalibrierungsdatensatz aus 200 zufällig gewählten Trainingsfenstern. Das resultierende `.tflite`-Modell hat eine Größe von lediglich **64 KB** und passt damit problemlos in den 4 MB großen Flash-Speicher des ESP32-C6. Die Inferenzzeit für ein einzelnes Fenster wird auf dem Zielprozessor im Bereich weniger Millisekunden erwartet, sodass eine Echtzeitklassifikation bei der gewählten Abtastrate (50 Hz, Fenster alle 1 s) gewährleistet ist.

5.7 Domänenlücke und Mitigationsstrategien

Der SisFall-Datensatz wurde mit einer am Gürtel (Hüfte) getragenen Sensoreinheit aufgenommen, während das Zielsystem eine schuhsohlenintegrierte Anbringung vorsieht. Diese Positionänderung stellt die wesentliche Domänenlücke dar, da sich die Kinematik der Fußbewegung grundlegend von der des Rumpfes unterscheidet: Beim Gehen erzeugt der Fersenaufsatz (Heel Strike) Beschleunigungsspitzen, die denen eines leichten Stoßereignisses ähneln und somit die Falsch-Positiv-Rate erhöhen können.

Um die Übertragbarkeit zu verbessern, wurden bereits in der aktuellen Pipeline mehrere Maßnahmen umgesetzt:

1. **Rotationsinvariante Merkmale:** Die Random-Forest-Features basieren ausschließlich auf Betragsgrößen (SVM), die unabhängig von der Orientierung des Sensors sind.
2. **Per-Window-Normalisierung:** Jedes Fenster wird vor der Eingabe in das CNN auf Mittelwert 0 und Standardabweichung 1 normiert, wodurch positionsabhängige Gleichanteile (z. B. unterschiedliche Gravitationsprojektion) eliminiert werden.

3. **Subjektunabhängige Validierung:** Die Aufteilung nach Probanden stellt sicher, dass die berichteten Kennzahlen nicht durch probandenspezifische Muster überschätzt werden.

Für die verbleibende Domänenlücke ist ein *Pilot-Fußdatensatz* geplant: Mit dem für den Prototyp vorgesehenen MPU-6050 auf dem ESP32-C6 werden Daten direkt am Fuß aufgezeichnet (Gehen, Laufen, Treppensteigen, Hinsetzen sowie simulierte Stürze auf eine Matte). Anschließend werden die letzten Schichten des trainierten CNN mittels Transfer Learning auf diesen Datensatz feinabgestimmt (Fine-Tuning). Um die Wirksamkeit dieses Vorgehens bereits vor Verfügbarkeit der eigenen Hardware zu überprüfen, wurde der UMAFall-Knöcheldatensatz [26] als Zwischenschritt herangezogen; die Ergebnisse sind in Abschnitt 5.8 dargestellt.

5.8 Cross-Position-Transfer: Quantifizierung der Domänenlücke

5.8.1 Motivation und Versuchsaufbau

Die in Abschnitt 5.7 beschriebene Domänenlücke wurde bislang lediglich argumentativ begründet. Um sie *quantitativ* zu erfassen, wurde ein Transferexperiment durchgeführt. Als Zielposition dient der Knöchelsensor des UMAFall-Datensatzes [26], da dieser unter allen öffentlich verfügbaren Sturzdatensätzen die größte Nähe zur geplanten Sohlenposition aufweist. Ein fußsohlenbasierter öffentlicher Datensatz existiert nach derzeitigem Kenntnisstand nicht; diese Lücke in der Literatur ist zugleich ein wesentliches Alleinstellungsmerkmal des vorliegenden Projekts.

UMAFall verwendet fünf gleichzeitig getragene Sensoren, deren Zuordnung (Sensor-ID zu Körperposition) im Dateikopf jeder Aufnahme dokumentiert ist. Diese Zuordnung ist *nicht* über alle Dateien identisch, weshalb sie bei der Auswertung dateiweise ausgelesen wird. Aus den Aufzeichnungen wurden ausschließlich die Kanäle des Knöchelsensors extrahiert, Beschleunigungs- und Gyroskopströme zeitlich synchronisiert und von der nativen Abtastrate (20 Hz) auf die Eingangsrate des Modells (50 Hz) hochgetastet. Die Fensterung erfolgte analog zur SisFall-Pipeline. Insgesamt standen 6800 Fenster von 19 Probanden zur Verfügung (471 Stürze, 6329 ADL).

Es wurden zwei Bedingungen verglichen:

- **Zero-Shot:** Das unverändert auf SisFall (Hüfte) trainierte 1D-CNN wird ohne jede Anpassung auf die Knöcheldaten angewendet.
- **Fine-Tuning:** Die vorderen Faltungsblöcke werden eingefroren, die übrigen Schichten mit kleiner Lernrate (10^{-4}) auf einem Teil der Knöcheldaten nachtrainiert. Die Bewertung erfolgt subjektunabhängig auf demselben Testsplit wie im Zero-Shot-Fall, sodass beide Bedingungen direkt vergleichbar sind.

5.8.2 Ergebnisse

Tabelle 5.2 und Abbildung 5.1 fassen die Ergebnisse zusammen.

Table 5.2: Cross-Position-Transfer vom Hüft- auf den Knöchelsensor (identischer, subjektunabhängiger Testsplitt).

Bedingung	Sensitivität	Spezifität	Genauigkeit
Referenz: SisFall (Hüfte)	98,0 %	99,7 %	99,6 %
Zero-Shot auf Knöchel	34,8 %	92,2 %	88,5 %
Nach Fine-Tuning	77,3 %	80,7 %	80,5 %
Differenz (Fine-Tuning)	+42,6 pp	−11,5 pp	−8,1 pp




Figure 5.1: Sensitivität und Spezifität des SisFall-Modells auf den UMAFall-Knöcheldaten vor und nach dem Fine-Tuning.

5.8.3 Interpretation

Drei Befunde sind hervorzuheben.

Erstens ist die Domänenlücke erheblich. Das Modell, das an der Hüfte eine Sensitivität von 98,0 % erreicht, erkennt am Knöchel ohne Anpassung nur noch 34,8 % der Stürze. Rund zwei Drittel aller Stürze würden somit übersehen. Bemerkenswert ist, dass die Spezifität mit 92,2 % vergleichsweise hoch bleibt: Das Modell klassifiziert im Zweifelsfall als ADL und wird dadurch *konservativ* statt fehleranfällig. Für eine sicherheitskritische Anwendung ist gerade der Sensitivitätsverlust jedoch der kritische Befund. Damit ist belegt, dass eine unveränderte Übernahme eines hüftbasierten Modells auf die Sohlenposition nicht zulässig ist.

Zweitens ist Transfer Learning wirksam. Das Fine-Tuning auf vergleichsweise wenigen Knöcheldaten hebt die Sensitivität von 34,8 % auf 77,3 %, also um mehr als das Doppelte. Der gleichzeitige Rückgang der Spezifität um 11,5 Prozentpunkte entspricht dem erwarteten

Kompromiss: Das Modell wird empfindlicher und meldet häufiger. Dieses Ergebnis bestätigt die methodische Grundannahme des Projekts, dass die Lücke durch eine vergleichsweise kleine Menge positionsspezifischer Daten geschlossen werden kann – und begründet damit die geplante Erhebung des Pilot-Fußdatensatzes nicht nur plausibel, sondern empirisch.

Drittens sind die absoluten Werte nach dem Fine-Tuning noch nicht praxistauglich. Hierfür kommen mehrere Ursachen in Betracht, die in weiteren Experimenten (Abschnitt 5.9) systematisch getrennt werden: die begrenzte Trainingsdauer, die Beschränkung von UMAFall auf drei Sturztypen, das starke Klassenungleichgewicht (471 zu 6329 Fenster) sowie insbesondere der Abtastraten-Störfaktor. Da UMAFall nativ mit 20 Hz aufzeichnet, das Modell jedoch für 50 Hz trainiert wurde, fügt das erforderliche Hochtasten keine zusätzliche Information hinzu. Ein Teil des beobachteten Leistungsabfalls ist daher möglicherweise nicht auf die Sensorposition, sondern auf die Abtastrate zurückzuführen. Die folgenden Kontrollexperimente dienen dazu, beide Effekte voneinander zu trennen.

5.9 Nächste Schritte

5.9.1 Geplante Kontrollexperimente

Zur Absicherung und Präzisierung der Ergebnisse aus Abschnitt 5.8 sind drei aufeinander aufbauende Experimente vorgesehen:

1. **Verlängertes Fine-Tuning.** Die Trainingskurven zeigen, dass der Validierungsverlust am Ende der 20 Epochen noch fällt und die Sensitivität noch steigt. Das Training wurde folglich zu früh beendet. Eine Wiederholung mit 60 Epochen und einer geringeren Zahl eingefrorener Schichten soll klären, welcher Anteil des verbleibenden Rückstands allein auf die Trainingsdauer entfällt.
2. **Kontrollexperiment Taille.** Derselbe Transfer wird auf den *Taillensensor* von UMAFall angewendet. Da diese Position der SisFall-Aufnahmeposition entspricht, isoliert der Vergleich den Positionseffekt vom reinen Datensatzwechsel: Bleibt die Leistung an der Taille hoch und fällt nur am Knöchel ab, ist die Sensorposition als Ursache belegt.
3. **Abtastraten-Kontrolle.** Das SisFall-Modell wird direkt bei 20 Hz trainiert und anschließend ohne Hochtasten auf die Knöcheldaten übertragen. Die dann verbleibende Differenz entspricht dem reinen Positionseffekt und erlaubt zugleich eine experimentelle Überprüfung der in Kapitel 3 abgeleiteten Abtastratenempfehlung.

5.9.2 Weitere Arbeitsschritte

Die folgenden Arbeitsschritte sind für den verbleibenden Projektzeitraum geplant:

1. **Ablationsstudie zur Abtastrate:** Wiederholung des CNN-Trainings bei 10, 20 und 50 Hz, um die in Kapitel 3 diskutierte Empfehlung experimentell zu überprüfen.
2. **Kreuzvalidierung auf KFall:** Training auf SisFall, Test auf KFall [27] und umgekehrt, um die Generalisierbarkeit über Datensatzgrenzen hinweg zu bewerten.

3. **Hardware-Integration:** Aufbau des ESP32-C6 + MPU-6050 Prototyps, Portierung des int8-TF Lite-Modells mittels `esp-tflite-micro` oder Edge Impulse und Messung der On-Device-Inferenzzeit sowie des Energieverbrauchs.
4. **Pilotdatenerhebung am Fuß:** Aufzeichnung eines kleinen Fußdatensatzes zur Validierung und zum Fine-Tuning.
5. **Long-Lie-Erkennung:** Implementierung einer zweiten Erkennungsstufe, die nach einem erkannten Sturz die Bewegungslosigkeit überwacht und bei anhaltender Liegeposition (> 60 s) einen Notfallalarm auslöst.

Bibliography

- [1] F. Bagalà, C. Becker, A. Cappello, L. Chiari, K. Aminian, J. M. Hausdorff, W. Zijlstra, and J. Klenk, “Evaluation of accelerometer-based fall detection algorithms on real-world falls,” *PLOS ONE*, vol. 7, no. 5, p. e37062, 2012.
- [2] A. Dinh, Y. Shi, D. Teng, A. Ralhan, L. Chen, V. D. Bui, H. Nguyen, D.-H. Le, W.-Y. Ko, K.-H. Ihn, and H. H. Nguyen, “A fall and near-fall assessment and evaluation system,” *Open Biomedical Engineering Journal*, vol. 3, pp. 1–7, 2009.
- [3] Q. T. Huynh, U. D. Nguyen, L. B. Irazabal, N. Ghassemian, and B. Q. Tran, “Optimization of an accelerometer and gyroscope-based fall detection algorithm,” *Journal of Sensors*, vol. 2015, p. Article ID 452078, 2015.
- [4] A. Hakim, M. S. Huq, S. Shanta, and B. S. K. K. Ibrahim, “Smartphone based data mining for fall detection: Analysis and design,” *Procedia Computer Science*, vol. 105, pp. 46–51, 2017.
- [5] A. Aggarwal *et al.*, “Fall detection using knowledge-distillation-based LSTM for offline embedded and low-power devices.” *arXiv preprint* arXiv:2308.12481, 2023.
- [6] P. Author, “Enhancing real-world fall detection using commodity devices: A systematic study,” *Sensors*, vol. 25, no. 17, p. 5249, 2025.
- [7] D. Roetenberg, H. J. Luinge, C. T. M. Baten, and P. H. Veltink, “Compensation of magnetic disturbances improves inertial and magnetic sensing of human body segment orientation,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 13, no. 3, pp. 395–405, 2005.
- [8] I. Weygers, M. Kok, M. Konings, H. Hallez, H. De Vroey, and K. Claeys, “Inertial sensor-based lower limb joint kinematics: A methodological systematic review,” *Sensors*, vol. 20, no. 3, p. 673, 2020.
- [9] S. Yang, M. Liu, W. Du, *et al.*, “NeurIT: Pushing the limit of neural inertial tracking for indoor robotic IoT.” *arXiv preprint* arXiv:2404.08939, 2024.
- [10] W. H. K. de Vries, H. E. J. Veeger, C. T. M. Baten, and F. C. T. van der Helm, “Magnetic distortion in motion labs, implications for validating inertial magnetic sensors,” *Gait & Posture*, vol. 29, no. 4, pp. 535–541, 2009.
- [11] InvenSense Inc. (TDK), “MPU-6000/MPU-6050 Product Specification, Revision 3.4,” tech. rep., InvenSense Inc., Sunnyvale, CA, USA, 2013. Datasheet number PS-MPU-6000A-00.
- [12] STMicroelectronics, “LSM6DSOX: iNEMO Inertial Module with Machine Learning

- Core,” tech. rep., STMicroelectronics, Geneva, Switzerland, 2020. Datasheet DS12140, Rev. 2.
- [13] Bosch Sensortec GmbH, “BHI360: Smart Sensor with Integrated IMU and On-Chip Sensor Fusion,” tech. rep., Bosch Sensortec GmbH, Reutlingen, Germany, 2023. Preliminary Datasheet.
- [14] Bulliot, B. and others, “Personal system for the detection of a risky situation and alert.” U.S. Patent 10,152,869, 2018. Cited for the widely used 0.6 g / 2.0 g fall threshold pair. Replace with a peer-reviewed source (e.g. Bourke) before final submission if preferred.
- [15] F. M. G. Cornelissen, R. Peeters, R. van der Straaten, C. E. E. M. van der Zee, A. De Brabandere, and B. Vanwanseele, “Evaluation of a restoration algorithm applied to clipped tibial acceleration signals,” *Sensors*, vol. 23, no. 10, p. 4747, 2023.
- [16] A. Sucerquia, J. D. López, and J. F. Vargas-Bonilla, “SisFall: A fall and movement dataset,” *Sensors*, vol. 17, no. 1, p. 198, 2017.
- [17] J. R. Villar, E. de la Cal, M. Fañez, V. M. González, and J. Sedano, “A study of the influence of the sensor sampling frequency on the performance of wearable fall detectors,” *Measurement*, vol. 193, p. 110945, 2022.
- [18] A. Díaz-Ramírez *et al.*, “The impact of the accelerometer sampling rate on the performance of machine and deep learning models in wearable fall-detection systems,” *Sensors*, vol. 26, no. 1, p. 162, 2026.
- [19] NXP Semiconductors, “AN4075 – The Trade-Off Between High Resolution and Low Power Consumption in MEMS Accelerometers,” tech. rep., NXP Semiconductors (formerly Freescale), 2013. Application note. Discusses effective number of bits in noise-limited MEMS accelerometers.
- [20] S. Arar, “Accelerometer specifications: Measurement range, sensitivity, and noise performance,” 2022. Technical article. Cited for the RMS-noise/bandwidth relation and the “10× noise floor” rule of thumb. Consider replacing with an appropriate NXP or ADI application note for the final submission.
- [21] M. Vagner, P. Beneš, and Z. Havránek, “MEMS gyroscope performance comparison using Allan variance method,” *Recent Researches in Applied Electrical Engineering*, pp. 199–204, 2011.
- [22] D. S. Ilcev, “Bias drift estimation for MEMS gyroscope used in inertial navigation,” *Geodesy and Cartography*, vol. 66, no. 1, pp. 61–79, 2017.
- [23] M. Ilyas, K.-S. Kim, J. Cho, and S. Park, “Strapdown inertial navigation systems for positioning mobile robots – MEMS gyroscopes random errors analysis using Allan variance method,” *Sensors*, vol. 20, no. 17, p. 4741, 2020.
- [24] G. Vavoulas, M. Pediaditis, E. G. Spanakis, and M. Tsiknakis, “The MobiFall dataset:

- An initial evaluation of fall detection algorithms using smartphones,” in *Proceedings of the 13th IEEE International Conference on BioInformatics and BioEngineering*, pp. 1–4, 2014.
- [25] G. Vavoulas, C. Chatzaki, T. Malliotakis, M. Pediaditis, and M. Tsiknakis, “The MobiAct dataset: Recognition of activities of daily living using smartphones,” in *Proceedings of the International Conference on Information and Communication Technologies for Ageing Well and e-Health (ICT4AWE)*, pp. 143–151, 2016.
- [26] E. Casilari, J. A. Santoyo-Ramón, and J. M. Cano-García, “UMAFall: A multisensor dataset for the research on automatic fall detection,” *Procedia Computer Science*, vol. 110, pp. 32–39, 2017.
- [27] X. Yu, J. Jang, and S. Xiong, “A large-scale open motion dataset (KFall) and benchmark algorithms for detecting pre-impact fall of the elderly using wearable inertial sensors,” *Frontiers in Aging Neuroscience*, vol. 13, p. 692865, 2021.
- [28] M. Saleh, M. Abbas, and R. Le Bouquin Jeannès, “FallAllD: An open dataset of human falls and activities of daily living for classical and deep learning applications,” *IEEE Sensors Journal*, vol. 21, no. 2, pp. 1849–1858, 2021.
- [29] D. Micucci, M. Mobilio, and P. Napoletano, “UniMiB SHAR: A dataset for human activity recognition using acceleration data from smartphones,” *Applied Sciences*, vol. 7, no. 10, p. 1101, 2017.
- [30] J. Marques, N. Bento, M. Barandas, and H. Gamboa, “Online fall detection using wrist devices,” *Sensors*, vol. 23, no. 3, p. 1146, 2023.

Versicherung

Ich versichere, dass ich diese Arbeit selbstständig verfasst und keine anderen als die angegebenen Hilfsmittel benutzt habe. Die den benutzten Hilfsmitteln wörtlich oder inhaltlich entnommenen Stellen habe ich unter Quellenangaben kenntlich gemacht. Die Arbeit hat in gleicher oder ähnlicher Form noch keiner anderen Prüfungsbehörde vorgelegen.

I declare that I have authored this thesis independently, that I have not used other than the declared sources / resources and that I have explicitly marked all material which has been quoted either literally or by content from the used sources.

Place, Date

Aly Elbermawy